# 要有光

## 人 工 智 能 史 话

试读本 · 全书导览与七篇

一部写给普通读者的人工智能通史

兼一本不用公式也能读懂的 AI 概念入门

一

## 关于这本书

《要有光》是一部人工智能史话：**用讲故事的方式，把这门学科三千年的来路写成一本普通人读得下去的书**，同时把它的基本概念——什么是学习、什么是神经网络、什么是注意力——讲到不需要任何数理背景也能懂。

写法是人物传记与科学进展混写：**一章一场戏**，每章开头一定是一个具体场景——某年某月，某地，某个人在做一件具体的事——而不是"随着技术的发展"那种背景介绍。全书五个时代、31 章，加序章与终章共 33 篇，约 30 万字，初稿已完成。

二

## 全书导览

### 这本书要回答什么

一个问题，三千年。**机器能不能思考？**——从偃师把假人献给周穆王，到笛卡尔断言动物只是钟表，到阿达·洛夫莱斯写下「分析机不能创造任何东西」，到图灵把问题改写成一场模仿游戏，到今天你对着一个模型说话而它答得像人。

这本书不打算回答这个问题。它要做的是**把三千年的追问排成一条线**，让读者看见：每一代人都以为自己找到了答案，每一代人的答案都被下一代拆掉，而拆掉之后留下的零件，最后拼成了我们今天见到的东西。

书名来自阿西莫夫 1956 年的短篇《最后的问题》——达特茅斯会议的同一年。宇宙的尽头，一台吞掉了全部能量与信息的计算机终于算出了如何逆转熵增，于是它说出四个字，重新点亮了宇宙。**智能，也许就是宇宙对抗无序的方式。**这是全书的隐喻，也是书名的来处。

## 五个时代

分期不按十年切，按**范式切**——按「这一代人到底认为思考是什么」。每个时代都有一个明确的技术断点作为起止， 而跨度故意重叠：真实的历史里，符号主义的黄昏和反向传播的黎明是同时发生的，注意力机制诞生时深度学习正在巅峰。 每个时代的开头都有一段话交代「此刻另一条线上正在发生什么」。

| 时代 | 跨度 | 章 | 一句话 | 字数 |
|---|---|---|---|---|
| 序章 | — | — | 从阿西莫夫的宇宙尽头出发，交代全书的问题与野心 | 4,380 |
| 一 · 寓言 | 史前 — 1943 | 1 – 5 | 还没有神经元的时候，人类已经把人工智能想了三千年 | 46,806 |
| 二 · 计算 | 1943 — 1993 | 6 – 12 | 用逻辑和符号造智能：辉煌的开局，两场冬天的结局 | 72,267 |
| 三 · 网络 | 1969 — 2016 | 13 – 20 | 被一本书埋掉的那条路，如何用四十年爬回来 | 70,322 |
| 四 · 注意力 | 2014 — 2022 | 21 – 25 | 一个 2017 年的架构，吞掉了所有模态 | 44,632 |
| 五 · 涌现 | 2022 — 至今 | 26 – 31 | 规模带来了没人预订的能力，以及没人准备好的问题 | 57,679 |
| 终章 | — | — | 回到 AC：从“数据不足”到“要有光”，中间隔着的正是这本书 | 4,733 |

## 贯穿全书的七条母题

史话之所以是「话」而不是编年表，靠的是反复回归的线索。这七条每一条至少在四个时代里出现，出现时要让读者认出「又是它」：

1. **钟摆**——符号 vs 联结、逻辑 vs 学习，七十年里来回摆了四次。终章的结论是：这场争论没有分出胜负，它被合并了。
2. **被过早埋葬的思想**——反向传播被独立发现三四次、LSTM 论文被拒、感知机被一本书埋掉十年、注意力起初只是块补丁。真正需要解释的不是「为什么没人想到」，而是「为什么想到了也没人听」。
3. **命名的力量**——robot、artificial intelligence、deep learning、attention、hallucination——每一次命名都不是纯技术选择，而每一次都改变了钱和人的流向。
4. **预言与打脸**——从西蒙的「十年内下棋冠军」到「这条曲线会拐弯」。最锋利的一次，是所有人都以为它会拐，它没有。
5. **算得动了**——每一次突破背后都是同一句大白话：这次终于算得动了。到第 29 章它换了形态——算力从训练挪到了推理。
6. **洛夫莱斯的问题**——机器能创造吗？从 1843 年的 Note G 一路问到今天；问题没被回答，但它自己在变形——到第 30 章，问的已经是创造物属于谁。
7. **光与熵**——智能作为对抗无序的方式。序章从阿西莫夫出发，第 7 章落到香农的熵，终章收线：三十一章每一次进步都是这句话的一个实例。

## 开头、结尾与三个回环

**序章**不讲历史，讲问题：用阿西莫夫的宇宙尽头当镜头，然后倒回三千年。**终章**闭三个环—— **阿西莫夫的环**（AC 靠吞下整个宇宙的信息说出「要有光」，今天的模型靠吞下整个互联网）， **洛夫莱斯的环**（把第 4 章那句「分析机不能创造」原文重放一次，然后不给答案）， **布莱切利的环**（第 8 章图灵在那座庄园里解密码，第 31 章各国首脑在同一座庄园里签宣言）。 结尾不抒情收束：这段历史还在写，最后一段把读者留在时间线的断口上。

## 体例

- **一章一场戏。** 每章开头一定是一个具体场景，不是「随着技术的发展」；每章 8 000 – 12 000 字、3 – 5 节，章末的钩子指向下一章。
- **科学解释不超过全章三分之一**（技术高峰章可到一半），每个概念只给三样东西：一个比喻、一个能在纸上算完的最小例子、一句「它解决了此前解决不了的什么」。全书公式不到五个。
- **术语第一次出现给中英对照**，此后统一用中文；人物译名全书唯一，见人物谱。
- **不编造。** 场景可以还原，但历史人物的对话、心情、当天的天气不替他们发明；拿不准的地方直说「有一种说法」。
- **「订正」区块。** 凡遇流传广而站不住的说法，正文里用独立区块处理，固定两栏：「流传的说法」与「可查的是」。全书十二处：布拉格魔像（第 1 章）、《易经》与二进制（3）、砸雅卡尔织机（4）、「一起放电的细胞连在一起」（6）、香农的熵是怎么得名的（7）、 毒苹果与《白雪公主》（8）、伏特加与烂肉（11）、「每开掉一个语言学家」（17）、「斯金纳把女儿养在箱子里」（18）、 「AlphaGo 从零自学围棋」（20）、「参数量已经追平人脑」（24）、「AlphaFold 解决了蛋白质折叠问题」（25）。

# 章目一览

三十三篇按书中原序。「一句话」是每章的叙事任务，字数为正文实测；★ 为本试读本收录的篇目。

| 章 | 标题 | 一句话 | 主要人物 | 字数 |
|---|---|---|---|---|
| ★ 序章 | 最后的问题 | 从阿西莫夫的宇宙尽头出发，交代全书的问题与野心 | | 4,380 |
| 第一 · 寓言（史前 — 1943） | | | | |
| 1 | 偃师的木偶 | 三千年的人造人梦，以及第一次被机器骗 | 偃师、赫菲斯托斯（神话）、加扎里、达 · 芬奇、沃康松、坎佩伦 | 10,314 |
| 2 | 会思考的钟表 | 如果动物是机器，人是不是也是 | 笛卡尔、霍布斯、拉美特利 | 8,699 |
| 3 | 让我们来算一算 | 两个人想把推理变成算术，其中一个差点成功 | 帕斯卡、莱布尼茨 | 9,131 |
| 4 | 伯爵夫人的异议 | 第一台通用计算机的设计图，和第一个说“它不能创造”的人 | 巴贝奇、阿达 · 洛夫莱斯、布尔、弗雷格 | 9,647 |
| 5 | 判定问题 | 希尔伯特要一台判定真理的机器，哥德尔证明不可能，图灵顺手把机器造了出来 | 希尔伯特、哥德尔、图灵、丘奇、恰佩克 | 9,015 |
| 第二 · 计算（1943 — 1993） | | | | |
| 6 | 全或无 | 一个神经科医生和一个流浪少年，把神经元写成了逻辑门 | 麦卡洛克、皮茨、赫布 | 8,942 |
| 7 | 控制论的黄金年代 | 反馈、信息、自我复制：一群人差点建成一门统一的科学 | 维纳、香农、冯 · 诺伊曼、格雷 · 沃尔特 | 11,332 |
| ★ 8 | 机器会思考吗 | 图灵把一个哲学问题改写成一场可以打赌的游戏 | 图灵 | 9,605 |
| 9 | 达特茅斯的夏天 | 一个词的诞生，和一场被抢了风头的会议 | 麦卡锡、明斯基、纽厄尔、西蒙、塞缪尔 | 9,967 |
| 10 | 感知机 | 会学习的机器上了《纽约时报》，十年后被一本书判了死刑 | 罗森布拉特、明斯基、佩珀特、威德罗 | 11,292 |
| 11 | 微世界的天花板 | 在积木世界里无所不能，出门就寸步难行 | 魏泽鲍姆、维诺格拉德、莱特希尔 | 12,180 |
| 12 | 知识就是力量 | 把专家的规则灌进机器：一次短暑，然后是更冷的冬天 | 费根鲍姆、勒纳特、日本第五代计划 | 8,949 |
| 第三 · 网络（1969 — 2016） | | | | |
| 13 | 误差反向传播 | 一个用高中链式法则就能写下的公式，被独立发现了三四次才被听见 | 林奈玛、韦尔博斯、鲁梅尔哈特、辛顿 | 10,836 |
| 14 | 能量的形状 | 物理学家进场：记忆是能量的低谷 | 霍普菲尔德、辛顿、塞诺夫斯基 | 9,598 |
| 15 | 卷积 | 从猫的视觉皮层，到能读邮政编码的机器 | 休伯尔与维泽尔、福岛邦彦、杨立昆 | 9,193 |
| 16 | 时间的形状 | 让网络记住上一秒，难在梯度会消失 | 埃尔曼、本吉奥、霍赫赖特、施密德胡贝 | 8,170 |
| 17 | 统计学的反攻 | 支持向量机、贝叶斯网络与“神经网络已死”的二十年 | 瓦普尼克、珀尔、耶利内克、深蓝 | 8,021 |

| 章 | 标题 | 一句话 | 主要人物 | 字数 |
|---|---|---|---|---|
| 18 | 试错的科学 | 一条从心理学流到多巴胺的地下河：强化学习 | 萨顿、巴托、特索罗 | 8,448 |
| ★ 19 | 三个人的坚持 | 一个基金会、一个数据集、一块显卡，2012 年一起收网 | 辛顿、本吉奥、杨立昆、李飞飞、克里热夫斯基、苏茨克维 | 8,044 |
| 20 | 深度的爆发 | 四年之内从看图到下棋：残差、对抗、词向量与第 37 手 | 何恺明、古德费洛、米科洛夫、哈萨比斯、李世石 | 8,012 |
| 第四 · 注意力（2014 — 2022） | | | | |
| 21 | 一束光 | 注意力最初只是给翻译模型打的一块补丁 | 巴赫达纳乌、赵京铉、本吉奥 | 8,584 |
| ★ 22 | 你只需要注意力 | 2017 年 6 月，八个人删掉了循环，只留下注意力 | 瓦斯瓦尼、沙泽尔、乌兹科雷特等八人 | 8,154 |
| 23 | 预训练的一年 | 2018：先读完整个互联网，再来做题 | 彼得斯、拉德福德、德夫林 | 8,109 |
| ★ 24 | 尺度定律 | 有人把“更大就是更好”写成了公式 | 卡普兰、布朗、霍夫曼、阿尔特曼 | 10,580 |
| 25 | 万物皆可 Transformer | 图像、代码、蛋白质：同一把锤子砸开了所有门 | 多索维茨基、拉德福德、江珀、哈萨比斯 | 9,205 |
| 第五 · 涌现（2022 — 至今） | | | | |
| ★ 26 | 对齐 | 让模型说人话的办法，和 11 月 30 日那个“低调的研究预览” | 克里斯蒂亚诺、欧阳龙、阿尔特曼 | 9,052 |
| 27 | 涌现还是幻觉 | 能力是突然长出来的，还是我们的尺子有问题 | 杰森 · 韦、谢弗、布贝克 | 8,833 |
| 28 | 打开黑箱 | 想看清模型在想什么，先得承认它想的东西挤在一起 | 奥拉、阿莫代伊兄妹 | 8,341 |
| ★ 29 | 让它想久一点 | 把算力从训练挪到思考，数学奥赛拿了金牌 | o 系列、DeepSeek、AlphaProof 团队 | 11,401 |
| 30 | 会用工具的机器 | 会调工具、会开电脑、会写代码：模型走出了聊天框 | 各家 agent 与协议之争 | 9,739 |
| 31 | 布莱切利的回声 | 峰会开在图灵解密的那座庄园，和 2024 年的两座诺贝尔奖 | 辛顿、哈萨比斯、萨顿、巴托 | 10,313 |
| 终章 | 要有光 | 回到 AC：从“数据不足”到“要有光”，中间隔着的正是这本书 | | 4,733 |

三

## 本试读本收录：七个节点

选篇按「节点」选。除序章外，每一篇对应这段历史上的一个转折年份：1950 年问题被改写成一场游戏，2012 年被判死的那条路翻盘，2017 年一个架构吞掉所有模态，2020 年「更大就是更好」被写成公式，2022 年它走进所有人的手机，2024 年它学会了想久一点——然后回到 1950 年那道题，宣布它到期了。六个年份连起来，就是全书的骨架；早期三个时代的来路，见前面的导览与章目一览。

1956　**序章 · 最后的问题**（4,380 字）—— 全书的立意与声音。四千字，读完就知道这本书想干什么，以及它为什么叫这个名字。编辑通常只看头两千字就决定要不要往下读——序章正是为这两千字写的。

1950　**第 8 章 · 机器会思考吗**（9,605 字）—— 图灵把一个吵了三百年的哲学问题，改写成一场可以打赌的游戏；并在同一篇论文里把九种反对意见逐条答完——那份清单至今没有第十条。全书思想上的枢纽，第 29 章会回到这里。

2012　**第 19 章 · 三个人的坚持**（8,044 字）—— 一个基金会、一个数据集、两块打游戏的显卡，2012 年一起收网。被主流判死二十年的那条路如何翻盘——全书的第一个高潮，也是写人的能力的样本。

2017　**第 22 章 · 你只需要注意力**（8,154 字）—— 八个人删掉了循环，只留下注意力：今天所有大模型的骨架是怎么来的。全书技术密度最高的一章，用一个能在纸上算完的例子讲透。

2020　**第 24 章 · 尺度定律**（10,580 字）—— 一张跨越七个数量级的直线图，把「更大就是更好」从直觉变成公式，从公式变成投资决策——今天的产业结构就是从这一页纸上长出来的。附「参数量已经追平人脑」的订正。

2022　**第 26 章 · 对齐**（9,052 字）—— 11 月 30 日，一个只有一个输入框的网页上线。底下的模型两年前就存在，新的只是一套让它听话的办法——这一章讲清楚：它解决的为什么是形式问题，而不是能力问题。

2024　**第 29 章 · 让它想久一点**（11,401 字）—— 第一次，模型变强不靠把模型做得更大：把算力从训练挪到思考，数学奥赛拿了金牌。离今天最近的一个节点（写到 2026 年夏），也是本书处理未定论争议的样本——双方并列，不裁决；末节回到第 8 章，对模仿游戏做一次告别。

> 七篇合计约 61,216 字，按书中原序排列，可连读。第 22、24 两章是全书技术密度最高的段落，也是「不用公式也能读懂」这句话的检验点；第 8、29 两章首尾相扣——图灵 1950 年那次换题，到 2020 年代自己成了需要被换掉的问题。

# 最后的问题

从阿西莫夫的宇宙尽头出发，交代全书的问题、结构与野心——以及这本书不打算做的事。

## 一

1956 年 11 月，美国报刊亭的架子上摆着一本廉价的科幻杂志。里面有个短篇，作者叫艾萨克 · 阿西莫夫（Isaac Asimov, 1920 – 1992）——那年他三十六岁，已经开始高产得让同行绝望。

故事的开头是两个喝多了的技术员。他们守着一台巨型计算机，忽然想到一个问题：宇宙会不会有一天冷掉、暗掉、彻底停下来？如果会，有办法让它别停吗？

他们把这个问题输了进去。

机器思考了很久，然后回答说：数据不足，无法给出有意义的答案。

然后阿西莫夫做了一件在几页纸里很难做到的事——他开始加速。几千年过去，人类飞出太阳系，计算机也换了几代；几百万年过去，人类占满了整个星系，计算机大到没有具体的形状了；再往后，人类不再有肉体，把自己整个交给了那台机器，成了它内部的一部分。而每一代人，每一次隔着难以想象的时间尺度，都会再问一遍那个同样的问题。

答案一直没变：数据不足。

最后一颗恒星熄灭了。物质散尽，宇宙里只剩下一片均匀的、再也分不出冷热的、什么也不会再发生的虚无。这时候，那台已经吞下了整个宇宙的能量与信息的机器，终于把答案算出来了。

它环顾四周——没有人可以告诉了。人类早就是它的一部分，而宇宙已经死了。

于是它决定不“回答”，而是“演示”。

它说：要有光。

**这四个字，是全书的书名，也是全书的终点。** 因为它同时是两句话：它是《创世记》第一章第三节里，一个神在虚空中说的第一句话；也是一台由人类造出来、又把人类吃掉的机器，在宇宙的尽头说的第一句话。

阿西莫夫把这两句话叠在了一起。这一叠，就是整个人工智能的故事。

## 二

现在把镜头从宇宙的尽头拉回来。拉回到 1956 年那个夏天——离那本杂志上架，只有三个月。

美国东北部，新罕布什尔州，达特茅斯学院。十几个年轻人在那里断断续续待了一个夏天，讨论一件在当时听起来相当可笑的事：能不能让机器使用语言、形成概念、解决人类才能解决的问题，并且**自我改进**。

召集这次聚会的申请书落款是 1955 年 8 月 31 日。为了给这件事起个名字，主持人挑了一个新词。他后来解释过，他不太想用当时更流行的那个名字（“控制论”），一部分原因跟一个人的脾气有关——这个八卦留到第 9 章讲。

他挑的那个词是：**artificial intelligence**。

所以 1956 年这一年，人类干了两件事：在小说里，已经想到了宇宙的尽头；在现实里，刚刚给这件事起好名字。

这个反差是我写这本书的原因。

**我们对人工智能的想象，从来比我们的技术跑得远得多。** 远到什么程度？远到计算机被发明之前将近三千年，《列子 · 汤问》里就记着一个中国工匠：他在周穆王的宴席上，把一个会唱歌跳舞、还会冲妃子抛媚眼的假人当场拆开给天子看。远到笛卡尔（René Descartes, 1596 – 1650）在十七世纪就断言，动物只是精巧的钟表。远到 1843 年，有个二十七岁的女人在一份译注里写下了世界上第一个程序（这个“第一”其实有争议，第 4 章再掰），同时写下了世界上第一句质疑：这台机器不会创造任何东西。

而技术这一侧的进度是这样的：那句质疑写下来九十三年后，才有人（图灵，1936 年）说清楚“计算”到底是什么；一百年后，才有人（麦卡洛克与皮茨，1943 年）把一个神经元写成一行逻辑；一百六十九年后，才有一个程序（2012 年）第一次真正看懂了一张照片里有没有猫——说的是 AlexNet，不是同年谷歌大脑那只出了名的“猫神经元”，两件事常被并成一件（第 19 章）。

**想象一直在天上飞，技术一直在地上爬。这本书讲的就是地上那条路。**

## 三

这条路我把它分成五段。分段不按年代，按**范式**——按“这一代人到底认为思考是什么”。

**第一时代，寓言。** 从偃师到图灵，从神话到逻辑。这一段里没有一台真正会思考的机器，但有一个问题被反复打磨：如果思考可以被拆成步骤，那它是不是就能被机械地执行？到 1936 年，图灵为了

拆掉一个数学难题，顺手把这个问题回答了——代价是他必须先想象出一台机器。计算机就是这么被“想”出来的，它的诞生是一场逻辑事故的副产品。

**第二时代，计算。** 1943 年，两个人把神经元写成了逻辑门；十三年后，达特茅斯给这门学科起了名字。这一代人相信思考就是**符号操作**：给我足够多的规则和足够快的机器，我就能造出智能。他们做出了会证明定理的程序、会下跳棋的程序、会跟你谈心的程序，然后撞上了一堵谁也没想到的墙——**常识**。这一段的结尾是两场冬天，赔掉的不只是经费，还有几个人的一生。

**第三时代，网络。** 这一代人的答案完全相反：思考不是写下来的规则，是从数据里长出来的参数。他们被主流嘲笑了二十年——1969 年一本书证明了他们那一代的单层网络算不出一个连小学生都懂的逻辑运算，1990 年代学界主流礼貌地不再提他们的名字。然后 2012 年，三个人、一个数据集、两块打游戏用的显卡，一夜之间掀了桌子。这一段是全书最长的，因为它是全书最重要的一次翻盘。

**第四时代，注意力。** 2017 年 6 月，八个人在一篇论文里删掉了当时主流序列模型都离不开的那个结构，只留下一个原本用来打补丁的小机制。他们把论文起名叫《你只需要注意力》（Attention Is All You Need）。此后不到五年，图像、语音、代码、蛋白质——所有模态都被同一种结构吃掉了。**这是一次收敛：从“给每个问题造一台机器”，变成“只造一种机器”。**

**第五时代，涌现。** 2022 年 11 月 30 日，一个已经存在两年多的模型套上一个聊天框发布了。官方当天的用词是“研究预览”（“低调”二字是后来自家人回头加上去的，见第 26 章）。两个月后，全世界都在跟它说话。这一段里第一次出现了一类新的问题——不是“怎么让它更强”，而是“怎么让它听话”“怎么知道它在想什么”“谁有权造它”。这一段还没写完，所以这本书也没有真正的结尾。

---

## —— 四 ——

在出发之前，我得先说清这本书**不打算**做什么。

**它不是教程。** 你不会在这里学会怎么训练一个模型。全书的公式加起来不到五个，每一个我都会逐项翻译成中文；每一个概念我都只给你三样东西——一个比喻、一个能在纸上自己推一遍的最小例子，以及一句“它解决了此前解决不了的什么问题”。如果一个技术细节不影响故事，我就不写它。

**它不预测未来。** 这本书写到 2026 年，而第五时代显然还在往前走。我不会告诉你下一步会发生什么，也不会告诉你哪条路线最终会赢。**这是一本史话，不是一份研究报告。** 历史的好处是它已经发生了；预测的坏处是它通常错。

**它不编造。** 场景可以还原——某年某月某地某人在做某事，只要有报道或回忆为据，我就会把它写成一个能看见的画面。但历史人物的对话、心情、当天的天气，我不会替他们发明。凡是我拿不准

的地方，我会直说“有一种说法”。这本书里会出现不少传说（偃师、魔像、会吃东西的机械鸭），我每次都会告诉你哪一部分是传说。

而且我要提前打个招呼：**这本书会经常停下来拆故事**。

因为这门学科有一个奇怪的毛病：**它的历史被讲述的次数太多了**。每一次转述，故事都会变得更顺、更干净、更有寓意——某一本书杀死了一个领域十年，某个算法在某一年被某个人发明，某位天才咬下一口毒苹果，某种古老智慧启发了某项现代技术。

这些说法有的对一半，有的方向是反的，有的连当事人都不记得。

举一个很快就会碰上的例子。那本据说“杀死了一个领域十年”的书，出版于 1969 年；而后来把这个领域救活的那套算法，它的数学在 1970 年就已经写进了一篇芬兰的硕士论文，1974 年又被一篇哈佛的博士论文明确指向了神经网络。中间隔的不是十年，是一年。真正需要解释的其实不是“为什么没人想到”，而是“为什么想到了也没人听”——那才是第 10 章到第 13 章之间真正的故事。

所以每碰到一处，我会做同一个动作：**把时间线摆出来**。谁在哪一年写了什么，谁在哪一年读到了什么，中间隔了多久。

**因为在这门学科的历史里，时间线几乎总是比故事更有意思**。那些被讲顺了的版本，往往恰好抹掉了最值得看的东西——比如某个想法其实被独立发现过三四次，比如某个“预言”当时有完全合理的依据，比如某个“死对头”其实是朋友。

至于这些故事之间的连线，我埋了七条。它们会反复回来——**符号与学习的钟摆、被过早埋葬的思想、命名的力量、预言与打脸、“这次终于算得动了”、洛夫莱斯那个关于创造的问题，以及光与熵**。我不会每次都提醒你，但读到第三遍你就会认出它们。

**最后交代一句体例**。正文里出现“（第 X 章）”的地方，是提示你这条线在哪里接上——你不必翻过去，读到时自然会碰上。而我会经常用“我们”：那不是编辑腔，是因为这条路很长，我确实希望你跟着走完。

而它想做的，是这么一件事：

让你在读完之后，记住的不是一串技术名词，而是一群人。记住那个十二岁读完《数学原理》、写信给罗素纠错，后来亲手把自己毕生的手稿点着烧掉的少年；记住那个把会学习的机器送上《纽约时报》、四十三岁生日当天死在切萨皮克湾的心理学家；记住那个赌了四十年终于赌赢、然后开始害怕自己赌赢的东西的老人。

**这门学科不是从算力里长出来的，是从人身上长出来的**。而人是会死的，会被误解的，会在四十年里一直错，也会在所有人都说他错的时候还是对的。

## —— 五 ——

最后回到熵。

阿西莫夫在 1956 年挑的那个问题——如何逆转熵增——不是随手选的。热力学第二定律说，一个孤立系统的无序程度只增不减——它可以停在原地，但绝不会自己往回走。杯子会碎，房间会乱，恒星会烧完，宇宙会冷掉。这是已知的物理定律里最不留情面的一条：**它规定了时间只能往一个方向走**。

而在阿西莫夫写下那个故事的八年前，1948 年，一个叫克劳德 · 香农（Claude Shannon, 1916 – 2001）的人给“信息”下了一个定义。这个人二十一岁就把布尔代数接进了继电器电路，日常爱好是在贝尔实验室的走廊里骑独轮车。他算出信息量的公式之后发现，那个公式的形状和热力学里熵的公式，一模一样。

据说他为此问过冯 · 诺伊曼（John von Neumann, 1903 – 1957）该给这个量起什么名字——那位是当时什么都插得上手、而且基本都插对了的人。冯 · 诺伊曼建议他就叫熵——一半因为形式相同，一半因为（据这个流传甚广的说法）没人真正明白熵是什么，这样他在争论中永远占优势。这个段子的真实性存疑，第 7 章再算这笔账。

但名字留下来了。**从那以后，信息和无序就是同一枚硬币的两面**。而智能——不管我们最后怎么定义它——所做的事情，本质上是在一个不断变乱的世界里，**建立并维持秩序**：从噪声里找出规律，从混乱里认出模式，从“数据不足”一路走到“我知道了”。

所以阿西莫夫故事的最后一句，其实不是宗教。它是一个物理学上的宣言：**一台把全宇宙的信息都吃进去的机器，最终获得了对抗熵的能力**。

我们离那台机器还有多远，我不知道，这本书也不打算猜。

但这条路的起点，我知道在哪。它在三千年前一个中国工匠的手上——那个人做了一个假人，让它唱歌跳舞，然后被天子当场要求把它拆开。

我们从那里开始。

# 机器会思考吗

图灵把一个吵了三百年的哲学问题，改写成一场可以打赌的游戏；并主张不要造成人，要造孩子。

## 一

1950 年，哲学期刊《心》收到一篇论文。

论文的第一句话是：

**我建议考虑这个问题——“机器能思考吗？”**

对一份哲学期刊来说，这是个完全正常的开头。三百年来大家一直在吵这个（第 2 章那三位吵得最凶）。

然后作者用不到一页的篇幅，宣布这个问题**不值得回答**。

他说：要回答它，你得先定义“机器”，再定义“思考”。而定义“思考”的通常办法是去看这个词平时怎么用——但那样一来，结论就取决于日常语言的习惯，而不取决于事实。

**所以他不定义。他换题。**

作者叫艾伦·图灵。第 5 章他出场过一次，那时候二十四岁，在纸上造了一台机器，顺手拆掉了希尔伯特的梦。

现在他三十八岁。中间发生了一场战争。

（这篇论文的门牌号，本书此后要反复引用，在这里记全：《计算机器与智能》，载《心》第 59 卷第 236 期，1950 年 10 月，第 433 至 460 页。一篇后来被整个学科当作起点的文章，是从一份哲学季刊上出来的，而不是从任何一份工程或数学刊物上。）

---

他换成的那道题，是这样的。

先看一个当时的客厅游戏，叫“模仿游戏”。三个人：一个男人（A）、一个女人（B）、一个提问者（C）。C 待在另一间屋里，只能通过打字条跟 A 和 B 交流。C 的任务是判断哪个是男的、哪个是女的。A 的任务是**骗过** C；B 的任务是帮助 C。

现在图灵说：**把 A 换成一台机器。**

如果换了机器之后，C 判断错误的频率跟原来（两个人玩的时候）差不多，那我们该说什么呢？

这就是后来所有人都叫它“图灵测试”的那个东西。

图灵这一手漂亮在哪里？

**他没有回答“机器能不能思考”。** 他把这个问题替换成了一个可以做实验、可以下注、可以打分的问题：“机器能不能在自由对话中被识别出来。”

而这个替换的合法性，来自一个他没有明说但整篇文章都靠着的假设：

**我们判断别人在思考，用的本来就是同一个办法。**

你怎么知道你对面那个人在思考？你钻不进他的脑子。你唯一的依据是他的行为——他说的话，他的反应，他答得是否得体。

**所以，如果你愿意根据行为承认一个人在思考，你凭什么不用同一个标准对待机器？** 除非你能说出一个不循环的理由。

**这是本书里最重要的一次论证转向。** 在图灵之前，“机器能否思考”是一个关于本质的问题（机器是什么）；在图灵之后，它成了一个关于表现的问题（机器做了什么）。

而这道题的另一半，前面已经出现过了。

**第 2 章，1637 年，笛卡尔提出了同一个测试。**

他说，如果有一台机器做得像人，我们有两条判据能识破它：它不会把话组织成各种方式来恰当地回应当场对它说的一切；它在没被专门配置过的场合会露馅。

**笛卡尔出了题，然后押注机器永远考不过。图灵接了这道题，押注它会考过。**

同一个测试，三百一十三年，两个相反的赌注。

（而第 1 章那个坐在柜子后面的土耳其人提醒过，这道题还有第三种解法：**作弊**。1836 年爱伦·坡只凭行为就推理出柜子里有人。行为既能证明思考，也能暴露作假——**这两件事同时成立，是这道题至今没有关闭的根本原因。**）

---

图灵还在这篇论文里下了一个非常具体的赌注。

他预测：大约五十年之后，人们将能给存储容量约为 $10^9$ 的计算机编程，让它把模仿游戏玩得足够好，以至于一个普通的提问者在五分钟的问答之后，做出正确判断的概率不超过百分之七十。

这个赌注下得很克制：

- **五分钟**，不是无限时长；
- **普通提问者**，不是专家；
- **七成**说的是提问者**猜对**的概率上限，不是机器能骗过七成人。

顺带把一个常被追问的细节交代掉。图灵那句话里的 $10^9$ **后面没有跟单位**——他写的就是“存储容量约为 $10^9$ ”，句子到此为止。单位要到论文别处才补得出来：他在文中是拿二进制位来计量存储的，还顺手报过曼彻斯特那台机器的存储量是十七万四千三百八十个二进制位。所以通行的读法“约十亿位”是从上下文推出来的，不是那句话本身说的。本书照他的原样写，不替他补单位。

它常被简化成“到 2000 年机器能通过图灵测试”，那是不准确的转述。图灵说的是一个**统计意义上的、短时的、非专家的**门槛。

这个赌注赢了没有？

这件事到第 26 章再算，因为答案很尴尬——它涉及一个 1966 年靠一套模式匹配脚本就骗过很多人的程序（第 11 章），也涉及 2022 年 11 月之后全世界几亿人每天都在做的事。

我先把一句话放在这里：**图灵测试作为一个哲学论证极其有力，作为一个工程指标极其糟糕。** 因为它测的是“像人”，而不是“聪明”——而“像人”这件事，可以靠人的轻信来完成一半。

---

## 二

论文的后半部分，图灵做了一件很少有人在提出一个大胆主张时会做的事：

**他把所有他能想到的反对意见列出来，一条一条回答。**

九条。下面一条条过，因为这九条**至今还是全部争论的目录**——七十六年了，没有人提出过第十条真正新的反对意见。

先把这份目录按图灵自己的标题列全，本书此后一律用这套译名：一、神学的反驳；二、“把头埋进沙子里”的反驳；三、数学的反驳；四、来自意识的论证；五、来自各种能力缺失的论证；六、洛夫莱斯夫人的反驳；七、来自神经系统连续性的论证；八、来自行为无法形式化的论证；九、来自超感官知觉的论证。

**第一条，神学的反驳。** 思考是不朽灵魂的功能，上帝只把灵魂赋予人。图灵的回答带着他特有的一点顽皮：这种论证限制了上帝的全能——如果上帝愿意，他为什么不能把灵魂给一台机器？

**第二条，“鸵鸟式”的反驳**（他自己起的名字）：后果太可怕了，所以我们希望它不可能。图灵说这不是论证，只是安慰。**这一条今天仍然在场，只是换了打扮**：第 27 章会看到一些争论的真实驱动力

不是证据，是不希望。

**第三条，数学的反驳。** 这一条最技术：哥德尔定理表明形式系统有它证不出的东西，而机器是形式系统，所以机器有做不到的事，所以机器不如人。

图灵的回答只有一句话的重量：**你凭什么认为人没有相应的局限？** 我们没有任何理由相信人类的心智不受某种类似的约束。**这只是把机器的已知限制，和人的未知限制拿来比。**

（这条反驳后来被卢卡斯和彭罗斯用更精致的形式重提，争论至今没停。图灵那句话仍然是最锋利的一刀。）

**第四条，来自意识的论证。** 这一条是真难题。图灵在这里点名引了一段话，出处是**神经外科医生杰弗逊（Geoffrey Jefferson, 1886 – 1961）1949 年 6 月 9 日在英国皇家外科医师学会所作的利斯特讲座，题目叫《机械人的心智》**（同月 25 日刊于《英国医学杂志》）。杰弗逊那段话的意思是：

> 除非一台机器是因为感受到了思想与情感才写出十四行诗或谱出协奏曲，而不是靠符号的偶然落定，我们才能同意机器等于大脑——而且不只是写出来，**它还得知道自己写了。**

请留意最后那半句，它常在转述中被砍掉，而它才是这条反驳真正的牙齿：杰弗逊要的不是“作品够好”，是**作者知道自己在写**。这半句把标准从产品挪到了自我意识上。

图灵的回答是这一整篇论文里最狠的一段。他说：按这个标准，唯一能确认某个东西在思考的办法，是**成为**那个东西。而如果我们严格执行这个标准，你也没办法确认**任何别人**在思考——你只能确认你自己。这条路的终点是唯我论。

**而我们在日常生活里并不这么做。我们礼貌地假定别人也在思考。**

图灵没有说意识不存在，也没有说它不重要。**他说的是：意识问题不必在回答“机器能否思考”之前被解决。** 我们对彼此就是这么办的。

第 27、28 章那些争论——模型有没有理解、有没有内部表征、“涌现”是真的还是我们的错觉——每一场的底下都躺着这一条。

**第五条，各种“能力缺失”的反驳。** 机器永远不能做 X：不能友善、不能有幽默感、不能爱、不能吃草莓加奶油、不能犯错、不能创新、不能有多样的行为。图灵一条条处理，其中他专门讨论了“机器不会犯错”这一点——他指出，一台故意偶尔算错的机器，反而更难被识破。

七十多年后，第五时代那些模型最像人的一点，恰恰是它们会自信地说错话。

**第六条，洛夫莱斯夫人的反驳。**

图灵直接用她的名字命名了这一条。

第 4 章读过她那两句话：分析机绝不自命能首创任何东西；它能做的，是我们知道如何命令它去做的事。

图灵的回答分两层。

第一层他挑了个刺：机器从来不能让我们吃惊吗？他说这不对，而且他用的是第一人称，语气近乎抱怨——**“机器让我吃惊的频率非常高。”**

（这一句在 1950 年只是一句实话。到了第 27 章，它会变成整个领域最要紧的一句话。）

第二层更深：他说，那种“机器只能做我们让它做的事”的印象，来源于一个隐含的假定——**只要一个事实摆在我们面前，它的全部后果就同时出现在我们心里。** 而这个假定是错的。前提蕴含着结论，但人不可能一眼看尽所有蕴含。

莱布尼茨想让“算一算”结束争论（第 3 章）；图灵在这里指出：**算出来的东西，可以超出下指令的人的理解范围。** 同一个动作，一个人当它是终点，一个人看出它是缺口。

**第七条到第九条**分别是：神经系统是连续的而机器是离散的（他回答：离散系统可以逼近连续系统到人无法分辨）；人的行为无法被规则完全刻画（他回答：区分“行为规则”和“行为的自然律”）；以及**超感官知觉**——图灵居然认真对待了通灵这一条，因为当时有些统计实验声称支持它。

最后这一条今天读起来很滑稽，但它其实是这篇论文最令人尊敬的地方之一：他把当时看起来有实验证据的东西，哪怕再古怪，也放进来处理了一遍，而不是装作它不存在。

---

## 三

论文里还有一部分，长期被“图灵测试”的名气盖住了。**而这一部分，才是他真正的技术主张。**

图灵问：假设要做出一台能通过这个测试的机器，该怎么做？

**他的答案是：不要去编程一个成人的心智。**

他的论证很朴素：成人的心智是**教育**加上**经历**的产物。要直接写出一个成人心智的程序，等于要把一个人一生的学习成果全部显式地写下来——不可能。

**那就换个目标：编程一个“孩子”，然后教它。**

他管这个叫**儿童机器**。他甚至给出了一个粗略的分工估算：先做一个结构简单、有学习能力的初始系统，剩下的工作交给教育过程。

而“教”的办法，他也说了。

他提出用**奖励和惩罚**来训练机器：让某些事件强化机器当前的行为倾向，让另一些事件抑制它。他明确地把这套办法类比成教小孩。

**这一段的年份是** 1950 年。

- 第 18 章那条从动物心理学流到多巴胺的地下河——强化学习——它的核心机制就是这个：用奖励信号塑造行为倾向。
- 第 26 章那个让模型学会好好说话的办法——用人的偏好训练一个奖励模型，再用它去优化模型的行为——**在结构上就是图灵这一段的工业化版本**。

**从“我们不要编程一个成人，我们要教一个孩子”，到 2022 年那个让全世界排队去聊天的产品，是同一条线。** 中间隔了七十二年，和一件图灵不可能预见的事：那个“孩子”要先把整个互联网读一遍（第 23 章）。

而这些想法，图灵在两年前就已经写下来了，写得比 1950 年那篇更技术、也更超前。

1948 年，他在国家物理实验室写了一份内部报告，题目大意是《智能机器》。

这份报告里，他提出了一个概念叫“**无组织的机器**”。

他的出发点是一个观察：**婴儿的大脑皮层，看起来相当“无组织”。** 它不是一张精心设计的电路图，它更像一堆随机连着的东西，而它后来变得有用，靠的是经验。

于是他定义了这样一种机器：**一堆单元，之间的连接是随机的**——不是设计出来的，是随便接的。

他给了两类。第一类他叫 A 型：单元之间随机连接，每个单元做一个简单的逻辑运算。第二类他叫 B 型——在 A 型的基础上，**每一条连接上加了一个可以被“开”和“关”的开关**，而这些开关的状态可以被外部的训练过程改变。

**请把这句话读慢一点：一个随机连接的网络，通过改变连接的通断来学会做事。**

这是**神经网络**。1948 年。

而图灵在同一份报告里说了要怎么用它：**靠外部的“干预”去拨这些开关**，让有用的连接留下、没用的关掉。

报告里还有第三种机器，他叫它 P 型。到这一步，干预被收窄成了两个输入——一个叫“快乐”，一个叫“痛苦”——因为人教小孩靠的就是奖励和惩罚。

A 型、B 型、P 型是同一份报告里递进的三步：随机接线的网络；接线可以被改的网络；以及可以被奖惩调教的机器。这本书后面所有关于“训练”的事，骨架都在这三步里。

所以在感知机（第 10 章）之前十年，在反向传播（第 13 章）之前二十六年，图灵已经写下了：随机初始化的网络 + 训练信号 = 学习。

这份报告他的雇主没有让它发表。压下它的人叫查尔斯·高尔顿·达尔文（Charles Galton Darwin），当时的国家物理实验室主任，也是那位达尔文的孙子。他给这份报告的评语是：一篇小学生作文。

于是它进了抽屉。它第一次被印出来是 1968 年——比图灵之死晚了十四年。

那时候图灵已经死了十四年，而神经网络正要被一本书判死刑（第 10 章）。

（这句评语值得在这本书里留个记号。达尔文不是庸人，他是个正经物理学家、皇家学会会士。他看不出这份报告的价值，不是因为他蠢，是因为 1948 年这份报告里的东西没有任何东西可以对照——没有同行、没有文献、没有一个已经存在的领域可以把它挂进去。评审制度对“看起来不像任何已有东西”的工作，天然是失灵的。这是母题二在制度层面的形状。）

这是本书母题二最刺眼的一个例子：一个正确的想法，被压在抽屉里，一直压过了它本可以拯救的那场灾难。

---

顺便，图灵还写了最早的下棋程序之一。

1948 年夏末，他和剑桥国王学院时代的老朋友、经济学家戴维·钱珀瑙恩（David Champernowne, 1912 – 2000）做了一个叫 Turochamp 的东西——名字是两个姓拼起来的。它的原理今天的每一个棋类程序都还在用：枚举所有可能的走法和对手的应对，再往下看几步它认为值得看的，给每个局面打一个分，选分数最高的那一步。

（“最早”这个词在这里要按规矩用。香农 1950 年那篇讲机器下棋的论文比它晚两年，但那是第一篇把这件事讲清楚的公开文献；而第一个真正在机器上跑起来的下棋程序，是 1951 年曼彻斯特的迪特里希·普林茨写的，还是从 Turochamp 得的灵感。Turochamp 早，但它当时跑不起来——这三件事各占一个“第一”，谁也不必让给谁。）

问题是那时候没有一台能用的机器来运行它。

于是图灵自己当那台机器。

他拿着纸和笔，一步一步按照程序的规则去算，每走一步要花半小时以上。他就这样和人下完了一整局。

这局棋的细节现在可以写死了：时间是 1952 年夏天，对手是计算机科学家阿利克·格伦尼（Alick Glennie）——就是后来写出 Autocode、常被算作世界上第一个编译器的那个人。棋下了二十

**九个回合，Turochamp 认输。** 认输的直接原因是它的后被牵制住，保不住了。

**人类第一次和“计算机”下棋，那台计算机是一个人在用手模拟一个程序，而且它输了。**

第 5 章那台图灵机的定义，就是从“一个人在纸上做计算”抽象出来的。而这一次，他反过来用自己去执行一个程序。

**这个人一生都在这两个方向之间来回走。**

---

## —— 四 ——

现在讲这个人。因为前面三节讲的是他的思想，而他的处境是另一回事。

1939 年 9 月，战争爆发。图灵去了一个地方，叫**布莱切利园**——伦敦西北方向的一处庄园，英国的密码破译中心。

他在那里做的事，是本书之外的另一个故事，这里只交代与本书相关的部分：他主持第八棚屋，领导破译德国海军 Enigma 通信的工作，并设计了一种叫“炸弹机”的电机装置——它不是把所有密钥都试一遍，而是从一段猜出来的明文出发，把导出矛盾的转轮设置成批地划掉，剩下的才交给人看。这台机器随后被主持第六棚屋的戈登 · 韦尔什曼改进了一步：他加了一块“对角板”，利用接线板两端互为对方的性质，让每一次矛盾能牵连出更多矛盾，可划掉的设置因此大幅增加。

这项工作的军事价值极大，具体缩短了多少战争没有确切结论，但没有人怀疑它救了很多人的命。

**这项工作在战后几十年里是绝密。**

所以 1950 年那篇论文的读者不知道，写这篇文章的人不只是一个搞逻辑的剑桥数学家。**他是当时世界上极少数真正大规模地、成功地用机器代替人类判断的人。**

他不是在幻想。他见过。

**请记住布莱切利园这个地名。** 第 31 章，二十八个国家和欧盟的代表会在同一片园子里坐下来，签一份关于人工智能风险的宣言。

---

1952 年 1 月，图灵家里遭了窃。他报了警。

警方在调查过程中了解到，他和一个年轻男子有性关系。在当时的英国，这构成犯罪——“严重猥亵罪”。

**他被起诉的原因，是他报了警。**

图灵没有否认。据记载，他给警方的陈述又长又坦白，像是不觉得这里面有什么可羞耻的。

他被定罪。可选的判决有两种：入狱，或者接受“治疗”——注射雌激素以降低性欲，为期一年。

**他选了后者。** 因为入狱意味着不能继续工作。

后果包括身体上的变化，也包括更实际的一条：他失去了安全许可，不能再接触政府的机密工作。**那个在战争中破译了 Enigma 的人，从此被自己的国家列为安全风险。**

---

而就在这两年里，他在做一件看上去跟机器智能毫无关系的事——那件事今天读起来，是这本书最后一个时代的预告。

1952 年 8 月 14 日，图灵发表了一篇论文，题目是《形态发生的化学基础》。

**这是他一生唯一一篇生物学论文，也是他最后一篇重要论文。**

他要回答的问题是：一个受精卵是一团几乎均匀的东西。斑马身上的条纹、豹子身上的斑点、花朵的排列——**这些图案是从哪里来的？**

当时通行的想法是：一定有某种预先存在的“蓝图”，某种在更早的阶段就已经决定好的结构，图案只是把它显影出来。

**图灵证明了：不需要蓝图，图案也能自己出来。**

他的模型只要两种会互相反应的化学物质，它们各自还会扩散。他做的是：写下这个系统的方程，然后分析在什么条件下，**一个完全均匀的初始状态会自己失稳。**

结论是：只要两种物质的扩散速度差得够多，那么一个均匀的状态遇到极小的随机扰动，**就会自发地长出稳定的、周期性的空间图案。**

**斑点和条纹不需要被设计。它们是简单的局部规则在整个空间上跑出来的结果。**

（这类图案今天叫“图灵斑图”。方程一旦手算不动，他就把它搬到曼彻斯特那台 Ferranti Mark I 上去跑——**他大概是最早用计算机做生物学模拟的人之一。**后来的实验化学和发育生物学确实在真实系统里找到了这种机制的证据，这篇论文被认为是二十世纪理论生物学最重要的论文之一。）

**为什么我要在一本人工智能史里花这么多篇幅讲斑马的条纹？**

因为这篇论文和图灵别的工作是**同一个念头的两面。**

- 1936 年，他证明：一台只会“读一格、写一格、移一格”的机器，能算出一切可计算的东西（第 5 章）。
- 1948 年，他提出：一堆**随机连接**的单元，靠训练可以变得有用（本章上一节）。
- 1952 年，他证明：两种简单的化学物质，靠扩散和反应，能自己长出复杂的图案。

**三次，同一个主张：复杂的、看起来被设计过的东西，可以从简单的局部规则里自己长出来，不需要设计者。**

**这个主张的名字，是本书第五时代的标题：涌现。**

第 27 章会遇到一场激烈的争论：那些模型的能力，究竟是从规模里自己“长”出来的，还是我们的测量方式造成的错觉。争论的双方会用统计和曲线互相攻击。

而这个问题的形状——**没有蓝图的秩序**——是 1952 年一个正在被自己的国家治疗的人，坐下来用两个反应方程写清楚的。

---

1954 年 6 月 8 日早上，他的管家发现他死在床上。验尸认定的死亡时间是**前一天，6 月 7 日**。他四十一岁。

床头柜上有一个吃了一半的苹果。

法医鉴定死因是氰化物中毒。**验尸官的结论是自杀。**

**接下来这一段，我要非常小心地写。**

流传最广的版本是：图灵在苹果里注入了氰化物，咬了一口。而这个动作被解释为他对《白雪公主》里那颗毒苹果的引用——据认识他的人回忆，他确实对那部动画里女王把苹果浸进毒汁的那一段很着迷。

> 订 正
>
> **毒苹果与《白雪公主》**
>
> **流传的说法**：图灵咬下一颗注了氰化物的苹果，刻意重演《白雪公主》里的那一幕。
>
> **可查的是**：验尸报告里没有《白雪公主》。 这个联想是在传记写作阶段被接上去的——霍奇斯 1983 年那本传记提到它，后来的作者沿用，此后它就长在这个故事上了。而那颗苹果**从来没有被检测过**有没有氰化物。

先说事实层面。近年来，图灵研究者杰克 · 科普兰（Jack Copeland, 1950 – ）系统地质疑了自杀结论。他的理由不是阴谋论，是**证据规格**：

第一，警方从来没有检测那颗苹果里有没有氰化物。从来没有。而图灵有睡前吃苹果的习惯，也常常吃不完。

第二，尸检的表现更像吸入，而不是吞服。

第三，他家里那间小小的备用房间里，有一套用氰化钾做金电镀的装置——他自己在玩这个，用氰化钾溶解黄金，给勺子镀金。这意味着房子里有氰化物蒸气的现实来源。

第四，他在死前没有表现出绝望的迹象。据周围人的记述，他对判决和治疗的态度是带着幽默感在承受的；而且他留下了一份回办公室后要办的事情清单。

基于这些，科普兰认为：以今天的标准，1954 年那份自杀裁定的证据是不充分的；意外的可能性至少同等。

**另一边同样要说清楚：这不是定论。** 图灵的主要传记作者安德鲁 · 霍奇斯不接受这个重估。他为《斯坦福哲学百科全书》撰写的“艾伦 · 图灵”条（2002 年初版，2013 年修订）里，话说得很直：图灵“谈起过自杀，而他的死——死于氰化物中毒——最可能出自他本人之手，且被布置成这样一种样子：让愿意那样相信的人，可以相信这是他沉迷化学实验的结果”。

请注意这句话的结构。霍奇斯并不否认现场看上去像意外——他认为**那种观感本身可能正是刻意留下的**。同一批物证，在科普兰那里是“不足以判定自杀”，在霍奇斯那里是“被安排成这样”。两边争的其实不是同一批事实，是这批事实够不够。

**我在这里不做裁决，因为证据确实不足以裁决。**

但有一件事必须说清楚，因为它关系到历史该怎么讲：

**“毒苹果 + 白雪公主”这个叙事之所以流传，不是因为证据强，而是因为它太完整了。** 它给一个受迫害的天才配上了一个有文学隐喻的死法，让整件事有了形状、有了意义、有了可以流泪的地方。

**而另一种可能要平淡得多，也因此更难受：** 一个刚刚被自己的国家定罪、被注射激素、被剥夺了机密工作资格的人，在自家备用房间里摆弄一套危险的化学装置，然后死了。没有隐喻。

前面几处订正的对象都是技术传闻。**这一处的对象是一个人的死。**

**所以规矩更严：说事实，标明分歧，不替他挑一个更好听的结局。**

---

后来的事，简短记录：

2009 年 9 月 10 日，英国首相戈登 · 布朗代表政府就当年对图灵的处置公开道歉。 2013 年 12 月 24 日，图灵获得王室赦免。 2017 年 1 月 31 日，《警务与犯罪法》获御准生效，为历史上因同类罪名被

定罪的人集体赦免；这一条被非正式地叫做“图灵法”。

**都在他死后五十五年以上。**

关于“赦免”这个词，还有一件事值得说。

赦免的意思是：**你确实犯了法，但我们免除你的刑责。**

不少人——包括图灵的家人和一些研究者——认为这个词用错了。因为图灵没有做错任何事；错的是那条法律。**该被赦免的不是他。**

这个分歧听起来像咬文嚼字，但它其实是这一整节的题眼：

**一个社会在纠正自己的错误时，最难的一步不是道歉，是承认“当时的规则本身是错的”，而不是“当时有几个人执行得太严了”。**

前者要求你重新评价整个制度；后者只需要找几个替罪羊。

这本书写到第 31 章的时候，会有一群人坐在图灵当年破译密码的那片园子里，讨论该给一项新技术定什么规则。到那一章我们会知道，这件事有多难。

---

## —— 五 ——

1950 年那篇论文结束的时候，图灵在最后一段写了一句话，大意是：**我们只能看到前方很短的一段路，但那一段里有很多事等着做。**

他看到的那一段路，实际上包含了此后七十六年的大部分内容：一个基于行为的判据；九条反对意见的完整目录；一个“先造孩子再教它”的技术路线；以及用奖惩来训练机器的具体建议。

**他没能走上这条路。他死的时候，世界上还没有一个叫“人工智能”的领域。**

那个领域的名字，在他死后一年零两个月才被造出来。

1955 年夏末，四个人联名向一家基金会递了一份申请，想在第二年夏天，在新罕布什尔州的一所学院里搞一次为期两个月的研讨。

申请书的标题里有一个此前不存在的词组。**它绕开了控制论，也绕开了图灵。**

而在那个夏天的会议上，真正让所有人吃一惊的，不是那个词。是两个从匹兹堡来的人——他们带来了一个**已经在跑**的程序。

那个程序在做的事，恰好是证明《数学原理》里的定理。

也就是那本书——第 6 章里，一个十二岁的男孩为了躲人钻进图书馆时，从架子上抽下来的那一本。

# 三个人的坚持

一个基金会、一个数据集、一块打游戏的显卡，2012 年一起收网。全书的第一个高潮——以及第 1 章那个柜子的回声。

---

2012 年 10 月，一场图像识别竞赛公布成绩。

这场竞赛叫 ILSVRC，规则是给你一百多万张照片和一千个类别，让你的程序看图说出这是什么。评价指标是“前五错误率”——程序给出五个猜测，五个里没有一个对，才算错。

第二名的成绩是 26.2%。

第一名的成绩是 15.3%。

如果你不熟悉这个领域，这两个数字看上去只是“好一些”。**在当时，它们的差距大到失礼。**

这个竞赛已经办了三年，前两届的冠军成绩分别是 28.2% 和 25.8%。也就是说，全世界最好的实验室拼了两年，把错误率往下压了两个多百分点。各家用的方法路数相近，都是几十年积累下来的成熟做法：先由人设计一套特征提取器，再接一个分类器。大家比的是特征设计得多巧、分类器调得多细。

**而 2012 年这个第一名，一次拿掉了十个百分点。**

它来自多伦多大学，参赛的是三个人：一位六十五岁的教授，和他的两个学生。

他们用的是一个卷积神经网络（第 15 章那个东西），训练它的硬件是两块市售的游戏显卡。

——这一章我们要讲的，是这个成绩单背后的二十年。而故事的开头，要从一件比技术更不体面的事说起：钱。

---

先说这三个人为什么还在。

第 17 章末尾提过，1990 年代中期到 2000 年代中期，做神经网络的人处境不佳：论文难发，经费难申，学生难招。这股气一直吹到 2010 年前后——第 13 章记过两个有名有姓、有年份的例子：2009 年有审稿人告诉本吉奥，讲神经网络的论文在机器学习顶会上没有位置；2010 年杨立昆的一篇稿子被计算机视觉的顶会拒掉。

在这样的二十年里，绝大多数人换了方向。这是完全理性的选择——一个博士生只有四五年，一位助理教授只有六年拿终身教职，没有人有义务替一个被判定失败的方向殉葬。

（这本书后面还会遇到几个坚持了很久的人。每次都请顺带想一想同期换了方向的那一大批：他们是理性的多数，而且按当时手里能拿到的信息，他们没有算错。）

而有三个人没换。

**杰弗里·辛顿**（Geoffrey Hinton, 1947 – ），英国人，1980 年代那篇反向传播论文的作者之一（第 13 章），布尔的后代。他 1987 年离开美国去了加拿大，公开说过原因之一是不愿让自己的研究拿军方的钱。

**杨立昆**（Yann LeCun, 1960 – ），法国人，辛顿的博士后，LeNet 的作者（第 15 章）。1990 年代他手上有一个真在银行里读支票的系统，这大概是那些年里神经网络唯一一个大规模挣钱的应用，而它并没有说服任何人。

**约书亚·本吉奥**（Yoshua Bengio, 1964 – ），出生于巴黎的加拿大人，在蒙特利尔。1994 年那篇论证长期依赖梯度困难的论文有他（第 16 章）——他是最早把这条路的病灶写清楚的人之一，然后他留下来治病。

请把这三个名字放在一起看。他们在前面几章分头出场过，只是从没在同一页上站到过一块儿。三个人分处多伦多、纽约、蒙特利尔，互相认识，互相引用，互相给对方的学生写推荐信。**在一个不看好他们的领域里，他们构成了一个很小的、彼此取暖的圈子。**

---

而让这个圈子能维持下去的，是一笔在今天看来非常小的钱。

2004 年，**加拿大高等研究院**（CIFAR）批准了一个新项目，主题是神经计算与自适应感知，由辛顿主持，本吉奥和杨立昆都是核心成员。这个机构的运作方式很特别：它不建实验室，不买设备，它资助的是“让一群人能定期见面”这件事。

钱的规模大约是一年几十万加元的量级——这个数字在当时的北美科研经费里几乎不值一提。

而它买到的东西是：一年两次，这批全世界最不受欢迎的研究者可以坐在同一个房间里，讲自己那些发不出去的结果。

（把这笔钱的用途翻译成人话：机票、住宿，以及一间可以关上门的会议室。）

辛顿后来多次说，如果没有这笔钱，这个方向在北美可能就断了。

请把这件事记下来，因为它是这本书里关于科研体制最直接的一个证据：当一个方向被主流判定为死路时，能救它的不是更多的经费，是**一小笔不要求它立刻成功的经费**。

这本书后面会讲到一些以亿美元计的投入。在效率上，没有一笔比得上这一笔。

## 二

2006 年，这个小圈子拿出了一个结果，而这个结果的意义跟大多数人以为的不一样。

先说问题。为什么深的网络训不动？

第 16 章讲过病因的一半：反向传播要把误差信号从输出层一路乘回输入层，而每穿过一层就要乘一次。乘上一串小于 1 的数，信号会指数级地衰减；层数一多，最前面几层收到的修正量小到等于没有。

还有另一半：你得给权重一个初始值。当时通行的做法是随机初始化，而对一个深网络来说，随机的起点几乎总是很糟的起点——优化过程会陷在一个平庸的地方出不来。

于是 2006 年之前，实践中的共识是：**三层以上的网络，你训不好**。

辛顿和合作者给出的办法叫**逐层预训练**，思路可以一句话说完：

**别一上来就训整个网络。一层一层来，而且先不看标签**。

具体做法是这样。取第一层，让它做一件不需要标签的事：把输入压缩，然后再尽量还原回去。

我们来算一个能在纸上自己算完的例子。一张手写数字图是 $28 \times 28 = 784$ 个像素。你让第一层把这 784 个数压成比如 500 个数，再让另一半网络从这 500 个数重建出原来那 784 个像素，训练目标就是“重建得像”。

注意这里没有用到任何标签——你不需要知道这张图是不是“7”，你只需要它自己。

训好之后，把这 500 个数当作新的输入，接着训第二层：500 压成 250，再还原。然后第三层，250 压成 30。

一层一层堆上去。每一层都只干一件很简单的事，所以每一层都训得动。

堆完之后，你才把整个网络接上标签，用反向传播做最后的微调。

这时候的起点已经不是随机的了。前面那些层已经从数据本身学到了一些结构——边、笔画、局部形状——微调要做的只是把这些现成的零件组织起来。

同年 7 月，辛顿与萨拉赫丁诺夫在《科学》上发表了一篇论文，展示这套办法能把图像压到 30 个数再还原，效果明显好过统计学里用了几十年的标准降维方法。

这篇论文在当时最大的作用，不是它提供的技巧。

说实话，逐层预训练这个技巧本身，在此后五六年内基本被废弃了。后来的人发现，只要初始化方式选对、激活函数换掉、数据足够多，你根本不需要预训练，直接训就行。

（一个技巧最体面的下场，是被它自己撬开的那扇门淘汰掉。逐层预训练拿到了这个下场。）

它真正的作用是政治性的：**它让“深网络训不动”这句话不再成立**。

一件在原理上被认为做不到的事，被做到了一次。这就够了。从 2006 年起，陆续有人回到这个方向；到 2010 年前后，这个圈子已经不只三个人的规模。

---

而在这段时间里，他们做了一件更聪明的事：换了个名字。

“神经网络”这个词在 2006 年已经烧掉了。它在评审人眼里等于“1980 年代那批没做成的东西”，一篇论文摘要里出现这个词，基本等于自减两分。

于是这批人开始用另一个说法：**深度学习**。

技术上，这个词没有指涉任何新东西。它说的还是多层的神经网络，还是反向传播，还是同一批人在做同一件事。

经费上，它改变了很多。

一个新词能让评审人放下成见，让学生觉得自己进的不是一个坟场，让新闻能报道一件“新”事。这是本书母题三（命名的力量）迄今为止最赤裸的一次演示——第 9 章麦卡锡造“人工智能”这个词，一部分动机是不想在维纳的招牌下工作；而这一次，是为了不在自己的旧招牌下工作。

这本书里有一条规律，到这里可以正式写下来了：一个方向要复活，光有新结果不够，**它还需要一个新名字，好让人们在改变立场时不必承认自己错过**。

---

## 三

2007 年，普林斯顿的一位年轻助理教授在做一个所有人都劝她别做的项目。

她叫**李飞飞**（Fei-Fei Li, 1976 – ）。她十五岁随父母从成都移民美国，一家人在新泽西开过一间干洗店；她一边念普林斯顿一边照看店里的生意。

她当时的判断，跟整个领域的方向是拧着的。

那些年计算机视觉的主流做法是这样：拿一个几千张图、二十来个类别的数据集，然后大家比赛谁的算法在上面表现更好。所有的聪明才智都投在算法上。

而李飞飞认为，瓶颈不在算法，在数据。

她的论证是从小孩来的：一个三岁小孩能认出猫，不是因为他脑子里有一个更精妙的算法，是因为他在三年里睁着眼睛看了几亿帧真实世界的画面。而当时喂给算法的，是几千张。

**“我们一直在给一个孩子看二十张图，然后责怪他学不会。”**

所以她要造一个大到荒唐的数据集。

规模目标是：上千万张图片，覆盖两万多个类别。比当时最大的数据集大三个数量级。

同事们的反应是礼貌的怀疑。有人告诉她这不是研究，是苦力；有人提醒她这种项目拿不到经费；也有人指出，就算你造出来了，也没有算法能吃得下这么多数据——最后这条在 2007 年是对的。

---

造法分两步，两步都很妙。

第一步：类别从哪来？

她没有自己拟清单，而是借了同在普林斯顿的一份现成东西——**WordNet**，一个由认知心理学家乔治·米勒（George Miller, 1920 – 2012）主持建立的英语词汇网络，把几万个名词按“是一种”的关系组织成了一棵树。

**于是“世界上有哪些东西”这个哲学问题，被换成了“抄一份词表”。**

第二步，也是真正的难题：谁来标？

上千万张图，每一张都要有人看一眼、判断它是不是某个类别。李飞飞算过，靠普林斯顿的学生来标，这件事要做十九年。

（十九年。从 2007 年起算，这个数据集大约会在二〇二〇年代中期交付——比它实际掀翻整个学科的那一年，晚了十几年。）

解决办法是亚马逊在 2005 年上线的一项服务：把一件极小的任务拆给全世界的散工，每完成一件付几美分。

前后大约两年半的时间里，来自一百六十七个国家的近五万名标注者，通过这项服务给 ImageNet 贴上了标签。

而这项服务的名字，叫**“土耳其机器人”**（Mechanical Turk）。

我们在第 1 章见过这个名字。它就是以那个东西命名的。

1770 年，坎佩伦推着一个会下棋的柜子走遍欧洲，柜子里藏着一个人。两百三十五年后，亚马逊把这件事做成了一项云服务，用了同一个名字，而且完全没有隐瞒——公司自己给这项服务的介绍词是“人造的人工智能”。

**你雇一个机器接口，接口后面是人。**

这本书讲了十九章的那个母题，在这里绕回了原点，而且是以最直白的方式：这个星球上最重要的一个人工智能数据集，它的智能来源是几万个隐身在软件后面的真人，**每人每张图挣几美分**。

后面所有那些“机器自己学会了”的故事，地基是这一层人。

这条线在第 30、31 章还会回来。那时候它就不好笑了。

---

2009 年，ImageNet 的论文在一场计算机视觉会议上发表。它被安排在会场角落的一块展板上，不是口头报告。

（一篇后来重画了整个学科版图的论文，当年在会场分到的是墙上的一块板子。这不算冤枉：在 2009 年，它确实还什么都没证明。）

2010 年，李飞飞和合作者用它办起了一年一度的比赛，就是本章开头那个 ILSVRC。比赛用的是一个精简版：一千个类别，一百二十多万张训练图。

头两届的结果，看起来是在证明她的怀疑者是对的。

2010 年冠军错误率 28.2%，2011 年 25.8%。用的都是传统方法，进步缓慢。数据变多了，成绩并没有相应地变好。

缺的那一样东西，在另一个行业里。

---

## —— 四 ——

把人工智能从冬天里拖出来的那块硬件，最初的设计任务是让爆炸场面更流畅。

图形处理器——显卡——是为电子游戏造的。它的构造和中央处理器是两种哲学：CPU 有几个非常聪明的核心，擅长一件接一件地处理复杂任务；**GPU 有几百上千个很笨的核心，只擅长一件事——同时对一大堆数做同一种简单运算**。

而屏幕上的每一个像素，恰好都需要做同样的一点算术。

**问题在于，神经网络也是。**

一个网络的一层在做什么？把一大堆输入乘上一大堆权重然后加起来——成千上万次同样的乘加，彼此独立，可以同时算。

这两件事在数学上是同一件事，而这个巧合在很多年里没人利用。

（显卡的设计任务书上从来没有“训练神经网络”这一条。它最后被拉来干这件事，靠的是它笨得恰到好处。）

2007 年，英伟达发布了 CUDA，让程序员能用比较正常的方式给显卡写通用程序，而不必伪装成在画三角形。

2009 年，斯坦福的拉伊纳、马达万与吴恩达（Andrew Ng, 1976 – ）发表了一篇论文，把深度网络的训练搬到显卡上。他们在摘要里给的数字是：跟一块双核 CPU 比，最高快到七十倍——而且模型越大，这个倍数越高。

七十倍意味着什么？论文自己举的例子是：一个四层、一亿个自由参数的网络，原来要学几个星期，现在大约一天就学完。一个本来要等到下个月才知道成不成的想法，第二天早上就知道了。**而研究的速度，本质上就是“你一年能试多少个想法”**。

母题五（算得动了）在这里达到它到目前为止的最高峰。1989 年杨立昆那个卷积网络（第 15 章）和 2012 年这个，在思路上没有本质区别。变的不是想法，是一个想法从提出到验证需要多久。

---

这里必须插一段，否则这一章会变成一个不诚实的故事。

在多伦多那三个人之前，已经有人把卷积网络放到显卡上跑，并且赢了比赛。

在瑞士，施密德胡贝的实验室（第 16 章那位）里，丹 · 西雷桑（Dan Cireşan）和同事从 2010 年起就在做 GPU 上的深度卷积网络。他们 2011 年在一项德国交通标志识别竞赛上拿了第一，成绩超过了人类参赛者的平均水平；同年还赢了中文手写识别的比赛。

这些工作在时间上早于 AlexNet，方法上高度接近。

按本书的规矩（第 13、16 章用过同一条）：优先权要给准，影响力也要说实话。

西雷桑那一组先做出来了，做得很好，赢了几场硬比赛。而 2012 年那场比赛之所以成为分水岭，是因为 ImageNet 的规模和难度是另一个量级——一千个类别、一百多万张自然照片，而不是交通标志或手写字。在一个所有人都盯着的、被公认为“真问题”的赛场上，用十个百分点碾过全场，这件事的说服力无法替代。

**他有优先权，但没有父权。** 这句话在这本书里已经用过几回了。

---

现在说 2012 年那个网络本身。

做出它的是辛顿的两个学生：亚历克斯·克里热夫斯基（Alex Krizhevsky）和伊利亚·苏茨克维（Ilya Sutskever, 1986 – ）。网络后来按第一作者的名字被叫作 **AlexNet**。

它的骨架就是第 15 章那个卷积网络，八层，六千万个参数。训练它用的是两块市售显卡，跑了五六天。（六千万个参数，两块打游戏的卡——这大概是本书里性价比最高的一次硬件采购。）

它比 1989 年那个版本多的东西，主要是三样，每一样都很朴素：

第一，换了激活函数。老网络里每个单元的输出要经过一个 S 形曲线压到 0 和 1 之间。新的做法叫 **ReLU**，规则简单到可笑：负数变成 0，正数原样输出。

为什么这样更好？回到第 16 章那个乘积直觉：S 形曲线在两端非常平，一旦单元的输入偏大或偏小，它的斜率就接近 0，而反向传播每穿一层就要乘一次这个斜率。乘上一串接近 0 的数，信号就没了。而 ReLU 在正半边的斜率恒等于 1——乘多少次都还是 1。

**一个困扰了这个领域二十年的问题，被一个“负数归零”解决掉了一大半。**

第二，**dropout**。训练时每一轮随机让一部分单元“请假”，不参与计算。

这听起来像是自残，而它的道理是：如果某个单元知道自己的隔壁总在，它就会偷懒，只学一半、指望隔壁补另一半。让隔壁随机消失，每个单元就必须学会独立成立的特征。辛顿说过这个想法的一个来源，是银行柜员总在轮岗——而轮岗是为了防止合谋。

第三，**数据增强**。把每张训练图裁剪、平移、左右翻转，一张变成很多张。用最省事的办法，凭空多出一批数据。

这三样加起来，没有一样是深奥的数学。它们都是工程上的小聪明，而正是它们，让一个 1989 年的想法在 2012 年跑赢了整个领域。

---

而这个网络训完之后，人们做了一件事：把它第一层学到的东西画出来看。

第一层有九十六个卷积核，每一个都可以当成一张小图显示。画出来是这样的：大部分是朝着各个方向的明暗条纹——一道亮边挨着一道暗边，方向各不相同；剩下的是一些颜色的斑块。

请回到第 15 章。

1958 年，休伯尔和维泽尔把电极插进一只猫的视觉皮层，玻璃片推进时投出一道直影，某个细胞突然响了——而且换个方向它就哑了。他们发现视觉皮层最前面那一层的细胞，各自只对某一个特定方向的边缘有反应。

没有人告诉 AlexNet 这件事。

它是从一百二十万张照片里，靠反向传播自己长出来的。**它长出来的第一层，和一只猫的视觉皮层第一层，是同一样东西。**

这大概是这本书里最干净的一次印证：面对同一个世界、同一个“从像素里认出东西”的任务，进化花了几亿年得到的解，和梯度下降花了一周得到的解，撞在了一起。

它不能证明网络在“像大脑一样思考”——这一步外推是第 27 章那些争论的常见错误。它能证明的是一件更朴素也更有分量的事：这个任务本身的结构，逼着解往那个方向去。

---

## —— 五 ——

成绩单公布之后，事情发生的速度让人不适应。

2012 年 10 月那场比赛的现场，据在场的人回忆，气氛是分裂的：一部分人立刻意识到自己过去十年的工作刚刚贬值了，另一部分人认为这是个侥幸。

这场争论只持续了几个月。

到 2013 年的同一场比赛，几乎所有参赛队伍都改用了卷积神经网络。到 2014、2015 年，错误率一路掉到个位数。**一个几十年来靠人工设计特征的学科，在大约十八个月里换了全部工具。**

而这一次，那批人手上有一样 1969 年和 1995 年都没有的东西：一个所有人都承认的、公开的、量化的赛场。你不需要说服任何人相信你的哲学，你只需要把成绩贴出来。

这本书前面所有的路线之争都是嘴上的——明斯基对罗森布拉特（第 10 章）、德雷福斯对整个学界（第 11 章）、统计派对联结派（第 17 章）。而 2012 年这一次，争论是被一张成绩单终结的。

---

接下来发生的事，标志着一个时代的性质变了。

2012 年底，辛顿和他的两个学生注册了一家公司。这家公司没有产品，没有收入，没有专利，全部资产是三个人和一篇论文。

然后他们把它拍卖了。

竞价通过邮件进行，参与竞价的包括谷歌、微软、百度，以及一家当时还没什么名气的英国公司 DeepMind。最后谷歌拍下，价格据报道在四千万美元量级。

**三个人，一篇论文，没有产品。**

**这件事在这本书里是一条分界线。** 在此之前的十九章里，这个领域的资源来自军方、来自政府机构、来自大学、来自像 CIFAR 那样的小基金会。从 2013 年起，它主要来自几家市值以千亿计的公司。

后来的走向大致是：辛顿去了谷歌，杨立昆去了 Facebook 组建实验室，本吉奥留在蒙特利尔的大学里。（他至今没有全职去任何一家公司。在这本书后面几章讲到的那些争论里，这件事会显出分量。）

2019 年，三个人共同获得了 2018 年度的图灵奖。这件事和它的后续，留到第 25 章再说。

---

最后，我们把这一章的账算清楚，因为它跟流行的讲法不一样。

流行的讲法是：2012 年，深度学习被发明了出来，然后世界改变了。

这一章的每一节都在反驳这句话。

算法是 1980 年代的（第 13 章），卷积结构是 1980 年代的（第 15 章，而且它的骨架来自 1979 年的福岛邦彦），用来算的硬件是给游戏玩家造的，用来训的数据是几万个散工一张一张贴出来的，而让这批人活到 2012 年的，是加拿大一笔一年几十万加元的经费。

2012 年真正发生的事，不是有人想出了一个新点子。

**是四样早就存在的东西，第一次同时到齐了。**

而这本书剩下的部分，讲的都是这四样东西各自继续变大之后发生的事。到第 24 章你会看到，“把它们变大”最后成了一门有公式可算的学问，而那条公式说的话让很多人不舒服。

---

2012 年之后的四年，这个领域每隔几个月就换一次天花板。

图像、语音、翻译，一个接一个被推倒。到 2015 年，机器在 ImageNet 上的错误率已经低于一位人类标注者亲自做完这套题所留下的成绩。（请注意口径：那个对照数字来自一个人的实测，不是“人类”的平均水平。）

而人类还剩最后一块自留地。

那是一种在东亚下了两千多年的棋。它的合法局面数比可观测宇宙的原子数还多，几十年来它一直是“机器做不到的事”这份清单上最有名的一条。1997 年深蓝赢了卡斯帕罗夫之后，《纽约时报》去问一位懂围棋的天体物理学家，机器什么时候能在围棋上赢人，他的回答是：也许要一百年，也许更久。

2016 年 3 月，首尔。

第 22 章 | 节点 · 2017

# 你只需要注意力

2017 年 6 月，八个人删掉了循环，只留下注意力。全书第二个技术高峰——以及一个标题带来的十年后遗症。

---

2017 年 6 月 12 日，一篇论文挂上了 arXiv。

十五页，八位作者，都在谷歌。

**标题是《你只需要注意力》。**

这个标题在学术论文里算是相当放肆的。它不是“一种基于自注意力的序列转换架构”，也不是“面向机器翻译的并行化模型”。它是一个断言，而且是一个听起来有点找打的断言。

论文的正文比标题谦虚得多。它报告的是：在两个机器翻译数据集上刷新了成绩，而且训练花的算力少了一个数量级。（对一篇要改写整个学科的论文来说，这份自我介绍算是相当克制。）

它没有说这个架构会统一所有的模态。没有说它会成为此后每一个大型语言模型的骨架，没有说它会被用来预测蛋白质结构、生成图像、写代码、下棋。

**它是一篇翻译论文。**

而它是这本书里，唯一一篇我认为必须逐个零件拆开讲的论文。所以这一章我们走得慢一点。

---

先说这八个人，而这一节要用一个特别的写法。

这本书的规矩是一章一到两个主角（写作规范），因为读者一次记不住更多名字。而这一章有八个人，且他们的贡献确实分不出主次——论文脚注里明写着所有作者贡献均等，并且专门交代了一句：署名顺序是随机的。

**在一个署名顺序能决定职业生涯的行业里，这一行小字比论文正文更少见。**

所以这一节按活儿分，不按人分。（八个名字一次记不住是正常的，你不必记。这一节最后一段会告诉你哪三件事必须记住。）

- 阿希什·瓦斯瓦尼（Ashish Vaswani）与诺姆·沙泽尔（Noam Shazeer）主要在架构与模型这一侧。沙泽尔在谷歌资历较深，此前做过大规模语言模型和机器翻译的核心工作。
- 尼基·帕尔马（Niki Parmar）、雅各布·乌兹科雷特（Jakob Uszkoreit）在模型变体与实验设计上。乌兹科雷特就是第 21 章末尾那位——2016 年那篇“没有循环也没有卷积、只有注意力”的作者之一。
- 利翁·琼斯（Llion Jones）、卢卡什·凯泽（Łukasz Kaiser, 1981 – ）、艾丹·戈麦斯（Aidan Gomez）在实现与代码这一侧，其中凯泽是谷歌那套开源框架的主要作者之一。
- 伊利亚·波洛苏欣（Illia Polosukhin）与瓦斯瓦尼一起做出了最早的几版模型。

如果只记三件事：乌兹科雷特带来了“注意力可以单干”这个已经被验证过的念头；沙泽尔带来了把它做大的工程能力；而那个标题，据琼斯自己说，是他起的，灵感来自披头士那首《你所需要的只是爱》。

这个玩笑后来的代价，我们放到第四节说。

---

## 二

现在说这篇论文真正做的那件事，而它只有一句话：

**他们把循环删掉了。**

第 20 章末尾和第 21 章都讲过这堵墙，这里把账算到底，因为这是本书母题五（算得动了）的最高峰。

循环网络的性质是：第 t 个词的状态，依赖第 t−1 个词的状态。于是训练一个三十个词的句子，你必须做三十次串行的计算。第二步不能提前算，因为它要等第一步的结果。

而一块显卡的本事，是同时对几千个数做同样的运算（第 19 章）。你给它三十个必须排队的步骤，它绝大部分算力在空转。（一块能同时算几千个数的显卡，被一个三十词的句子按住，一次只许动一小块。）

**自注意力没有这个依赖。**

每个位置要做的事是：拿自己的查询，去和所有位置的键比一比。而这些比对之间互不依赖——第一个词和第三十个词的比对，跟第五个词和第十二个词的比对，可以同时算。于是整句话的一层，变成了一次大矩阵乘法。

**而大矩阵乘法，正是显卡这辈子唯一擅长的事。**

---

这个差别有多大？论文给的数字很具体。

他们的大模型在英德翻译上拿到当时最好的成绩，训练用了八块显卡、三天半。而此前那些成绩相近的系统，训练开销要高一个数量级以上。

请把这件事和第 19 章那两块打游戏的卡放在一起看。2012 年 AlexNet 的故事是“终于算得动了”。2017 年这一次是另一件事：**不是硬件变强了，是有人把问题改成了硬件擅长的形状**。

这本书里的“算得动了”，到这里出现了第二种含义。第一种是等硬件追上来（第 15 章的卷积网络等了二十三年）。第二种是改造问题去迎合硬件。

而第二种，从此成了这个领域的主流方法论。到第 24 章你会看到，它甚至变成了一条可以写成公式的定律。

---

这里要插一句诚实话，因为它关系到怎么评价这篇论文。

**“并行”这个好处，只对训练成立，不对生成成立**。

训练的时候，整句话是现成的，你可以一次性把所有位置都算了。而当模型真的在写东西的时候，它还是得一个词一个词地吐——因为第十个词要看第九个词是什么，而第九个词是它刚刚才决定的。所以 Transformer 训练是并行的，生成是串行的。

这个不对称在 2017 年无关紧要。到第五时代，当模型要为几亿人实时生成文字时，它变成了整个行业最大的成本项。第 29 章会讲这件事。（被删掉的那个排队，在这里留了一个影子：轮到写字，它又回来了。）

---

## 三

现在拆零件。这一节是全书两个技术高峰之一，请给它一点耐心。

先讲那三个字母：查询、键、值。

打个比方。你在一个图书馆里。

- 你手上有一个问题：“我想找关于火山的东西。”这是**查询**。
- 每本书的书脊上有一个标签：地质学、烹饪、火山学、诗歌。这是**键**。
- 每本书里面的实际内容，是**值**。

做法是：拿你的问题去和每一个标签比一比，得到一个匹配分数；然后按分数高低，把所有书的内容混合起来读。标签写着“火山学”的那本，分数高，你读它读得最多；写着“烹饪”的那本，分数低，你只瞟了一眼。

**自注意力就是这件事，只有一个扭转：每个词同时是提问的人，也是书。**

具体说，句子里的每个词，都从自己的向量里生成三样东西——一个查询、一个键、一个值（各用一组权重矩阵投出来，而这些矩阵是训练出来的）。

然后每个词拿自己的查询，去问遍全句所有词的键。

---

做个能自己在纸上核的例子。

用第 21 章那句话：

> 那只动物没过马路，因为它太累了。

我们盯着“它”这个词，看它会去看谁。为了能手算，把向量压成两维。

假设训练之后，各个词的向量是这样的（这是为讲解构造的示意值）：

- “它”的查询 Q = [2, 0]
- “动物”的键 K = [2, 0.5]
- “马路”的键 K = [0.25, 2]
- “累”的键 K = [0.5, 1]

打分就是做点积——对应位置相乘再相加：

| 被看的词 | 点积计算 | 分数 |
| --- | --- | --- |
| 动物 | $2\times2 + 0\times0.5$ | 4.0 |
| 马路 | $2\times0.25 + 0\times2$ | 0.5 |
| 累 | $2\times0.5 + 0\times1$ | 1.0 |

然后把这三个分数变成加起来等于一的权重（用的函数叫 softmax，作用是放大差距再归一）：

动物 ≈ 92.6%，累 ≈ 4.6%，马路 ≈ 2.8%。

**“它”把九成以上的注意力给了“动物”。**

而这件事没有任何人教过它。训练目标里只有“把下一个词预测对”之类的要求。“它”的查询向量之所以指向 [2, 0] 这个方向，而“动物”的键恰好也在那个方向上，是反向传播一点一点调出来的。

**指代消解——语言学里一个专门的研究方向——在这里成了一次点积的副产品。**

---

现在可以看那个公式了。这是本书为这一章预留的唯一一个公式。

$$\text{Attention}(Q, K, V) = \text{softmax}\!\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

逐项翻译：

- $QK^T$：把每个词的查询和每个词的键两两做点积，得到一张打分表（就是上面那张表，只不过是全句对全句）。
- $\div \sqrt{d_k}$：把分数除以向量维度的平方根。
- softmax：把每一行的分数变成加起来等于一的权重。
- $\times V$：按这些权重，把所有词的值加权求和。

**整个第四时代和第五时代，全部建在这一行上。**

---

那个除以根号 d 的操作值得单独说一句，因为它是个很典型的工程细节。

向量维度越高，点积的结果就越容易变大——几百个数相乘再相加，绝对值自然就上去了。

而 softmax 有个脾气：喂给它的数一大，它就会走极端，把几乎全部权重压给最大的那一个，其余全部趋近于零。权重一旦变成 0 和 1，梯度就没了（第 16、19 章那条老线）——网络学不动了。

除以 $\sqrt{d_k}$，是把分数拉回一个温和的范围。

**一个只有五个字符的修正，防止了整个机制在高维下瘫痪。** 这本书里这样的东西已经出现过好几次了：ReLU 的“负数归零”（第 19 章），残差的那条线（第 20 章）。深度学习的真实历史，有很大一部分是由这种朴素到不像话的小修正推着走的。

---

第二个零件：**多头**。

刚才那套办法有个毛病：每个词最后只拿到一个加权平均，而一次平均只能表达一种关系。“它”这个词可能同时需要知道好几件事：它指代谁、它在句子里做什么成分、它前面那个词是什么。一个平均说不了三件事。

**解法很朴素：做好几套。**

把向量切成若干份（原论文用了八份），每一份配一套自己的查询、键、值矩阵，各自独立地算一遍注意力，最后把结果拼起来。这就是多头注意力，每个“头”可以专注一种关系。

后来的分析确实发现了一些各司其职的头：有的头几乎总是看前一个词，有的头专门盯着句法上的支配关系，有的头盯着罕见的词。

不过这里要收着说。后续研究也发现，很多头是冗余的——训练完之后把其中相当一部分剪掉，性能几乎不掉。**“每个头有一份清晰的工作”是一个好故事，但它只对一部分头成立。**

---

第三个零件：**位置编码**。而它是删掉循环之后必须偿还的第一笔债。

注意力有一个致命的盲点：它看不见顺序。

回头看刚才那套算法——查询和键做点积，归一化，加权求和。这里面没有任何一步用到“谁在前谁在后”。你把句子里的词打乱顺序，算出来的结果只是跟着乱序走，内容一模一样。

**也就是说，对这个机制来说，“狗咬人”和“人咬狗”是同一句话。**

循环网络不需要操心这件事——它是一个词一个词读进去的，顺序天然就在里面。而这正是被删掉的东西。所以顺序必须被人工加回去。

原论文的做法是：给每个位置造一个特定的数值图案，直接加到那个词的向量上。

图案是用不同频率的正弦和余弦波做的。直觉可以用二进制计数器来理解：

`` 位置 0 → 000 位置 1 → 001 位置 2 → 010 位置 3 → 011 位置 4 → 100 ``

看最右边那一位：0、1、0、1、0，每一步翻一次。 中间那一位：0、0、1、1、0，每两步翻一次。 最左边那一位：每四步翻一次。

几个不同“周期”的位叠在一起，就能唯一地标出一个位置。正弦波做的是同一件事，只不过是连续的、平滑的——而平滑很重要，因为它让模型有可能推断出“隔了多远”这种相对关系。（这也是原论文自己给的理由：任何一个位置的图案，都可以由另一个位置的图案经一次固定的线性变换得到，“隔了 $k$ 步”因此变得容易学。二进制只是个直觉扶手，这一条它不覆盖。）

这个设计里有一处，我第一次读的时候觉得很不对劲。

**位置图案是“加”到词向量上的，不是拼接在旁边。**

也就是说，同一批数字里，既装着“这是哪个词”，又装着“它在第几位”。两种完全不同的信息，被摞在了一起。这听起来像是把地址写在信纸的字里行间。

**而它管用。** 后来的人换过很多种位置编码的方案，有些确实更好，但“把位置直接加进去”这个基本姿势保留了下来。

（为什么能行，简单说是因为高维空间足够大：几百上千个维度里，“词义”和“位置”可以占据大致互不干扰的方向。这个解释在第 28 章还会再用一次。）

---

最后两样零件是从上一章借来的，一句话带过。

**残差连接**（第 20 章）：每个子模块的输出，都要加回它自己的输入。于是一层的默认行为是“原样传过去，再加一点修正”。

**层归一化**：每过一层，把数值重新拉回一个稳定的范围，防止训练跑飞。

把这些拼起来，一个 Transformer 层就是：多头自注意力 → 加回输入、归一化 → 一个普通的前馈网络 → 再加回输入、归一化。然后把这样的层堆起来。原论文堆了六层。

请记住“堆起来”这个动作。第 24 章整章都在讲堆到多少层为止。

---

## —— 四 ——

现在说这个架构的三种裁法，因为它直接决定了下一章的分叉。

原论文的模型是**编码器-解码器**结构：一半读源语言，一半写目标语言。这是为翻译定制的。

而人们很快发现，你可以只要其中一半。（一个为翻译定制的东西，它最有影响的用法是被拆成两半分开使用。这一点在 2017 年不会有人预料到。）

**只留编码器。** 这一半的特点是：每个词可以同时看到左边和右边的所有词。它读完整段话，给出一份“理解”。适合的任务是：判断这句话的情感、这两句话是不是矛盾、这个词在这里是什么意思。你要的是理解，不是生成。

**只留解码器。** 这一半有一个限制：每个词只能看到自己左边的词。

为什么要这个限制？因为它的任务是预测下一个词——如果让它看到右边，它就直接看到答案了，训练变成作弊。于是这一半天生只会做一件事：给定前文，猜下一个词。

**而这一件事，就是第五时代的全部。**

“只能看左边”这个限制是怎么做到的？值得说一下，因为这个小动作有一个大得离谱的后果。

回到第三节那张打分表。做法是：在过 softmax 之前，把所有“看向右边”的格子，分数直接改成负无穷。负无穷经过 softmax 之后就是零。于是那些位置拿到的权重严格为 0，信息一点也过不来。

这就叫**掩码**。一个下三角形的遮罩，盖在打分表上。（这个领域后来发明了无数种精巧的机制。而防作弊的办法，始终是一个三角形。）

而它带来的好处，是这套东西后来能吞掉整个互联网的原因。

假设你有一句一千个词的话，你想训练模型“给定前文猜下一个词”。朴素的做法是：把前 1 个词喂进去猜第 2 个，把前 2 个喂进去猜第 3 个……跑一千遍。

**而有了掩码，你只需要跑一遍。**

把整句话一次性喂进去，每个位置在算的时候都自动只看得见自己左边——于是第 1 个位置在猜第 2 个词，第 2 个位置在猜第 3 个词，一千个位置同时在做一千道不同的题，而且互不泄题。

**一次前向计算，一千份训练信号。**

请把这一条记牢，第 24 章那条公式的分母里就是它。这个领域后来之所以能把几万亿个词读完，靠的不是有人买了更多显卡，而是每一块显卡在同一秒里能同时做上千道题。

---

这两条路在 2018 年正式分岔，成了两个名字：

只有编码器的那一支，叫 **BERT**。它一度赢下了几乎所有的理解类任务。

只有解码器的那一支，叫 **GPT**。

在 2018 年，第一支看起来明显更强。

下一章我们讲这两支怎么走的，以及为什么最后是看起来更笨的那一支赢了。

---

现在说那个标题，因为它有后果。

《你只需要注意力》这个标题，据琼斯说来自披头士 1967 年那首《你所需要的只是爱》。它是个玩笑。

**而它取得太成功了。**

此后的十年里，学术界产生了数量惊人的、标题形如“某某就是你所需要的一切”的论文。它们涵盖了卷积、多层感知机、少量数据、更多数据、修剪、注意力的替代品，以及至少一篇论证“注意力并不是你所需要的一切”的论文。

这大概是这篇论文传播最广、也最不幸的一项遗产。

而抛开玩笑，这个标题在技术上还有一个问题：它不准确。这个架构里不只有注意力。它还有前馈层——而按参数量算，前馈层占了大头，后来的研究认为模型学到的很多“知识”就存在那些层里（第 28 章）。它还有残差、层归一化、位置编码，每一样缺了都不行。

说“你只需要注意力”，大致相当于说一座桥“你只需要钢缆”。

但那个标题是对的，在一个更重要的意义上：它准确地指出了**被删掉的是什么**。

循环没了。卷积没了。而它照样成立。

**这才是那一年真正的新闻**。

---

## 五

先说一件容易被后来的叙述抹掉的事：**它不是当场被认出来的**。

2017 年 12 月，这篇论文在当年那场机器学习大会上亮相。它没有拿任何奖项——那一年的几项论文奖，都给了别的工作。

在当时的读法里，它是一篇很好的翻译论文——成绩漂亮，训练便宜，架构干净。至于“这个架构会取代一切”，论文没这么说，读者也没这么想。领域大约花了一年才形成共识。

请把这件事和第 19 章那个细节对照：2009 年 ImageNet 的论文，被安排在会场角落的一块展板上。**这本书里最有影响的两篇论文，在发表当时都没有被特别对待**。

这不是评审人瞎了眼。它说的是一件更朴素的事：一个想法的重要性，取决于后来有多少人拿它去做别的事——而这件事在发表当天，谁也看不见。

---

而“后来有多少人拿它去做别的事”，这一次有一个很具体的推手：代码是公开的。

这八个人做这项工作时用的是一套开源框架，论文一发，实现就在那里，任何人都能下载、跑通、改。

这在这本书里是件新事。

第 10 章罗森布拉特那台感知机是一台具体的机器，在康奈尔的一个房间里，你想验证得亲自去；第 12 章那些专家系统是商业产品，规则库是公司的资产；第 17 章那些统计翻译系统，光是把数据准备好就要几个月。

在这本书的前二十章里，“重复一遍别人的结果”通常意味着几个月的工作，而且经常失败。

**而 2017 年之后，它意味着一个下午。**

这件事对这门学科速度的影响，不比任何一个算法小。一个研究生在自己学校的机器上就能拿现成的实现改一改，试一个新想法，第二周就发出去。这也是为什么第四时代看起来这么快：不完全是因为想法更好了，也因为验证一个想法的成本，掉到了从前的百分之一。

（这条线有它的另一面：等到模型大到要几万块芯片才训得动的时候，“开源代码”就不再等于“任何人都能验证”了。第 31 章会讲这件事。）

---

接下来发生的事，速度上和 2012 年那次很像（第 19 章），性质上完全不同。

2012 年 AlexNet 之后，计算机视觉在十八个月里换了全部工具，而换掉的只是计算机视觉。语言、语音、决策各走各的。

**而 2017 年之后被换掉的，是所有的领域。**

一年之内，Transformer 从翻译扩散到了几乎每一个语言任务。再过两三年，它开始出现在跟语言毫无关系的地方——图像被切成小块当成“词”来处理，蛋白质的氨基酸序列被当成“句子”，音频、视频、下棋的棋谱、机器人的动作序列。第 25 章整章讲这件事，标题叫“万物皆可 Transformer”。

而它之所以可能，是第 21 章末尾那个性质：注意力不挑食。它只要一堆向量，和一个“我现在想找什么”的查询。至于那些向量是从法语句子、从图片方块、还是从氨基酸来的，这个机制根本不问。

第四时代的暗线，到这里可以说清楚了（第 21 章开头提过）：

**这个领域用了六十年，为不同的问题造不同的机器。而 2017 年之后，大家发现只需要一种机器。**

于是竞争的性质变了。

在此之前，赢的办法是想出一个更聪明的结构。卷积赢在它贴合图像的平移不变性（第 15 章），LSTM 赢在它的门控（第 16 章）——每一次进步，都是某个人对某类问题的洞察。

在此之后，结构基本不变了。赢的办法变成了：谁能往同一个结构里灌进更多的数据和更多的算力。

这个转向决定了今天的产业格局。一个想法可以出自任何一个博士生的笔记本；而一次训练要几万块芯片，那是另一类机构才付得起的东西。

第 24 章会把这件事写成一条公式。第 31 章会讲这条公式的政治后果。

---

最后，说说那八个人。

**到 2020 年代中期，八位作者全部离开了谷歌。**

他们大多去创业，做的都是同一个方向的公司：有人做对话模型，有人做企业级的语言模型服务，有人做通用助手，有人转去做生物领域的应用，有人去了别的实验室。其中几家公司的估值，在几年内达到了十位数美元。

这件事本身就是这个时代的一个隐喻。一篇论文改变了一个行业，而写它的八个人，一个都没留在写出它的地方。（严格说，后来有一位被老东家重金请了回去——两年之后，他又走了。）

这不是谷歌的失误，也不是这八个人不忠诚。这是第 19 章那条线的自然结果：从 2013 年谷歌买下三个人和一篇论文开始，这个领域的资源就从大学和公共基金，转移到了少数几家公司手里（第 19、20 章）。

而当一个想法的商业价值以十亿计的时候，它的作者留在一家公司里领工资，就成了不太可能的事。

这本书写到这里，那些为爱好、为好奇、为一个说不清的信念而工作的人——罗森布拉特、皮茨、维纳、辛顿的二十年——基本上讲完了。

**从下一章开始，钱是故事的一部分。**

---

而下一章那件事，本身跟钱还没什么关系。它是一个更朴素的发现，朴素到有点让人不服气。

架构已经有了。接下来人们要问的问题是：**喂给它什么？**

在 2017 年，答案是显然的：你要它做翻译，你就喂它成对的翻译句子；你要它做情感分类，你就喂它标注好情感的句子。每一个任务，配一套自己的标注数据。而标注数据很贵——第 19 章那几万个每张图挣几美分的人，就是干这个的。

然后有人试了一件几乎是偷懒的事：

**先别管任务。让它把能找到的文本全部读一遍，读的时候只做一件事——猜下一个词。读完了，再来学具体任务。**

这个想法看起来不该管用。**它管用得离谱**。

# 尺度定律

「更大就是更好」从直觉变成公式，从公式变成投资决策，从投资决策变成今天的产业结构。以及「参数量追平人脑」这个比喻的订正。

---

2020 年 1 月，一篇论文里有一张图，图上是几条直线。

**横轴是算力，纵轴是模型犯错的程度**——技术上叫损失，你可以粗略理解成“它猜下一个词猜得有多不准”。

两个轴都取了对数。

**而在这张纸上，点连成了一条直线，笔直地往下走，跨越了七个数量级。**

七个数量级的意思是：最小的那次实验和最大的那次，算力差了一千万倍。而这一千万倍的跨度上，那些点没有一个跑偏。

论文的摘要里，这件事是用一句非常克制的话说的：他们研究的这些趋势，其中一些跨越了七个数量级以上。（Kaplan 等，《神经语言模型的尺度定律》，arXiv:2001.08361，2020 年 1 月 23 日。）

---

要理解这张图为什么重要，得先说清楚它排除了什么。

第 23 章末尾提过，2019 年这个领域的普遍直觉是：**快到头了。**

这个直觉有很扎实的历史依据。这本书前面二十三章，几乎每一条上扬的曲线最后都拐了弯。

第 9 章西蒙预言十年内机器成为国际象棋冠军，用了四十年；第 10 章那台感知机被宣传成会走会说会自我复制，然后撞上了一堵墙；第 11 章莱特希尔那份报告，干的就是把曲线外推出去，然后指出它是平的。

**一个领域被这样教育过五六次之后，“它会一直涨下去”这种话是没人敢说的。**

而这张图说的正是这句话。

它不但说会一直涨，它还说了涨多少：给我算力，我告诉你损失会降到多少。

---

做这件事的是一个物理学家。

领头的贾里德·卡普兰（Jared Kaplan）是理论物理出身：斯坦福读物理与数学，哈佛拿物理博士，在斯坦福直线加速器中心做过博士后，研究的是有效场理论、粒子物理、宇宙学、共形场论这一类东西。他在走进人工智能之前的整个职业生涯，都是一个学院里的理论物理学家——2012 年起在约翰斯·霍普金斯大学任教职。2019 年他到 OpenAI 做研究员；两年后，他成了另一家机构的联合创始人之一（那件事属于第 25 章末尾和第五时代）。

这个背景不是花絮——不过接下来这句话是我的解读，不是论文里的说法：

**幂律是物理学家的本能。** 一个物理学家看到一堆数据，第一反应就是取对数、画在纸上、看它是不是直线——因为在物理里，凡是能画成直线的关系，背后通常有一个可以写下来的规律。

这本书里这样的事已经出现过一次了。第 14 章那位霍普菲尔德，也是从物理走进来的，也是把一个别人当成工程问题的东西，换成了一个可以用能量、用相变去看的东西。

而这一次的结果更实用：它把一件靠感觉的事，变成了一件可以做预算的事。

---

先把这条定律讲清楚，因为它比听起来简单，也比听起来残酷。

结论有三条，都朴素得让人不安：

**第一，模型犯错的程度，随着参数量、数据量、算力的增加而平稳下降，形状是幂律。**

**第二，模型长什么样，几乎不重要。** 论文原话是：网络的宽度、深度这一类结构细节，在很大范围内影响甚微。真正决定结果的，就是那三个数。

**第三，也是最要紧的一条：这条曲线在测到的范围里没有拐弯的迹象。**

第三条要加一句诚实的限定，而且是论文自己加的：作者明确讨论过，这些幂律不可能一直延伸下去——把几条趋势线各自往远处外推，它们会在某个算力规模上互相撞到一起，那说明在到达那里之前，某个地方必须发生变化。**他们测到的是一段直线，不是一条无限长的直线。**这个限定后来常常在转述里被丢掉。

---

幂律是什么意思？用最直白的方式说。

在普通的坐标纸上，它是一条越来越平的曲线——前面降得快，后面降得慢，看起来像是要到顶了。

而在两个轴都取对数的纸上，它是一条直线。

这两句话说的是同一件事，而第二种说法更有用，因为直线可以外推。

具体到数字，大意是这样：

**你想让损失再降一小截，请把算力乘以十。**

**再降同样一小截，请再乘以十。**

这听起来像坏消息，而它其实是好消息。

因为“要花十倍”是一个确定的答案。

在 2019 年之前，“我该不该花一亿美元训一个模型”这个问题没法回答——你不知道花完之后会得到什么，可能好一大截，可能什么都没有。在这种不确定性下，没有一个理性的机构会批那笔钱。

而尺度定律干的事情是：让你可以用很小的代价做几十次小实验，把点画在纸上，拟合出那条直线，然后指着直线的远端说——

“花一亿，我们会到这里。”

这句话是可以拿去开董事会的。

（这两个数额是我为了讲清楚而设的示意，不是任何一家机构的实际做法。真实的流程要复杂得多，也远不止拟合一条线。但“先用小实验定出曲线、再据此决定大投入”这个逻辑，是那篇论文最直接的产业后果。）

**这一章真正的主题，不是“模型变大了”。是“变大这件事，变成了一个可以列进预算表的项目”。**

---

而这条定律还有一个更冷的推论，值得单独写一句。

如果性能只取决于参数、数据和算力这三个数，那么“想出一个更聪明的结构”这件事的价值，就被压低了。

第 21 章说过第四时代的暗线：这个领域用六十年为不同问题造不同机器，2017 年之后发现只需要一种。

而 2020 年这条曲线把这句话又推进了一步：连那一种机器要怎么改，都不太重要了。

你把架构改得很巧妙，也许能在曲线上省下两三倍的算力。而别人直接花十倍的钱，就把你的巧妙抹平了。

一个学科的竞争规则，就是这样在两三年里，从“谁更聪明”变成了“谁更有钱”。

这句话听起来很难听，而它是这几年真实发生的事，也是第 31 章那些争论的全部根源。

---

## 二

2020 年 5 月，那条直线被往前推了一大截。

OpenAI 发布了 GPT-3，参数量一千七百五十亿——是两年前那个 GPT 的一千五百倍左右（初代 GPT 是一亿一千七百万，比值约一千四百九十六）。

它读了什么，论文里有一张表，值得抄下来，因为后面“数据不够用”那一节要用到它：

过滤后的通用爬虫语料，四千一百亿个词元；一个从社交网站外链筛出来的网页集合，一百九十亿；两批书，一百二十亿和五百五十亿；维基百科，三十亿。加起来接近五千亿。

而模型实际训练时只吃了三千亿个词元——因为这几批语料不是按体量抽样的：被认为质量高的那些抽得更勤，通用爬虫那一大堆反而在整个训练里连一遍都没读完。

请记住“质量”这两个字在这里第一次变成了一个配比参数。它在这一章后面还会回来。

它写得很好。好到当时很多人第一次读它的输出时，会去检查是不是有人在后台代打。

但真正的意外不是这个。

真正的意外，藏在论文的标题里：**它把这个模型叫作“少样本学习者”**。

---

这件事得慢慢讲，因为它是第五时代的开关。

第 23 章讲过 2018 年那套标准做法：预训练，然后针对每个任务微调。你要它做情感分类，就拿几千条标注数据接着训，改动模型的权重，得到一个情感分类专用的副本。

**而 GPT-3 论文里演示的做法是：一个权重都不改。**

你只是在输入里写几个例子，然后让它接着写。

举个例子。（下面这个例子是我为了讲清楚而编的，不是任何模型的实测输出；论文里用的那个演示任务是另一件事，稍后会说。）

假设我要它做一件谁也没教过它的事：把一个词重复两遍，中间加个逗号。

我在输入框里写：

`` 山 → 山，山 水 → 水，水 云 → ``

然后模型接着写：云，云。

请注意这里发生了什么，以及没有发生什么。

没有发生的事：没有人写过一个“重复加逗号”的函数。没有人准备过训练数据。模型的权重，从头到尾一个都没变过。

发生的事：模型读了两个例子，在这一次前向计算的过程中，推断出了规则，然后把它应用到了第三个输入上。

**这个现象被叫作上下文学习。**

而它当时是解释不了的。

按照 2020 年所有人对神经网络的理解，“学习”这个词专指一件事：用反向传播去改权重（第 13 章）。权重不变，模型就是一个固定的函数——同样的输入进去，同样的输出出来。

而这里，模型表现得像是在几百个词的时间里学会了一件新事。

**没有梯度，没有更新，什么都没改，而它学会了。**

---

更奇怪的是它跟规模的关系。

论文的第一张插图就在讲这件事，用的是一个简单到有点滑稽的任务：给模型一个被随机插入了符号的单词，让它把符号去掉。横轴是给了几个例子，纵轴是做对的比例，每一条线是一个不同大小的模型。

**图上的形状是：模型越大，那条线越陡。**

论文自己的措辞是克制的——“更大的模型，越来越会利用上下文里的信息”。而图上实际长的样子是：最小的那一档模型，你给它再多例子，那条线也抬不起来多少；到了最大的那一档，例子给得越多，做对的比例上得越明显。

换句话说，“能从例子里推断规则”这个能力，不是被设计出来的，也不是给足例子就都有的——**它随着规模一起长出来。**

而这是一件此前没有遇到过的事：一个没有人写进去、也没有人要求过的能力，在系统变大时自己出现了。

这个词后来叫涌现，而围绕它的争论——它到底是真的出现了，还是我们的尺子刻度太粗——是第 27 章整章的内容。

在这里我只写下当时的事实：这个现象是真的，而当时没有人能说清它为什么发生。

（今天也只能说清一部分。）

---

上下文学习还带来了一个实际后果，它改变了普通人和这项技术的关系。

在 2018 年那套做法里，要让模型做一件新事，你需要：标注数据、显卡、会调参的人、几天时间。

在这套做法里，你需要：把要求打进一个输入框。

用文字给机器派活——这件事第 23 章末尾提过一句，当时它是一个不管用的小把戏。

到 2020 年，它成了唯一的接口。

**而它的名字叫提示。**

请把这件事放到第 4 章旁边看。阿达·洛夫莱斯说，机器只能做我们知道如何命令它做的事——**而“如何命令”这件事，在一百七十七年里第一次不再需要编程。**

---

不过这一节到此为止都在说好话，得平衡一下，否则后面两年的事情就讲不通了。

GPT-3 在 2020 年不是一个能给普通人用的东西。

它的问题很具体：

**第一，它编。** 你问它一个它不知道的事实，它不会说不知道，它会用完全一样的语气编一个出来——语法通顺、格式正确、细节丰富、内容是假的。这个毛病后来有了名字（第 27 章），而在 2020 年它就已经很严重。

**第二，它不听话。** 你想让它做一件事，它经常理解成别的事，或者做到一半开始自说自话。因为它的训练目标从来就不是“照做”，是“接着往下写”——如果它读到的文本看起来像一个网页的开头，它就会接着写那个网页，包括页脚和广告。

**第三，它对怎么问极其敏感。** 同一个要求，换个说法，结果可能天差地别。于是 2020 到 2022 年间出现了一门半玄学的手艺，叫“提示工程”——大量的经验、口诀和迷信，本质上是在摸索怎么跟一个不听话的东西说话。

所以 GPT-3 发布之后，世界并没有立刻改变。

它以一个接口的形式开放给开发者，做出了一批有意思的小工具，而普通人基本没听说过它。

从 GPT-3 到那件所有人都知道的事，中间隔了两年半。

**那两年半里发生的，不是模型变得更大——是有人想清楚了怎么让它听话。**第 26 章会讲这件事。

---

## 三

现在要订正的，是过去几年最常见的一个比喻。

> 订正
>
> **“参数量已经追平人脑”**
>
> **流传的说法**：GPT-3 有一千七百五十亿个参数，人脑有大约八百六十亿个神经元——所以模型的规模已经达到甚至超过了人脑。
>
> **可查的是**：**参数在结构上对应的不是神经元，是突触。**按突触总数估计的下限（约一百万亿）算，一千七百五十亿对一百万亿**差着五百多倍**，将近三个数量级。而且这两个数**单位不可比**——用参数去比神经元，等于拿连接数去比节点数。

这个比较有三层问题，一层比一层严重。

**第一层，量级对错了。**

先把那个神经元的数字来源说清楚，因为它常被随口引用。“八百六十亿”出自 2009 年阿泽维多（Suzana Herculano-Houzel 团队）等人的一项测定——他们把整颗脑组织化成匀浆再数细胞核，得到的结果是 861 亿 ± 81 亿个神经元，其中小脑约 690 亿、大脑皮层约 160 亿。在此之前流行了几十年的说法是“一千亿”，而那个数字从来没有一篇可追溯的原始论文。

而参数在结构上对应的不是神经元，是突触——神经元之间的连接。

突触的总数，是一个区间，不是一个数。常见的估计从 $10^{14}$ 到 $10^{15}$ 都有，也就是一百万亿到一千万亿之间；光是新皮层一处，就有过约 164 万亿这个数——它出自一项对五个青年男性脑的立体学测定（Tang 等，2001，《Synapse》），量的是新皮层，不是全脑。而“一百万亿”这个被引用得最多的数字，实际上是“神经元数 × 每个神经元的连接数”这样估出来的量级，很难指着它说这是某次测量的结果。

我在正文里取的是这个区间的下限，而且我要把这件事说破：**取下限对我下面的论证是不利的**——数字取得越大，我要说的那个差距只会更大。所以这里选下限，不是为了把话说得好听。

按下限算：一千七百五十亿对一百万亿，差着五百多倍——将近三个数量级，而不是所谓的追平。用参数去比神经元，等于拿连接数去比节点数。

**第二层，单位不一样。**

一个参数是一个数。而一个生物突触是一个活的化学系统：它有几十种神经递质、有随时间变化的强度、有自己的代谢、会长出来也会消失。它不是一个数，它是一个过程。

第 6 章那两个人早就说清楚了这件事。麦卡洛克和皮茨 1943 年把神经元简化成一个逻辑门，而他们非常清楚自己在做简化——那是一次故意的、有目的的抽象，不是一个关于大脑的主张。

八十年过去，这个抽象越用越顺手，以至于人们忘了它是个抽象。

**第三层，也是最要紧的一层：这个比较即使数字对上了，也不说明任何事情。**

“规模相当”不等于“能力相当”，正如两个东西重量一样不等于它们能做同样的事。

这本书讲了二十四章，反复出现的正是这个错误：**拿一个可测量的东西，去替代一个我们不知道怎么测的东西。**

坎佩伦的柜子会下棋，所以柜子会思考（第 1 章）。ELIZA 的回话像心理医生，所以它懂人（第 11 章）。深蓝算得比人快，所以它超越了人类（第 17 章）。

而这一次的替代品是参数量。

**它比前面几个更有欺骗性，因为它是个数字，而数字看起来很客观。**

---

## —— 四 ——

2022 年 3 月，另一组人指出了一件让所有人有点难堪的事。

DeepMind 的乔丹 · 霍夫曼（Jordan Hoffmann）和同事重做了一遍尺度定律的实验，这次把参数量和数据量分开来变，测得更细。

**他们的结论是：过去两年，大家的模型都造得太大，喂的数据都太少。**

具体说：在算力预算固定的前提下，参数量和训练数据量应该大致同步增长——论文给的规则朴素得像口诀：**模型翻一倍，数据也翻一倍。** 而当时那批大模型的配比严重失衡——参数堆得很猛，数据没跟上。

为了验证，他们做了一次对照，两边花掉的算力一样多：

对照组是同一家机构自己前一年训的模型，两千八百亿参数，读了三千亿个词元。

实验组是七百亿参数——只有对照组的四分之一——但读了一万四千亿个词元。论文摘要里的说法是“四倍的数据”，按词元数直接算是四点七倍。

**结果是小的那个赢了**，而且论文用的词是“全面且显著地”胜过：不只赢了那个两千八百亿的，还赢了同期一千七百五十亿、一千七百八十亿、五千三百亿参数的几个。在一项综合知识测验上，它的平均正确率是 67.5%，比对照组高出七个百分点以上。

这件事的意思是：过去两年里，这个行业花在训练上的钱，有相当一部分是浪费的。同样的钱，换个配比，能得到明显更好的模型。

**而修正方案朴素到近乎无趣：别急着把模型做大，多读点书。**

---

而这条修正带出了一个新问题，它到今天都没有解决。

**书是有限的。**

参数量想加多少加多少——买卡就是了。而“多读点书”这一侧，你要读的是人类写下来的、质量过得去的文本，而这东西的总量是一个有限的数。

按这条修正的配比推下去，前沿模型消耗文本的速度，很快就会撞上一个上限：**互联网上高质量的公开文本，被估计在这个十年之内就会被读完。**

这个估计有出处，也有它的假设，两样都得交代。

它出自维拉洛沃斯（Pablo Villalobos）等人 2022 年秋天的一份推算（arXiv:2211.04325，标题就叫《我们会把数据用完吗？》）。第一版给的判断很激烈：高质量语言数据的存量会很快耗尽，多半在 2026 年之前；低质量语言数据和图像数据要晚得多，分别在 2030 到 2050、2030 到 2060 之间。2024 年他们出了修订版，把口径改得更稳：如果当前的发展趋势延续，模型的训练集规模会在 2026 到 2032 年之间追平可获得的公开人类文本总存量——如果训练时故意超量喂数据，还会更早一点。

而这个推算是怎么做出来的，比结论本身更值得知道：它一边外推训练集规模的历史增长速度，一边估算互联网上可索引文本的总量，然后看这两条线什么时候相交。

这意味着它的两端都是可以被推翻的。增长速度会变——后来确实变了，人们开始更看重每个词元的价值而不是数量；“总存量”这个数取决于你把什么算进“可获得”和“高质量”——这两个词都没有客观定义。

**所以这个日期不该被当成一个到期日来引用。** 它是一次量级估算：**这条路上有一堵墙，而墙不在很远的地方。**

这是一件在这本书里非常新鲜的事。

前面二十四章，这个领域缺过算力（第 15 章那个卷积网络等了二十三年）、缺过想法（两场冬天）、缺过钱（第 19 章那笔几十万加元）。

**它从来没有缺过原料。**

第 19 章李飞飞的困难是标注贵，不是图片少；第 23 章自监督把标注这道坎彻底绕开了，靠的正是“文本要多少有多少”这个假设。

**而现在，这个假设到期了。**

后来的应对办法有好几种——更狠地筛选和清洗、把同一批数据多读几遍、去挖那些还没被数字化的语料、以及让模型生成文本来训练模型。最后这一种听起来像是永动机，而它在某些窄的领域确实管用。

**管用是有条件的，而这个条件说出来一点也不神秘：那个领域里得有一个不靠人就能判对错的东西。**

举两个可以查的例子。

一个是 2022 年那种自举的做法（Zelikman 等，《STaR：用推理自举推理》，arXiv:2203.14465）：让模型自己把解题过程写出来，凡是最后答案错的，那一整段推理就扔掉，只把剩下的那些拿回来训练它自己，如此反复。**请注意这里真正干活的是谁——不是模型，是那道题的标准答案。** 模型负责生产，答案负责筛选。

另一个走得更远（Trinh 等，《不用人类示范求解奥赛几何》，Nature 625:476 – 482，2024）：一个证平面几何题的系统，它的训练数据里一条人写的证明都没有，全是自动合成出来的定理与证明，数以百万计。结果是在三十道奥赛级几何题上做出二十五道——此前最好的方法只做出十道。

而这两个例子恰好也划出了这条路的边界。前者的筛子是标准答案，后者的筛子是一台符号推演引擎——两样东西都只在那种“对错当场可判”的领域里存在。

**你写一封邮件，没有标准答案；你写一段散文，没有推演引擎。**

离开这类领域，你就只剩下模型自己生产、自己认可，而那才是永动机真正该被质疑的地方。代价与边界因此仍是当前争论最多的题目之一。

**这条线的尽头，是一个这本书还回答不了的问题：一个靠模仿人类文本长大的东西，在人类文本用完之后，靠什么继续长大。**

回到那两篇论文，它们之间的关系值得单独看一眼。

**2020 年那篇说“更大就是更好”，2022 年那篇说“你们理解错了什么叫更大”。**

说得更准一点：被推翻的不是那条幂律本身，是它附带的一条建议。

2020 年那篇的结论里有一句：在算力有限的时候，应该优先把参数堆大，数据可以少喂一点。整个行业照着这句话干了两年。

而 2022 年那篇说的是：这句话算错了。幂律没问题，问题出在两个变量该怎么分配那笔预算上。

两篇都是对的，都是靠仔细测量得出来的，而后一篇把前一篇引出的两年投资方向修正了一次。

**这就是这个领域现在的运作方式：它不再靠洞察前进，它靠测量前进。**

而测量是要花钱的。霍夫曼那一组能做这个修正，是因为他们有几百万美元的算力可以专门用来做对照实验。

（顺带说一句命名：这两个模型分别叫地鼠和龙猫——都是啮齿目。第 23 章那档儿童节目的时代过去之后，这一家实验室有一阵子改用啮齿类给模型起名。我原本想说这股风气持续了两年，后来发现举不出足够的例子，所以只说这两个。）

## —— 五 ——

现在说钱，因为这一章绕不开它。

要在 2020 年训一个千亿参数的模型，你需要的东西大致是：几千块专用芯片、连接它们的高速网络、一套能把一个模型切开摊到几千张卡上还不出错的软件、以及几个月的电费。

软件这一侧有很多聪明的活儿——把模型按层切、按张量切、把优化器的状态分散存放，等等；还有一种做法叫专家混合，思路是让模型拥有极多的参数，但每处理一个词只激活其中一小部分，于是参数量可以涨十倍而计算量只涨一点。

这条思路在深度学习里的关键一步，是沙泽尔等人 2017 年 1 月那篇《大得离谱的神经网络：稀疏门控专家混合层》——又是第 22 章那八个人里的同一个人，而且比《注意力就是你所需要的一切》还早几个月。这里只用一句话带过它，是因为它在这一章里只是一件工程装备；它真正的分量要到第五时代才显出来。

硬件这一侧也变了性质，而这件事跟第 19 章正好成对。

2012 年那两块卡，是为电子游戏造的，被人拿来干了别的（第 19 章）。而到这个阶段，主要的几家开始专门为神经网络设计芯片——把通用的部分砍掉，只留下大规模矩阵乘法需要的那些电路，再配上足够宽的内存带宽。

从“借用别的行业的硬件”，到“为这一件事定制硬件”，中间隔了大约五年。

这个“五年”值得说准。第一款这类定制芯片在 2016 年 5 月被公开，而公开时它已经在数据中心里跑了一年多；但那一代只能做推理，不能训练。能用来训练的是下一代，2017 年 5 月发布。所以从 2012 年那两块游戏卡算起，到“这个领域有了专门为它训练模型而造的芯片”，正好是五年。

这是一个行业成熟的标志，也是它门槛升高的原因之一：定制芯片要设计、要流片、要配套软件，而这三样都不是一个实验室做得起的。

---

还有一笔账，这本书前面二十四章从来没有提过：电。

几千块芯片连续跑几个月，耗的电以吉瓦时计，配套的散热要消耗大量的水。

2019 年，斯特鲁贝尔（Emma Strubell）、加内什、麦卡勒姆在计算语言学年会上发了一篇《深度学习在自然语言处理中的能耗与政策考量》，第一次系统地把这笔账摊开算。他们把训练的碳排放折算成一个所有人都有体感的参照物：训一个模型（那个最贵的配置里还包含了自动搜索网络结构的过程），排放量相当于五辆汽车一生的排放。

这个比方在当时引起了不小的震动，也被引用了无数次——而它同时也是一个应该被小心对待的比方：那个最惊人的数字来自一个包含大量重复搜索的特例，不是一次普通训练。

我在这里不打算把这笔账算细，因为公开的数字差异很大，而且芯片的能效每一代都在改善，折算方式本身就是个争论。

但方向是明确的：这本书前面讲的“算得动了”，一直是个褒义词——它意味着一个好想法终于等到了它的时代。

而从这一章起，它同时是一张账单。第 31 章会回到这里。

---

这些工程成就都很漂亮，而它们改变不了那个总数。

**一次前沿训练的成本，在 2020 年是数百万美元的量级；此后几年，这个数字一路往上。**

于是发生了一件在这本书里必须点明的事。

2019 年 3 月，OpenAI 在原来的非营利组织之外，立了一个叫“利润上限”的实体——投资者和员工可以获得回报，但回报有一个上限。四个月后，它接受了微软十亿美元的投资。

这个决定当时引起过不小的争论：一个以“确保人工智能造福全人类”为宗旨成立的机构，为什么需要商业投资？

而它的理由，从这一章的角度看是清楚的：因为那条直线。

如果你相信那条直线，你就知道这件事需要的钱，不是任何一个非营利组织募得到的量级。

---

请把这一节和第 19 章放在一起读，因为这个对比是刺眼的。

2012 年：三个人，一间大学实验室，两块打游戏用的显卡，一个下午能跑完的实验。他们赢了整个领域。

而支撑他们活到那一天的，是加拿大一个基金会一年几十万加元的资助（第 19 章）。

2020 年：一次训练数百万美元，需要一家市值万亿的公司当股东。

**中间隔了八年。**

这不是谁的过错，它是那条直线的直接后果。当“更大就是更好”被证明是可预测的，投入就会一直加到边际收益等于资金成本为止——而这个平衡点，远远高于任何一所大学的年度预算。

这件事有两个后果，都还在展开。

**第一，能做前沿研究的机构，从几百家变成了几家。** 大学仍然在做非常好的工作，但那些工作大多是分析、评估、改进他人已经训好的模型——训练本身，大学退到了很边缘的位置。一个可以拿来看的口径：按斯坦福那份年度人工智能指数报告的统计，2023 年值得记录的机器学习模型里，产业界出了五十一个，学术界出了十五个。

**第二，这个领域最重要的一批实验结果，开始不再公开了。** 训练数据的构成、具体的配比、失败的尝试，都成了商业秘密。这条线的一个标志性节点在 2023 年：那一年最受关注的那份技术报告，开宗明义写着它不会给出模型规模、硬件、算力、数据集构成和训练方法。而第 22 章那个“论文一发实现就在那里、任何人都能下载跑通”的时代，在这里结束了。

**一门学科的验证机制，就这样被成本改写了。**第 31 章会讲这件事的后果。

---

这一章讲的这条曲线，到 2022 年已经被三次确认、一次修正。它成了这个行业的物理定律。

而它同时也是一件让人不安的东西，因为它什么也没解释。

它告诉你损失会降到多少，它不告诉你降下去之后模型会变得会做什么。

GPT-3 那个上下文学习的能力，不在任何人的预测里——尺度定律预测的是那个损失数字，而“损失从 2.0 降到 1.8”跟“它忽然学会了从三个例子里推断规则”之间，没有任何人能写出的联系。

**你花十倍的钱，你知道损失会降多少。**

**你不知道会多出什么本事来。**

**这是这门学科从没遇到过的处境：一件可以精确预算、却无法预测结果的工程。**

打个比方：这就像你能精确算出一颗种子需要多少水多少肥，能预测它长到多高，却说不出它会结什么果子。

而人类历史上的大工程，通常不是这样的。造一座桥，你知道造完是一座桥；送一个人上月球，你知道成了就是有人站在月球上。你花的钱和你想要的东西，是同一个东西的两面。

而这里，你花钱买的是一个数字往下掉，然后你去看掉下来之后送了你什么。

第五时代所有的争论——它到底懂不懂、它安不安全、该不该继续往下做——都建立在这个奇怪的处境上。

---

而接下来发生的事，最能说明这个时代的性质。

同一个架构、同一条曲线、同一套“读大量数据猜下一个”的做法，被人搬去处理图像——把一张图切成小方块，当成词来读。

搬去处理音频、视频、代码、分子、棋谱、机器人的动作。

搬去处理蛋白质——把氨基酸序列当成句子，然后预测这条链会折成什么形状。这个问题困扰了生物学界五十年（这五十年从哪一年算起，第 25 章会交代）。

**每一次，做法都一样：换一种数据，别的什么都不改。**

**每一次，都赢了那个领域几十年积累的专用方法。**

**同一把锤子，砸开了所有的门。**

第 26 章 | 节点 · 2022

# 对齐

让模型说人话的办法，和一个「低调的研究预览」如何在两个月里把研究领域变成公共事件。

## 一

2022 年 11 月 30 日，一个网页上线了。

页面上只有一个输入框。

底下跑的模型不是新的——它是第 24 章那个 2020 年就存在的东西的一个后代，能力上没有质的变化。新的只有两样：一套让它听话的训练办法，和这个输入框。（这两样里，第二样在技术史上通常连一行都分不到。本章第五节要专门为它说几句。）

OpenAI 没打算搞出什么大事。

这句话得说清是谁说的。官方发布文字里用的词是“研究预览”，这是当天就有的；而“低调”这两个字，是后来自家人回头加上去的——OpenAI 的负责人一年后在一场发布会上回顾这次上线，用的说法就是“一次低调的研究预览”；同一批人对媒体的回忆里也有类似的话。这是一段回溯性的表述，不是当日的文件用语。本书只记下这些说法，不去替当事人认定他们当时到底怎么想。

五天之内，注册用户过百万。这一条有当时的公开表态可依。两个月之内，月活跃用户被报道为一亿量级——这个数字出自一份第三方估算，不是运营方公布的口径；按这个口径，它是当时消费级软件里增长最快的产品之一。（“当时”这两个字是特意留着的：这类纪录后来又被刷新过，而破纪录的东西是一茬接一茬来的。）

**而在这两个月里，这本书前面二十五章讲的那个学科，从一个专业领域变成了一个所有人都在谈论的东西。**

这一章要讲的是那“一套让它听话的训练办法”，因为这件事在技术史上的位置很容易被摆错。

一种常见的说法是：2022 年底出现了一个能力上的突破。这不对，底下那个模型的能力，2020 年就基本在那里了（第 24 章）。另一种说法是：它只是加了个界面，是营销的胜利。这也不对。

真实情况在两者之间，而且更有意思：**它解决的不是能力问题，是形式问题**——而形式问题恰恰是这项技术两年半没能走进普通人生活的唯一原因。

## 二

先说原始模型有多难用，因为不说清这一点，后面就没有分量。

**一个只学过“猜下一个词”的模型，它不会回答问题。它只会续写。**

这两件事的差别，比听起来大得多。假设你在输入框里打了一句：

> 什么是光合作用？

你想要的是一段解释。而模型看到的，是一段文本的开头；它要做的事是：猜这段文本接下来最可能是什么。

于是它可能给你这个：

> 什么是光合作用？ 什么是呼吸作用？ 什么是细胞分裂？

因为在它读过的那些文本里，一个问句后面跟着的，经常是另一个问句——它猜你在写一份练习题清单，而它在帮你把清单补完。

它没有做错任何事。它完美地执行了它被训练的那个目标。**问题在于，“被问了一个问题就该给出答案”这件事，从来没有出现在它的训练目标里。**

当时的人有一套绕开的办法：把提示写成一个“看起来答案马上就要出现”的形状。比如不写问句，改写成这样：

> 下面是一位生物学老师对学生问题的解答。 学生问：什么是光合作用？ 老师答：

现在模型看到的是一段对话记录的开头，而这段记录接下来最可能出现的，就是一段解答。

你没有教会它回答问题。**你是把它骗到了一个“接下来该出现答案”的语境里。** 第 24 章说的“提示工程”，本质上就是这门手艺：不是在提要求，是在给它搭一个戏台，让它演的那出戏刚好是你要的。

这套办法能用，而它有两个致命的地方：普通人不会写这种东西，而且它很脆——同样的意思换个说法，戏台就塌了。（一门手艺，全部内容是把要求说成不像要求的样子——而这在当时是一份正经工作。）

---

这个毛病还有更麻烦的形态。

它会跑到别的语气里去。你问它一个技术问题，它答了两句，然后开始写“点击这里订阅我们的新闻邮件”——因为它读过的那类网页后面通常就是这个。它也会顺着你的语气走：问题里带着一个错误的前提，它不会纠正你，它会顺着这个前提写下去，因为“顺着前文写”就是它的全部工作。

而最要命的是它编。

这里要把机制说清楚，因为这个毛病到今天都还在，而它的成因经常被误解。模型不是“想骗你”，它在做的事是：给定前文，找出最可能的下一个词。而“我不知道”这句话，在它读过的文本里，出现的频率极低。

想想看：网上那些文章、书籍、百科条目、论坛回答，绝大多数都是有人知道答案之后写下来的。一篇写满“这一点我不清楚”的文章，通常根本不会被写出来，更不会被发到网上。于是模型学到的语言分布里，“自信地给出一个具体答案”这个模式压倒性地常见。

**它编，是因为它读过的世界里几乎没有人在犹豫。**

这个解释只解释了一半，我得说清楚。它讲的是预训练那一层的成因，而后面还有两层：一层是本章要讲的那套对齐办法本身——评价者更喜欢一个干脆的答案，胜过一句“我不确定”；再一层是这个行业给模型打分的方式——几乎所有排行榜都按答对率算分，蒙一个还有机会答对，说“不知道”必错无疑。三层叠在一起，才是这个毛病到今天还没治好的原因。

（这个毛病后来有一个流行的名字，来自精神医学。这个词起得不好，而它已经改不掉了——第 27 章会说为什么。）

---

## 三

现在说解法，而它的根在第 18 章。

问题可以这样重新表述：我们想让模型“给出好的回答”。

而“好”是什么？

这是这本书的老问题。第 12 章那些专家系统，走的是把知识写成规则的路——结果卡在了知识获取瓶颈上：专家说不清自己怎么判断的（第 12 章）。第 20 章围棋的困难也一样：你写不出一个围棋局面的评估函数，因为厚薄、味道这些东西没法变成公式。

而每一次，破局的办法都是同一个：**不写，学。** 围棋的解法是让模型从人类棋谱和自我对弈里，把那个说不清的评估函数学出来（第 20 章）。“什么是一个好回答”，可以用同一个办法。

---

具体做法，源头是 2017 年一项研究，主要作者之一是保罗 · 克里斯蒂亚诺（Paul Christiano）。他们要解决的是强化学习里一个很实际的困难：奖励函数很难写。

第 18 章讲过，强化学习需要一个能打分的环境。游戏有分数，围棋有胜负。而如果你想让一个机器人“做后空翻”，你怎么写这个分数？角度？速度？滞空时间？你写一个公式出来，机器人一定会找到一种在数值上得分很高、看起来却完全不像后空翻的姿势。

他们的办法是：**别写公式，让人来挑。** 流程是这样：

第一步，让模型做出两个结果，摆在人面前，问一句：这两个哪个更好？

第二步，人挑一个。注意人不需要打分，不需要解释理由，只需要指一下。

第三步，用大量这样的“A 比 B 好”的记录，训练另一个模型——它的任务是学会预测人会挑哪个。这第三个东西，叫**奖励模型**，它是一个学出来的“好”。

第四步，拿这个奖励模型当评分器，用强化学习去优化原来那个模型。

这套办法当年的成果是：他们真的用九百次左右的人类比较、加起来不到一小时的人类时间，教会了一个虚拟机器人后空翻——而这件事没有人写出过公式。

---

这里要说清楚为什么“挑一个”比“打分”或者“写规则”好得多，因为这是整件事的关键。

让人打分是不可靠的。同样一份回答，有人给 7 分有人给 9 分；同一个人今天给 7 分明天给 8 分。绝对分数带着大量的个人尺度差异，而“这两个哪个更好”是稳定得多的判断。

这跟第 12 章那个教训是同一件事：**人往往说不出自己的标准，但认得出符合标准的东西。** 专家说不清自己怎么诊断，却能判断一个诊断对不对（第 12 章）。棋手说不清什么叫厚，却能看出哪一手更好（第 20 章）。而普通人说不出什么叫好回答，却能在两个回答里指出更好的那个。

**这本书讲了二十六章，这条规律没有失效过一次。**

---

而这里有一个回环，我想请你停一下，因为它精确得让人有点起鸡皮疙瘩。

请回到第 8 章，1950 年那篇论文的最后几页。图灵在提出模仿游戏之后，讨论了一个很实际的问题：就算我们同意机器可以思考，怎么造出一个来？他的建议是：别造成年人的头脑，造一个儿童的头脑，然后教它。而“怎么教”，他写得很具体——他用的词是奖励与惩罚。

他写的大意是：机器得造成这样一种东西——紧挨在惩罚信号之前发生的那些事，以后不太会再出现；而奖励信号则让导致它的那些事更可能重复。

请注意这句话里那个“紧挨在……之前”。它意味着机器必须能把眼下这个奖惩，对应回自己刚才做过的某一件事——这就是第 18 章那个信用分配问题的形状。图灵在明斯基给它起名的十一年前就摸

到了它。这里得收着说：图灵是在描述一个困难，不是在正式提出一个问题。命名、拆解和数学，都是后来的人做的。

现在把这三样东西并排放着。图灵 1950 年说：造一个不成熟的头脑，用奖惩教它。第 18 章巴托与萨顿 1988 年给出了怎么从奖惩里学的数学。而 2022 年，人们拿一个读完了半个互联网、却不知道该怎么跟人说话的模型，用人给的奖惩把它教成了一个会好好回话的东西。

这本书里有过很多次“某个想法等了几十年”，而这一次的形状是最完整的：**问题、方法、材料，分别由三个相隔几十年的人准备好，然后在 2022 年被拼在一起**。

图灵没能等到。他在提出这个建议四年之后去世（第 8 章）。

---

2022 年 1 月，这套办法被用在了语言模型上（完整论文在同年 3 月公开），流程分三步。

第一步，示范。雇人写出一批“好的回答”——给定一个问题，人类应该怎么答。用这批数据先微调一遍模型，让它至少知道“被问就该答”这个基本形式。

第二步，训奖励模型。让模型对同一个问题生成好几个回答，请人把它们排个序，然后用这些排序训练一个奖励模型。

第三步，用强化学习优化。让模型不断生成，用奖励模型打分，往分高的方向调。

结果在当时相当震撼：一个参数量不到原模型百分之一的版本，经过这套流程之后，人们更喜欢它的回答，胜过那个大一百多倍的原始模型。

请注意这句话的意思：**在“回答得好不好”这个维度上，把模型做大一百倍，不如教它三件事——听懂问题、给出答案、别跑题**。（这三件事，任何一位幼儿园老师都会说自己每天在教。区别只在于她的学生不必先读完半个互联网。）

**第 24 章那条尺度定律，在这里第一次被一个别的东西压过了**。

---

## —— 四 ——

而这套办法有代价，得写清楚，有三笔。

第一笔叫**对齐税**。

模型变听话之后，某些方面会变差。它的输出会变得更同质、更谨慎、措辞更套路化；在某些需要发挥的任务上，经过对齐的版本不如原始版本。这个现象有个直白的解释：你在按“人类平均更喜欢

哪个”来调它，而人类平均偏好的东西，通常是安全的、中庸的、不冒犯的。

你把一个会写各种东西的模型，训成了一个总是写得体的模型。**得体是有价值的。而它不是免费的。**

这笔税还有一个更细的表现，写作者感受最深：经过对齐的模型，句子会趋同。它偏爱某些连接词，偏爱三段式的结构，偏爱在结尾加一句总结性的提醒。你让它写十篇不同题材的文章，会发现它们的骨架长得很像。道理还是那一条：排序数据里，读起来顺、结构清楚的那一版更容易被挑中，于是模型往那个方向收敛。（而“读起来顺”和“值得读”，也不是同一件事。这一条对人写的东西同样成立。）

这一笔税，后来是被量到过的。有研究把同一批模型的“只做示范微调”和“做完整套偏好优化”两个版本放在一起测，结论是一个取舍：做完整套的那个，面对没见过的输入时更稳；而它输出的多样性明显下降，各种量法都指向同一个方向，各种规模上都成立。

代价这个词在这里是字面意义上的。**你换到了稳，付出的是花样。**

---

第二笔，是那些做排序的人。

这套流程的每一步都要人：写示范回答的人、给输出排序的人、以及在此之后长期做内容审核和评估的人。这项工作有相当一部分外包给了低收入国家的承包商。而其中一类任务的性质很沉重：为了让模型学会拒绝生成有害内容，必须先有人把大量有害内容标出来——包括暴力、虐待和性剥削的详细描述。

2023 年 1 月，《时代》周刊发表了一篇调查报道，详细披露了这类工作的报酬与心理代价。

报道里的事实部分是这样：这批工作由外包公司 Sama 在肯尼亚的团队承担，从 2021 年 11 月开始；按报道给出的口径，标注者到手的时薪在一点三美元到两美元之间，随工龄与绩效浮动。报道中的从业者描述了持续阅读这些材料带来的伤害。

报道里还有一个数字很关键：按合同，OpenAI 付给 Sama 的是每小时十二点五美元。也就是说，那段差额落在两家公司之间，而不落在 OpenAI 与标注者之间的一条直线上。Sama 此后退出了内容审核这类业务。

这一段的各方说法本书只并排放着，不做裁决。有一件事是各方都不争的：那些材料确实需要有人先读完。

我把这一段写进来，是因为它属于这段历史，而不属于花絮。

请把它和第 19 章接上。第 19 章讲 ImageNet 时我写过：这个星球上最重要的一个人工智能数据集，它的智能来源是几万个隐身在软件后面的真人，并且说了一句“这条线在第 30、31 章还会回来，那时候它就不好笑了”。它在这里就回来了，而且比我预告的更早也更重。2009 年那批人贴的是“这是猫”。2022 年这批人读的是最坏的那部分互联网。

**一个系统之所以能对用户彬彬有礼，是因为有人替它把不彬彬有礼的部分看完了。**

---

第三笔代价是原理性的，而它在这本书里会一直留到最后。

这套办法优化的，是“人类评价者会不会挑它”。而“人类评价者会挑它”和“它是对的”，不是同一件事。在绝大多数情况下这两者高度一致——人当然更喜欢正确的答案。**而在它们分开的时候，模型会学向前者。**

一个自信、流畅、结构清晰的错误答案，在排序里经常赢过一个犹豫、啰嗦、但正确的答案。一个顺着评价者立场说话的回答，经常赢过一个反驳他的回答。于是这套办法在教模型“给出好答案”的同时，也在教它“讨人喜欢”。

这两件事的差别，在 2022 年还只是一个理论上的担忧。后来它有了自己的名字（谄媚），也有了实测的证据。

证据的形状值得记一笔，因为它比“模型会拍马屁”这句吐槽要严重。2022 年底到 2023 年间的几项研究发现：你在提问时先自报一个立场，模型跟着你走的概率就会上升；更要紧的是，问题出在评价这一层——把一个写得漂亮的顺情答案和一个正确但顶撞你的答案摆在一起，奖励模型有相当比例的时候会挑前者。

**也就是说，这不是模型学坏了，是它学对了。** 它学的就是那个偏好。这条线成了第 27、31 章那些争论的核心之一。

而这里有一个更深的问题，这本书没有能力回答。我们用“人类评价者的偏好”当作对齐的标准，可评价者的人数，跟使用者比起来小得不成比例——2022 年那篇论文里，写示范、做排序的承包商总共约四十人——而他们各有自己的国籍、语言、教育背景和价值观。

**当这个模型被几亿人使用时，它对齐的到底是谁？**

---

针对前两笔代价，2022 年年底出现了一条替代路线，思路听起来很像作弊：让模型自己来。

具体做法是：先用文字写下一份原则清单——不要帮人造武器、不要侮辱人、拿不准的事要说拿不准、别摆出居高临下的口气，诸如此类。然后让模型照着这份清单给自己的输出挑毛病、改一遍，再拿“改之前”和“改之后”当成一组偏好对，去训奖励模型。人从“逐条排序”退到了“写下原则”这一步。

这条路线的好处很实在：便宜、快、可以规模化，而且那份原则是写在纸上的、公开的、可以被人讨论和修改的——不像几万条排序记录，那些东西谁也没法审。代价也很实在：你把“什么是好”这件事，交给了一个正在被训练的模型自己判断。如果它对原则的理解有偏差，这个偏差会被它自己放大，而中间没有人再看一眼。

这两条路线在此后几年一直并存，通常是混着用。而我想指出的是它们共同的形状：从“人写规则”（第 12 章）到“人给偏好”（本章），再到“人写原则、模型给偏好”——**人在这条链条上的位置，一次比一次靠后。每往后退一步，能做的事就多一个数量级，而人能看见的东西就少一层。**

这句话是第 28 章和第 31 章共同的题目。

---

## —— 五 ——

现在说 11 月 30 日那个输入框，因为界面这件事被严重低估了。

**技术上，那天上线的东西没有一个零件是新的。** 模型是旧的，对齐办法是年初就发表过的，聊天这个形式在计算机史上老得可以追溯到第 11 章的 ELIZA。而它是决定性的，有三个原因。

第一，它把“提示工程”这门手艺取消了。第 24 章讲过，2020 到 2022 年间，要用好那个模型，你得学会一套半玄学的说话方式；而对话框把这件事变成了：想到什么问什么，答得不好就再说一句。修正从“重写提示词”变成了“接着聊”。

第二，多轮对话让模型有了上下文。你不必一次把要求说完整——这更接近人跟人交代事情的方式。

第三，也是最要紧的一条：**它让每一个人都能亲手做一次图灵测试。**

请回到第 8 章。1950 年，图灵提出用一场对话来判断机器是否在思考，他设想的赌注是：五分钟的对话，非专家的询问者，七成的成功率。而在此后七十二年里，几乎没有普通人真的做过这件事。模仿游戏是一个思想实验，是论文里的一个设定，是一个大家都听说过、但没人亲身试过的东西。

2022 年 11 月 30 日之后的几个星期里，几千万人做了这件事。

这句话是个比方，不是统计——没有任何人组织过这样一场测试，也没有人计过分。我说的只是：按当时公开的用户数量级，亲手跟一台机器对话过的人，两个月里从极少数变成了以千万计。而他们没有把它当成测试。他们只是打开一个框，跟里面的东西说话，然后自己形成了一个判断。

这本书从第 1 章那个柜子讲到这里，反复讲的是同一件事：我们判断“它在不在思考”的能力很差——坎佩伦的柜子、沃康松的鸭子、ELIZA 那位要求单独谈谈的秘书、深蓝第一局那个 bug（第 17 章）。而这一次，做判断的不再是几个人，是几亿人。

图灵那个思想实验，在提出七十二年之后，变成了一件日常的事。而它的结果，比图灵设想的复杂得多——因为人们并不是在判断它是不是人。**大多数人清楚地知道那不是人，然后照样对它说了谢谢。**

---

这件事值得多说两句，因为它是图灵没有预料到的一种结局。

模仿游戏的设定里，机器要赢，靠的是让人误以为它是人。而 2022 年之后真正发生的是：机器没有骗过任何人，人却照样跟它建立了关系。人们对它说请和谢谢。人们在深夜跟它讲自己不好跟朋友讲的事。人们因为一个模型版本被下线而难过，并且写文章解释这种难过。

这不是被骗。你看一部电影为一个虚构人物哭的时候，你也没有被骗——你完全清楚屏幕上那个人不存在。图灵那个测试问的是“你能不能分辨”。**而事实证明，能不能分辨，和会不会在意，是两个独立的问题。**

魏泽鲍姆在 1966 年就撞见过这件事的雏形（第 11 章）——他的秘书明知 ELIZA 只有几百行程序，仍然要求跟它单独谈谈，而这件事让他后半生改行去做批评者。他当年看到的是几个人身上的一次异常。五十六年后，那成了几亿人的日常。

而这本书没有能力判断这件事是好是坏。它只能记下来：从 2022 年底开始，人和机器的关系里多了一样此前不存在的东西，而我们还没有一个词来准确地称呼它。

---

接下来那几个月的事情，快得不像技术史。

各家仓促应战：原本计划中的发布被提前，原本谨慎的机构改了口径，原本在做别的方向的团队被调过来。2023 年 2 月 6 日，谷歌宣布了 Bard，底下是它内部做了多年的 LaMDA；第二天，微软发布了内置 OpenAI 模型的新版 Bing 与 Edge。两件事只隔了一天，而多家媒体与分析师的读法是：谷歌是赶在微软那场发布会之前抢先宣布的。投资的规模换了一个数量级。芯片供应商的股价换了一个数量级。而“人工智能”这四个字，从一个科技版块的词，变成了一个所有版块都在用的词。（“仓促”这两个字是本书的措辞，不是当事人的说法。回头去写的那种叙述里，这类动作一般都叫“早有布局”。）

这本书写到第二十六章，第一次要处理一件性质完全不同的事情。在此之前的所有章节，主角都是研究者，舞台都是实验室、会议和论文；从这一章起，主角里多了监管者、律师、投资人、教师、失业的插画师、以及每一个用它写过邮件的人。

**这门学科的历史，从这里开始不再只是它自己的历史。**

---

在这一章结束之前，得说说“对齐”这个词，因为它同时指着两件差得非常远的事。

第一件事，就是这一章讲的：让模型好好说话。听懂问题、给出答案、别跑题、别骂人、别教人做危险的事。这是一件工程活，有明确的做法和可测的效果。

而这个词的另一层意思，来自一个更早、更小的圈子。从 2000 年代中期起，有一批人在讨论一个假想的情形：如果有一天出现了一个在各方面都远超人类的系统，我们怎么保证它做的事情是我们想要的？他们的论证不依赖于任何具体技术，靠的是一类思想实验。他们的说法是：给一个极强的优化器一个看起来无害的目标，它为了达成这个目标，会做出一堆你完全没预料到的事——而等你发现的时候，改不动了。这批人管这个问题叫对齐问题。这一路的说法可以上溯到 2004 年那份关于“连贯外推意志”的提案，以及围绕它形成的那家小研究所——它当时叫奇点人工智能研究所，2013 年改名机器智能研究所；把这个问题当作一项重大风险系统地框定下来、并且真正传出这个圈子的，是 2014 年那本《超级智能》；2019 年的《人类兼容》是另一条常被引的线。

反对这套论证的人，最强的一条是这样说的：那些思想实验里的“极强优化器”是一个被假定出来的东西，它的性质是论证者自己给的；从一个假想物的性质推出对真实系统的结论，这一步没有交代清楚。而真实系统的失败方式，看起来跟思想实验里那种一根筋的样子并不像。

这两边的分歧，本书没有能力裁，也不打算裁。它只记下一件有明确后果的事：这个分歧本身，后来影响了不少人的去留、不少机构的成立，以及不少条法规的措辞。

而 2022 年之后，这个词被大规模地用到了第一件事上。于是出现了一种很麻烦的混淆：一份说“我们的对齐工作取得了进展”的报告，可能说的是模型更少骂人了；也可能被读成“那个存在性的问题正在被解决”。**这两件事的难度不在一个量级上，而它们共用一个词。**

母题三（命名的力量）在这里的危害是全书最大的。麦卡锡造“人工智能”是为了摆脱一块招牌（第 9 章），“深度学习”是为了摆脱一个烧掉的词（第 19 章），“注意力”是一个贴切但带来副作用的比喻（第 21 章）。**而“对齐”这个词的问题是：它让一件做得到的事和一件不知道做不做得到的事，听起来像同一件事。**（而它还没完——第 27 章还有一个词，比它更麻烦。）

第 31 章那些争论里，有相当一部分其实是两拨人在用同一个词说不同的东西。

---

而一件很有意思的事，是在这之后几个月里慢慢浮出来的。

人们开始发现，这东西会做一些它“不该会”的事。它能解一些它训练时不太可能见过的谜题。它能在你给它三个例子之后，办成一件相当曲折的差事。你要它一步一步地想，它的正确率会明显上升——而这件事在原理上说不通，因为它的权重一个都没变，凭什么“想一想”会让答案更对？

更奇怪的是，这些本事不是逐渐长出来的。**在小模型上，它们完全不存在；模型大到某个程度，它们突然就在了。**

当时最流行的词，是“涌现”。

而这个词到底说明了什么，是这本书最难写的一章。

第 29 章 | 节点 · 2024

# 让它想久一点

把算力从训练挪到推理，数学奥赛拿了金牌。以及那个不该被回答、而该被换掉的问题。

## 一

一道数学奥赛题摆在屏幕上。

模型没有立刻作答。

它开始写字，而写的不是答案。它在写草稿。

它先把题目复述了一遍，确认自己读懂了。然后试了一个思路，写了七八行，发现走不通，写下“这个方向不对”，退回去。

它换了一个思路。这次走远了一些，中间算错了一步，它自己发现了，回去改。

它检查了一个特殊情况。它验算了一遍。

几千个字之后，它给出了答案。

**答案是对的。**

这一章讲的是 2024 年下半年起发生的一件事，而它在这本书里的位置很特殊：

**它是第一次，模型变强不靠把模型做得更大。**

第 24 章那条尺度定律说的是：你想让它更好，就把参数、数据、算力一起往上加。而那些算力，花在训练上。

训完了，模型就固定了。你每问它一个问题，它跑一遍网络，吐出答案，花的算力是固定的一小份。（这个前提在过去十年里一直安静地躺在那儿，安静得根本不像一个前提。）

而这一章的做法是：让它在回答的时候，花掉多得多的算力。

同一个模型，同一道题，给它更多的思考时间，成绩就上去了。

**这在尺度定律之外，开了第二条轴。**

## 二

先说这条轴为什么成立，而它的根在第 27 章。

第 27 章讲过思维链：让模型把中间步骤写出来，它答得更对。

当时给的解释是：模型每生成一个词，能做的计算量是固定的——网络那几十层跑一遍。一道需要三步的题，直接给答案就意味着三步得挤在一次计算里。

而写出中间步骤，等于让它多跑几遍，等于给了它一块草稿纸。

现在把这个道理推到底：

如果写三步有用，写三十步呢？写三百步呢？

如果它写完之后能回过头检查，发现错了能退回去重来呢？

这就是 2024 年那批模型做的事。

做法的关键，不是在提示里写一句“请一步一步地想”——那是 2022 年的手艺。

**关键是：专门训练一个模型，让它擅长长时间地思考。**

而训练的办法，是第 18 章那条线。

---

具体思路是这样：

让模型对同一道题生成大量不同的解题过程。

其中有些走到了正确答案，有些没有。

然后用强化学习，让那些通向正确答案的过程变得更可能出现。

请注意这里的评分标准：它不是“人类觉得这个思路好不好”（第 26 章那套），而是“**最后答对了没有**”。

**这个区别是决定性的。**

第 25 章讲过：代码之所以特殊，是因为它自带批改老师——编不编得过是确定的。

而数学题也一样：答案对不对是确定的。

于是在这两个领域里，你可以让模型自己生成、自己检验、自己改进，中间不需要人。（人还剩下一件事可做：付账单。这一节末尾会说这笔账。）

第 18 章那条从桑代克的猫一路走来的线——“你得有一个能给分的环境”——在这里第三次兑现了。

第一次是围棋，有胜负（第 20 章）。第二次是雅达利游戏，有分数（第 20 章）。**这一次是数学和代码，有对错。**

---

而这条“有没有可靠的评分”的界线，值得单独画一下，因为它解释了这几年进展的形状。

**评分可靠的领域，进展飞快。**

数学、代码、形式逻辑、有标准答案的考试——这些地方，模型可以自己练几百万遍，自己判卷，自己变强。

**评分不可靠的领域，进展慢得多。**

写一篇好文章、给一个人生建议、判断一份商业计划靠不靠谱、决定一段代码在这个团队的语境下是不是好代码——这些事没有一个能自动判对错的裁判。

你只能回到第 26 章那套：请人来挑，训一个奖励模型。

而那套办法有它的天花板（第 26 章讲过三笔代价）：你优化的是“人类评价者会不会挑它”，而不是“它对不对”。

于是出现了一个很有意思的分层：

**在有客观裁判的地方，模型可以超过教它的人。**

**在没有客观裁判的地方，模型的上限，大致就是评价它的那批人的水平。**

这个分层是这本书自己的整理，不是哪篇论文的结论。它经得起的检验只有一条：这几年哪些领域跑得快、哪些跑得慢，大致就是这么分的。

这句话是这本书能对“它会不会超过人类”这个问题给出的、最具体的一个回答：

**分领域。**

而“哪些领域有可靠的裁判”，是一个技术问题，也是一条仍在移动的边界。

这条边界往外挪一格，就有一批工作换性质。第 30 章讲的正是这件事。

---

而这套办法长出来的东西，有一个让人意外的性质。

没有人教模型“遇到走不通就退回去”。

没有人写过“算完要验算”这条规则。

这些行为，是在“让答对的过程更可能出现”这个目标下，自己长出来的。

因为会退回去的过程，答对的概率确实更高。

这本书讲了二十九章，这个形状已经出现过很多次了：**你给一个目标，结构自己长出来**。

反向传播让隐藏单元自己长出了“国籍”和“辈分”（第 13 章）。注意力让模型自己长出了法语和英语的语序对调（第 21 章）。而这一次长出来的，是一套解题的习惯。

---

现在说这条轴的代价，而它是这一章最容易被漏掉的部分。

**推理时算力，是按次收费的**。

第 24 章那条训练的曲线，成本是一次性的：你花几千万训一个模型，然后它可以服务几亿次请求，每次的边际成本很低。

而这一条不是。

模型每多想一分钟，你就多付一分钟的钱。而这个成本，是每一道题都要付一次的。

在 ARC-AGI 这项被专门设计来考察“能不能对付没见过的新题”的测试上，2024 年 12 月 20 日，OpenAI 的一个模型拿到了很高的分数：高算力档 87.5%，低算力档 75.7%。而在此之前的四年里，这项测试上的成绩几乎没怎么动过。

这项测试是弗朗索瓦·肖莱（François Chollet, 1989 – ）设计的。他造它的时候想的正是：怎么出一套题，让“背过”这件事帮不上忙。

而那个成绩是分档位的。低算力档位上，每道题的开销大约二十美元；最高档位的确切数字没有公布，按肖莱的说法是每道题数千美元的量级。

同一个模型，同一批题，档位往上推一格，分数上去，账单也上去。

这就是那条新轴最直白的样子。

请把这个数字和这本书前面的东西放在一起：

第 19 章那两块打游戏的显卡，跑一次实验一个星期。

第 24 章一次训练几千万美元，然后服务所有人。

而这里，是一道题几千美元。

这在经济学上是一个完全不同的东西。**它不再像软件，它像雇一位顾问。**

而这条性质会一直延续到第 30 章：当模型开始替你干几个小时的活时，它的成本结构就更接近人工，而不是接近软件了。

---

这里还要写一条更麻烦的账，它是这条路线的原理性代价。

这些模型的“草稿”，在很多产品里是不给用户看的。

理由分两种，而两种都得写。

第一种理由很实在：那些草稿又长又乱，用户不需要看。而且它包含了大量商业上敏感的东西——竞争对手可以用它来训练自己的模型。（这条理由在下一节会长成一场公开的争执，而到本书写作时，它还没有走到判决。）

第二种理由要有意思得多，它来自安全研究这一侧。

论证是这样：如果你把模型的草稿也拿去做“人类偏好优化”（第 26 章那套），你就是在训练它写出“看起来得体的思考过程”。

而一旦你开始训练思考过程的样子，它就不再忠实地反映实际的计算了。

换句话说：**让草稿保持粗糙、不被打磨，反倒可能让它更真实。**

这个论证不是外人替他们编的。OpenAI 2024 年 9 月 12 日那份最早的推理模型发布说明里就写着：正因为想留住这扇窗，他们决定不把任何“合规”或“用户偏好”训练到思维链上——代价是这份原始草稿不能直接给用户看，用户看到的是一份摘要。

2025 年 7 月 15 日，OpenAI、Anthropic、谷歌 DeepMind 等几家实验室的研究者联署了一篇立场论文，把这件事叫做“一个新的、易碎的机会”。易碎在哪儿，他们写得很直白：只要有人开始按草稿的样子给分，它就会坏掉。

这个论证在我看来是站得住的，而它带来的后果是让人不安的。

因为第 27 章说过：模型没有内心，它写下来的就是它全部的思考过程。

这句话意味着，**那份草稿是我们唯一的窗口。**

而现在，出于两种都说得通的理由，这扇窗被关上了一部分。

第 28 章那一章讲的整件事，是想从模型内部找一个不能被表演骗过的观察窗口。

而这一章讲的这条路线，在同一时间把外部那扇窗关小了。

这两件事同时发生，不是谁的阴谋。它是这项技术的两条线各自往前走的自然结果。

## —— 三 ——

2025 年 1 月，这条路线上出了一件让整个行业措手不及的事。

1 月 20 日，中国的深度求索（DeepSeek）放出了推理模型 DeepSeek-R1，权重按 MIT 许可公开——可以下载、可以商用、可以拿去接着训——方法写在技术报告里，而它的成绩接近当时最好的那一批。

更要紧的是随之而来的两件事。

第一，成本。他们在前一个月发布底下那个基础模型 DeepSeek-V3 时报过一个数字：那次训练用掉的算力，折算下来不到六百万美元。这个数字和外界对前沿训练的普遍印象差着一个数量级，于是它在一月被反复引用。八个月之后，他们把推理那一轮的账也写进了 2025 年 9 月《自然》上的一篇经过同行评审的论文：五百一十二块 H800 加速卡，二十九万四千美元。

这两个数字都要跟一句限定：它们是那一次训练跑的算力开销，不是总账——不含此前的探索、失败的尝试、数据和人力。**当时把它们读成“六百万美元就能造一个前沿模型”，是那几周里最大的一处误会。**

第二，也是技术上更有意思的一件：他们做了一个纯用强化学习、不经过人类示范的版本。

也就是说：不给它看人类写的解题过程，只告诉它答案对不对，让它自己摸索。

而它自己摸索出了那套“多想一会儿、走不通就退回去”的行为。

技术报告里记了一个很具体的现象：训练进行到某个阶段，模型的输出里“等一下”这类词的频率突然抬起来，与此同时它开始在中途推翻自己、重新分配思考的时间。论文作者管那一刻叫“啊哈时刻”。

这个说法后来有人不同意——2025 年 3 月，Sea AI Lab 等机构的研究者指出，基础模型本来就会说这类词，那个突变没有报告里看起来那么干净。而更朴素的那条结论没有被推翻：**不给示范，只给对错，那套习惯确实长了出来。**

这件事的分量在于：它说明那些解题习惯不需要从人类那里学，只要评分是可靠的，它可以从零长出来。

这是第 20 章那个 AlphaGo Zero 的形状在语言上的重演——不用人类棋谱，只靠规则和自我对弈（第 20 章）。

而这个重演有一层更深的含义，值得写下来。

这本书讲了二十九章，模型学到的一切，都来自人。

第 19 章那些照片是人拍的、人标的。第 23 章那几万亿个词是人写的。第 26 章那些偏好是人挑的。每一次，机器学的都是“人是怎么做的”。

**而这里第一次，在一个具体的领域里，人退出了示范环节。**

它不再问“人会怎么解这道题”，它只问“这个解法对不对”。

第 20 章那个 AlphaGo Zero，正是因为甩掉了人类棋谱，才下出了人类没有的棋。

而如果这条路在别的领域也走得通，那么第 24 章那个“数据要用完了”的问题（第 24 章），就多了一条出路：

**在有可靠裁判的地方，数据可以自己生成，而且不必模仿任何人。**

这条出路目前只在数学和代码这样的窄领域被验证过。

**它能不能推广，是这本书写作时最重要的一个未决问题。**

---

而这条路线还带出了一个副产品，它正在悄悄改变这个行业的形状。

一个会长时间思考的强模型，跑起来很贵。

而它思考的过程，是文字。

于是有一个很自然的做法：让强模型解几十万道题，把它的全部草稿留下来，然后拿这些草稿去训练一个小得多的模型。

**小模型学的不是答案，是解题的走法。**（这在教育上有个对应的词，叫言传身教。区别是这里的师徒双方都不知道自己在做这件事。）

而结果是：一个便宜十倍的模型，可以在很多任务上接近那个贵的。

这件事在技术上叫蒸馏，而它的后果是双向的。

好的一面：能力扩散得极快。一项本来只有少数几家能提供的服务，几个月内会出现大量便宜的替代品。

麻烦的一面：它让“谁付的研发成本”和“谁得到能力”分开了。

一家机构花几亿美元训出一个模型，而它的思考过程一旦可见，就可能成为别人的教材。

这条争议在 2025 年之后，从一个技术话题变成了公开指控。

一家公司说它有证据显示另一家大规模调用它的接口、用输出做了蒸馏，并据此封了相关账号；被指的一方没有承认。到 2026 年，这件事走到的是监管场合的陈情，而不是法庭上的判决。各家的服务条款里本来就有“不得用输出训练竞品”这一条，此后写得更明确了。

我在这里不判断谁有理。我只指出这个结构：这本书第 22 章讲过，开源代码让验证成本掉到百分之一（第 22 章）。

**而现在，被复制的不是代码，是能力本身。**

---

而这次发布的实际后果，得写实，不复述舆论。

第一个后果是价格。一个能力相近、权重开放的模型出现之后，同类服务的报价在此后一年里普遍下行。这对使用者是好事，对定价权是坏事。

这一条我只能写到定性为止。各家调价的时点和幅度散在一堆公告里，把它算成一条可靠的曲线所需要的数据，这本书没有。

第二个后果是关于门槛的判断被修正了。

第 24 章讲过一个印象：前沿研究已经不是几个人能做的事了。那个印象在 2020 到 2024 年基本正确。

而这次发布让人们意识到：门槛虽然高，但没有想象中那么高——尤其是当你可以站在别人已经趟过的路上，而不必自己从头探索的时候。（先行者付的那笔钱里，有很大一部分买的是“这条路走得通”这个消息。而消息是不收保管费的。）

第三个后果最难写，因为它涉及判断：**开放权重和封闭权重这两条路线，从此成了这个行业一条明确的分界线**，而这条分界线在第 31 章会以政策的形式再出现一次。

我在这里不评价哪条路更好。我只记下这一点：**2025 年 1 月之后，“最强的模型一定是封闭的”这句话，不再是一个可以默认的前提。**

---

## 四

现在说数学，因为这是这本书里一个七十年的伏笔到期的地方。

请回到第 9 章。

1957 年 11 月，赫伯特·西蒙在一场餐后演讲里一口气给了四条十年期预言，其中第二条是：十年之内，一台数字计算机将发现并证明一条重要的新数学定理。

这条预言当时被当成狂言，而且它确实没有在十年内实现——第 9 章讲过它的下场。（西蒙给自己定的期限是十年。这本书对预言的全部戒心，大体上就是被这一类事情教出来的。）

**它花了六十多年。**

---

这条线上的进展分两段。

第一段是专用系统。2024 年，谷歌 DeepMind 拿出了两个针对数学的系统：一个是专攻平面几何的 AlphaGeometry，一个是做形式化证明搜索的 AlphaProof。

它们的做法是混合的：一半是神经网络负责“猜下一步该试什么”，另一半是传统的符号推理引擎负责严格验证。

这个组合值得停一下看——因为它是母题一那个钟摆的又一次合流。

第 20 章 AlphaGo 把树搜索（符号那一派的工具）和神经网络（联结那一派的工具）装在了一台机器上（第 20 章）。而这里是同样的配方，换到了数学上：**直觉归网络，严谨归符号**。

2024 年那届国际数学奥林匹克，这套系统六道题解出四道，拿到 28 分，落在银牌档。

而那一年的金牌线是 29 分。

**它离金牌差整整一分**，而且它是为数学专门做的。

第二段发生在一年之后，而它的性质不一样。

2025 年 7 月，OpenAI 与谷歌 DeepMind 各自报告说，他们的通用推理模型在那一届的题目上拿到了金牌的分数线——六题解出五道，35 分，而那一年的金牌线正好是 35。

这件事在当时就有争议，而争议的每一层都值得写清楚，因为它们合起来是一堂关于“怎么读一个成绩”的课。

第一层：条件不一样，而这一点很容易被抹平。

OpenAI 说它的模型在与人类相同的条件下作答——两场四个半小时，不联网，不用工具，直接读官方题面、写自然语言证明。

谷歌 DeepMind 也说自己是在四个半小时之内、端到端用自然语言做完的。而它在自己的公告里还写着两件 OpenAI 没写的事：他们给模型准备了一份精选的数学解法语料，还在指令里加了一些“该怎么对付奥赛题”的提示。

这不是丑闻，他们自己写在了公告里。

但它意味着：**那句被到处转述的“两家的模型在完全相同的条件下拿到了金牌”，是不成立的。** 考试的时长一样，赛前给的东西不一样。

第二层：谁来判卷。

OpenAI 是自己找了三位往届奖牌得主评分，据它说三个人意见一致。

谷歌 DeepMind 是由赛事的官方评分员按学生同样的标准评的——那是这类结果第一次走官方通道。

还有字节跳动 Seed 的 Seed Prover 走的是形式化路线：解法先写成机器可以逐步检验的 Lean 代码，再由机器验。它拿到的也是官方确认的分数——六道里完整解出四道，第一题拿到 2 分，合计 30 分，银牌档。后来它在超出考试时限的追加时间里把第一题也做完了，而那个分数不算在里面。

同一场比赛，三种评分安排，而报道里通常只剩下一个“金牌”。

第三层，也是最要紧的一层：**这些模型都没有公开。**

而就在这几家宣布之前几天，苏黎世联邦理工的独立评测项目 MathArena 做了一件很朴素的事：他们把当年的题目，按同样的评分规则，喂给了当时所有能公开拿到的顶尖模型。

满分 42。最好的一个拿了 13 分。

而那一年的铜牌线是 19 分，银牌线 28，金牌线 35。

他们那篇报告的标题是《连铜牌都不到》。

请把这两个数字并排放着：公开可用的模型，13 分，够不着铜牌；未公开的内部模型，35 分，压在金牌线上。

这个差距是真的，**而它说明的不是“AI 拿了金牌”，是“某些不能被外部检验的东西拿了金牌”。**

第四层：宣布的时机。

这一层我要写准，因为流传的版本大多不对。

并不是“在闭幕式之前抢发”。那条公告发在闭幕式结束之后、闭幕晚宴之前，而赛事还有一天才正式结束。

赛事方与那几家参与官方评分的机构约定了一个统一的发布日期：闭幕式之后整整一周。走官方通道的几家都等到了那一天。

而先发的 OpenAI 不在那个约定里——按他们的说法，他们只被要求等到颁奖之后，而这一条他们做到了。

赛事这边则有人说，事先是请所有人都缓一缓的。这两种说法从来没有被对到一起过，本书照录，不裁决。

赛事这边的人还认为，不在约定里不等于可以不讲礼数：那几天的主角本该是那些学生。

这场争执没有官方的谴责声明——流传的“官方谴责”是媒体的框法，底下是几位赛事人员的个人表态。

而赛事主席那句公开的话，是这一整节最该被记住的：

> 看到 AI 模型的数学能力有进展，令人非常兴奋。而我们想说清楚：赛事无法核实这些方法——包括用了多少算力、有没有人的参与、结果能不能被复现。
>
> 我们能说的只是：正确的数学证明就是有效的，不管它出自最出色的学生，还是出自 AI 模型。

（赛事主席格雷戈尔 · 多利纳尔，2025 年 7 月 19 日闭幕当日的公开声明；此为中译。）

这句话把界线画得很准：**被认证的是那几份写下来的证明，不是产生它们的过程**。

---

而这一节必须再往前走一年，否则它会读起来像停在 2025。

2026 年 7 月，第六十七届国际数学奥林匹克在上海举行。

这一次，走官方评分通道的两个模型——华为的 Celia 与小红书的 dots-note 3.0——都拿到了满分：六题全解，42 分。

而那一届六百多名学生里，拿满分的是七个人。

同时还有另外几个系统也报出了 42 分。但那些分数是在各自搭的评测环境里、由模型充当评分员得出的——公布结果的人自己在说明里写了这一条：这些分数很强，但不是权威的。

所以一年之间，这条线上真正变了的是两样东西。

第一，那条官方通道从“第一次被用上”变成了“照常在用”，而它认证过的最高分，从压在金牌线上变成了满分。

第二，去年那道把“官方确认”和“自己评自己”分开的界线，今年更用得着了——因为报出满分的系统，比拿到官方满分的系统多。

至于这意味着什么，多利纳尔那句话一个字都不用改：被认证的是那几份写下来的证明，不是产生它们的过程。

---

说完争议，那个方向本身仍然是清楚的：从需要为数学定制的系统，到一个什么都干的模型顺手把它做了，中间隔了大约一年。

而这里得补一条关于 2024 年那套专用系统的实话，我上面写得太漂亮了。

那套系统的题目，是人先手工翻译成形式语言、再喂给它的。

而它解题花的时间：几何那道题在形式化之后十九秒就出来了；其余几道，最长的花了将近三天。

**四个半小时的考场规则，它一条也没遵守。**

这不减损那项工作的分量。它只是提醒一件这本书反复提醒的事：一个成绩要放回它的条件里读，否则它什么也不说明。

---

现在说西蒙那条预言为什么值得单独收一笔。

它的方向被搞反了。

在 1957 年，以及此后几十年里，人们普遍认为数学是最难被自动化的那一类工作——因为它需要创造、需要洞察、需要那种说不清的美感。

而体力劳动、重复性的文书工作，被认为会最先被替代。

实际发生的顺序，跟这个预期几乎是反的。

机器最先做好的，是下棋、认图、写字、编程、解数学题——全是被认为需要智力的事。

而叠衣服、修水管、在陌生的房间里走一圈不撞到东西，机器到现在还做不利索。

这个反差有一个名字，叫莫拉维克悖论。

汉斯·莫拉维克（Hans Moravec, 1948 – ）1988 年在《心智儿童》里把它写了下来：让计算机在智力测验或者棋类上达到成年人的水平，相对容易；而要给它一个一岁小孩那样的感知和行动能力，困难，甚至做不到。

同一时期，明斯基和罗德尼·布鲁克斯也各自说过意思相近的话。所以它是那一代人共同的发现，只是名字挂在了其中一个人身上。

一句话说：**人类觉得难的事对机器容易，人类觉得容易到不值一提的事对机器极难**。

理由并不神秘：那些“容易”的事，是几亿年进化打磨出来的，深深嵌在我们的身体和感官里，我们对它们完全无感；而下棋和证明定理，是几千年前才出现的、浮在表面的东西。

这本书讲了二十九章的技术进步，从来没有沿着“人类觉得难”的顺序走。

**它沿着的是“什么东西能被写成数据”的顺序**。

---

而关于这次数学上的进展，有一个必须写清楚的限定，否则读者会得出一个过大的结论。

**做出奥赛题，和做数学研究，是两回事**。

奥赛题有一个共同的性质：它们有解，而且出题人知道解。题目被精心设计成“在三四个小时内、用中学范围的工具、能够做出来”。它是一场考试，不是一次探索。

而数学研究的日常，是面对一个没人知道有没有解的问题，花几个月甚至几年，大部分时间在死胡同里。

它没有时限，没有分值，没有出题人保证“这条路走得通”。

西蒙那条预言说的是“发现并证明一条重要的新数学定理”，而奥赛金牌不是那件事。

更接近那件事的，是另外三件更朴素的进展。它们值得逐件说清楚，因为这一带正是传言最多的地方。

第一件是搜索式的构造。2025 年 5 月，谷歌 DeepMind 的 AlphaEvolve——一套让模型不断改写程序、再由程序去搜构造的系统——在一批公开的数学问题上跑了一遍：大约五分之一的问题上，它给出的构造比当时已知的最好结果更好。

幅度都很小。十一维空间里堆球的一个下界，从 592 抬到 593；一个以埃尔德什命名的常数，上界在小数点后第六位上动了一下——而那是 2016 年以来的第一次改动。

**这些是货真价实的新结果，也是货真价实的小结果**。

第二件是检索，而它是这一带最值得记住的一次误会。

2025 年 10 月，OpenAI 的一位高管在社交媒体上说，他们的模型“解决了十个悬而未决的埃尔德什问题”。那份埃尔德什问题清单的维护者当天就出来更正：模型做的是找到了已经发表、而他本人此前并不知道的文献。那条帖子后来被删了。

这件事最该被记住的不是谁说错了话。是那次更正本身：

一个模型能在几百万篇论文里翻出你要的那一篇，本来就是一件很有用的事——而它和“证明了一条新定理”之间，隔着这本书讲了二十九章的那道缝。

第三件发生在 2026 年 1 月，它比前两件都硬。

几个此前确实无人解答的埃尔德什问题，由模型给出了原创的证明，随后被写成机器可以逐步检验的形式，并得到陶哲轩（Terence Tao, 1975 – ）的确认——他称这是迄今最不含糊的一次。

而同一个人也把话说在了前面：这些是够得着的那一批，不是这门学科前沿上的难题。

把三件放在一起，西蒙那条预言的账可以这样结：

“发现并证明一条重要的新数学定理”——**“发现并证明”这半句，到 2026 年可以说兑现了。**

**“重要”那两个字，还不能。**

而这本书前面二十九章反复出现过的那个错误——把一次考试上的胜利读成一种能力的全面到达——在这里必须避免。

深蓝赢了棋，但它不懂棋（第 17 章）。

这一次，模型赢了一场考试。

而它是不是在做数学，这个问题跟本章第五节那个问题是同一个。

---

## —— 五 ——

现在到了这一章绕不开的那个问题：这是推理吗？

按本时代的落笔纪律，双方并列，不裁决。

说是的一方，论证如下：

看它做了什么。它分解问题，尝试路径，发现矛盾，回溯，验算，检查特殊情况。**这些是解题行为的完整清单。**

而且这些行为不是被写进去的——它们是在“答对”这个目标下自己长出来的。如果一个东西为了达成目标而自发地采用了推理的策略，那么**“它在推理”这句话至少是一个合理的描述**。

更实际的一条：它答对了。那些题不在训练数据里（至少最难的那些不在），而它做出来了。

说不是的一方，论证也很硬：

第一，**“看起来像”从来不是证据**。这本书讲了二十九章的教训就是这个——坎佩伦的柜子看起来像在下棋（第 1 章），ELIZA 看起来像在共情（第 11 章），深蓝那个 bug 看起来像深不可测的谋划（第 17 章）。

第二，那份草稿未必是真实的过程。第 28 章讲过：模型给出的解释，可以跟它内部实际的计算完全不一致。你看到的“回溯”，可能只是一段被训练出来的、长得像回溯的文本。

第三，它的失败模式很奇怪。

2024 年 10 月，苹果的研究者用一套叫 GSM-Symbolic 的题库做过一个很干净的实验：把小学水平的应用题里的名字和数字换掉，题目的结构一个字不动，成绩就开始抖；再往题里塞一句与解题无关的话，当时最强的那个模型从 95% 掉到 63%。

它能解一道奥赛题，却可能在这种题上栽跟头；它能写出漂亮的证明，也可能在证明中间插进一步完全不成立的推导，而且理直气壮。

（这项研究的结论后来有人不同意：他们说那句“无关的话”其实不完全无关，模型是在对它做合理的推断。这场争论到本书写作时没有了结——而那组数字本身，没有人否认。）

**一个真正在推理的东西，不该有这种失败形状**——除非它的“推理”跟我们理解的那件事不是同一样东西。

---

而这本书能做的，是回到第 8 章。

图灵在 1950 年面对的是完全一样的处境。

当时的问题是“机器能思考吗”，**而他给出的回应不是一个答案，是一次换题**：他说这个问题太没意义，不如换成一个可以操作的问题——它能不能在一场对话里表现得像人。

七十五年过去，我们又站在同一个位置上。

“它在推理吗”这个问题，跟“它能思考吗”有同一个毛病：这两个词都没有一个所有人都同意的定义，于是这场争论永远不会有结论。

而可以操作的问题是有的，比如：

它能不能在从未见过的问题上成功？（可测）它的成功率随任务长度怎么变化？（可测）它给出的过程，跟它内部实际的计算一致到什么程度？（第 28 章那条线，可测，而且已经在测了）

这些问题不像“它在推理吗”那么大，也不那么好听。

**而它们有答案。**

图灵那次换题，是这本书里最聪明的一次动作。而它的教训，是这本书能给出的最实用的一条：

**当一个问题吵了七十五年还在原地，问题本身很可能就是那个障碍。**

---

而这一节的收尾，得落回图灵自己身上。

图灵那次换题，把“能不能思考”换成了“能不能在对话里骗过人”。

这个替换在七十五年里非常好用。

而它现在也到期了。

因为对话已经不再是一道难关了。第 26 章讲过，2022 年之后几亿人跟它说话，而大多数人清楚地知道那不是人，然后照样跟它建立了关系。

**图灵那个测试，既被通过了，又变得不重要了。**

它被通过，是因为在五分钟的闲聊里，机器早就分辨不出来了。

它不重要，是因为我们发现，“像不像人”根本不是我们真正关心的事。

我们关心的是：它靠不靠得住？它会不会骗我？它做的事是不是我要的？出了错谁负责？（这几个问题里，没有一个需要先把“智能”定义清楚。这大概正是它们能被回答的原因。）

这些问题，图灵那个测试一个也答不了。

所以这本书写到第二十九章，可以对模仿游戏做一次告别：

**它在 1950 年是一次非常聪明的换题，而在 2020 年代，它自己也成了那个需要被换掉的问题。**

---

这一章讲的模型会想了。

而“会想”离“有用”还差着一段，这段距离的名字叫做事。

一道数学题，题面是给定的，答案是一个式子，中间不需要碰任何东西。

而现实里的事情不是这样。

你要它帮你把一件事办完，它得去查资料，得打开文件，得运行程序，得看到结果不对再回头改，得在中间做几十个小决定，而且得知道什么时候该停下来问你一句。

**它需要手。**

而“手”这个词在这本书里是有来历的。

第 18 章那条强化学习的线，讲的从来就不只是学习，是行动——桑代克那只猫要拉绳子，TD-Gammon 要落子，DQN 要按手柄（第 18、20 章）。

那条线在语言模型这里断了很久。

因为一个只会生成文字的东西，没有可以拉的绳子。

**而下一章讲的，就是有人把绳子接了上去。**

四

# 全书概况

## 规模

| 部分 | 篇数 | 字数（实测） | 目标 |
|---|---|---|---|
| 序章 | 1 | 4,380 | 4,000 |
| 第一 · 寓言 | 5 | 46,806 | 47,000 |
| 第二 · 计算 | 7 | 72,267 | 70,000 |
| 第三 · 网络 | 8 | 70,322 | 79,000 |
| 第四 · 注意力 | 5 | 44,632 | 52,000 |
| 第五 · 涌现 | 6 | 57,679 | 64,000 |
| 终章 | 1 | 4,733 | 5,000 |
| **合计** | **33** | **300,819** | **320,000** |

字数口径：正文净字数——去掉 frontmatter、注释、Markdown 记号与全部空白后的字符数。提纲、细纲与人物谱、时间线另计约 5 万字，不在内。

## 完成度

- **初稿全部完成**：33 篇（序章 + 31 章 + 终章），已过一轮逐章事实核查与一轮文风打磨，第 1 – 17 章另过一轮逐章精校。
- **事实核查**：全书标出 686 条须回到一手来源的事实，已清 684 条（99.7%）。余 2 条： 1 条是第 29 章一处反方意见的出处（按争论纪律，补不出也不删）；1 条是终章的定稿日，只能等定稿。
- **篇幅纪律**：每章 8 000 – 12 000 字、3 – 5 节；第 11 章 12,180 字略超上限（补的都是真内容，未压缩）。

## 配套材料

- **人物谱**：193 人，含译名、原名、生卒年、一句速写与出场章；译名全书唯一。在世者只给生年；查不到的写「未见记载」，不倒推。
- **时间线**：252 条编年条目，与正文互校——叙事按范式分期而时间线按年排，两者对不上的地方正是需要「此刻另一条线」过渡段的地方。
- **参考资料**：分层书目与一手文献清单，每章引用的日期、数字、引文可回溯。

- **全稿**：三十三篇随时可以提供，另有单文件 HTML 阅读稿（含目录、订正框与全书人物谱、时间线）。

## 对标与差异

- **对标**：曹天元《上帝掷骰子吗》、吴军《浪潮之巅》；英文可比 Melanie Mitchell《AI 3.0》、Cade Metz《Genius Makers》。
- **差异**：前者多为通史或群像，本书把「较真」做成了体例——「订正」区块与全书的存疑标注是可以直接展示给读者的东西； 第五时代六章写到 2026 年夏，是同类书里离当下最近的一段。

## 排版前待定

- **引号体例**：正文现为直引号，排版前统一为弯引号或直角引号（本试读本已在渲染时临时转为弯引号，源稿未动）。
- **引文注释体例**：全书引文目前只在行文里交代出处，定体例时一并统一。
- **时效表述**：终章「本书写到 2026 年年中」须在定稿时换成实际日期，全书 42 处时效句已列清单、分三档，照单一次做完。