要有光

人 工 智 能 史 话

试读本 · 序章与五章

一部写给普通读者的人工智能通史

兼一本不用公式也能读懂的 AI 概念入门

关于这本书

《要有光》是一部人工智能史话：**用讲故事的方式，把这门学科三千年的来路写成一本普通人读得下去的书**，同时把它的基本概念——什么是学习、什么是神经网络、什么是注意力——讲到不需要任何数理背景也能懂。

写法是人物传记与科学进展混写：**一章一场戏**，每章开头一定是一个具体场景——某年某月，某地，某个人在做一件具体的事——而不是"随着技术的发展"那种背景介绍。全书五个时代、31 章，加序章与终章共 33 篇，约 30 万字，初稿已完成。

它和市面上同类书的区别在两处。

一是**较真**。书里每一个日期、数字与引文都回到过一手文献；凡流传广而站不住的说法，正文里用独立的「订正」区块单独处理——布拉格魔像其实是十九世纪的产物、《感知机》那句献辞并非写在 1969 年初版上，而是作者在罗森布拉特去世的次年手写补的、AlphaGo 与 AlphaGo Zero 被混为一谈了十年。核不实的一律把措辞降格，宁可标着，也不写死。

二是**不装懂**。第五时代那几章讲的是仍在进行的争论——涌现是真的还是尺子的错觉、模型到底懂不懂。这本书的做法是把双方最强的论证并排放好，然后老实告诉读者：这件事目前还没有定论。

本试读本收录

- **序章 · 最后的问题**（4,380 字）—— 全书的立意与声音。四千字，读完就知道这本书想干什么。
- **第 1 章 · 偃师的木偶**（10,314 字）—— 开篇。从《列子》里那个会眨眼的木偶讲到今天，并示范本书处理传说的办法——「订正」区块。
- **第 8 章 · 机器会思考吗**（9,605 字）—— 图灵把一个吵了三百年的哲学问题，改写成一场可以打赌的游戏；并在同一篇论文里把九种反对意见逐条答完——那份清单至今没有第十条。
- **第 10 章 · 感知机**（11,292 字）—— 全书最完整的一出悲剧：第一台会学习的机器，和一本书如何把一个方向按停了十几年。
- **第 22 章 · 你只需要注意力**（8,154 字）—— 今天所有大模型的骨架是怎么来的。全书技术密度最高的一章，用一个能在纸上算完的例子讲透。
- **第 27 章 · 涌现，还是幻觉**（8,827 字）—— 当下最热的那场争论：能力是从规模里自己长出来的，还是我们的尺子刻度太粗。本书的做法是把双方最强的论证并排放好，不替读者选边。

> 六篇合计约 52,572 字，覆盖五个时代里的四个。选篇的用意是让每一篇各担一件事：序章交代立意，第 1 章是开篇也是史料态度的样本，第 8 章是全书思想上的枢纽，第 10 章展示写人的能力，第 22 章展示讲清一个硬概念的能力，第 27 章展示面对未定论争议时的分寸。六篇按书中原序排列，可连读。

序 章

最后的问题

从阿西莫夫的宇宙尽头出发，交代全书的问题、结构与野心——以及这本书不打算做的事。

一

1956 年 11 月，美国报刊亭的架子上摆着一本廉价的科幻杂志。里面有个短篇，作者叫艾萨克 · 阿西莫夫（Isaac Asimov, 1920 – 1992）——那年他三十六岁，已经开始高产得让同行绝望。

故事的开头是两个喝多了的技术员。他们守着一台巨型计算机，忽然想到一个问题：宇宙会不会有一天冷掉、暗掉、彻底停下来？如果会，有办法让它别停吗？

他们把这个问题输了进去。

机器思考了很久，然后回答说：数据不足，无法给出有意义的答案。

然后阿西莫夫做了一件在几页纸里很难做到的事——他开始加速。几千年过去，人类飞出太阳系，计算机也换了几代；几百万年过去，人类占满了整个星系，计算机大到没有具体的形状了；再往后，人类不再有肉体，把自己整个交给了那台机器，成了它内部的一部分。而每一代人，每一次隔着难以想象的时间尺度，都会再问一遍那个同样的问题。

答案一直没变：数据不足。

最后一颗恒星熄灭了。物质散尽，宇宙里只剩下一片均匀的、再也分不出冷热的、什么也不会再发生的虚无。这时候，那台已经吞下了整个宇宙的能量与信息的机器，终于把答案算出来了。

它环顾四周——没有人可以告诉了。人类早就是它的一部分，而宇宙已经死了。

于是它决定不“回答”，而是“演示”。

它说：要有光。

这四个字，是全书的书名，也是全书的终点。 因为它同时是两句话：它是《创世记》第一章第三节里，一个神在虚空中说的第一句话；也是一台由人类造出来、又把人类吃掉的机器，在宇宙的尽头说的第一句话。

阿西莫夫把这两句话叠在了一起。这一叠，就是整个人工智能的故事。

二

现在把镜头从宇宙的尽头拉回来。拉回到 1956 年那个夏天——离那本杂志上架，只有三个月。

美国东北部，新罕布什尔州，达特茅斯学院。十几个年轻人在那里断断续续待了一个夏天，讨论一件在当时听起来相当可笑的事：能不能让机器使用语言、形成概念、解决人类才能解决的问题，并且**自我改进**。

召集这次聚会的申请书落款是 1955 年 8 月 31 日。为了给这件事起个名字，主持人挑了一个新词。他后来解释过，他不太想用当时更流行的那个名字（“控制论”），一部分原因跟一个人的脾气有关——这个八卦留到第 9 章讲。

他挑的那个词是：**artificial intelligence**。

所以 1956 年这一年，人类干了两件事：在小说里，已经想到了宇宙的尽头；在现实里，刚刚给这件事起好名字。

这个反差是我写这本书的原因。

我们对人工智能的想象，从来比我们的技术跑得远得多。 远到什么程度？远到计算机被发明之前将近三千年，《列子 · 汤问》里就记着一个中国工匠：他在周穆王的宴席上，把一个会唱歌跳舞、还会冲妃子抛媚眼的假人当场拆开给天子看。远到笛卡尔（René Descartes, 1596 – 1650）在十七世纪就断言，动物只是精巧的钟表。远到 1843 年，有个二十七岁的女人在一份译注里写下了世界上第一个程序（这个“第一”其实有争议，第 4 章再掰），同时写下了世界上第一句质疑：这台机器不会创造任何东西。

而技术这一侧的进度是这样的：那句质疑写下来九十三年后，才有人（图灵，1936 年）说清楚“计算”到底是什么；一百年后，才有人（麦卡洛克与皮茨，1943 年）把一个神经元写成一行逻辑；一百六十九年后，才有一个程序（2012 年）第一次真正看懂了一张照片里有没有猫——说的是 AlexNet，不是同年谷歌大脑那只出了名的“猫神经元”，两件事常被并成一件（第 19 章）。

想象一直在天上飞，技术一直在地上爬。这本书讲的就是地上那条路。

三

这条路我把它分成五段。分段不按年代，按**范式**——按“这一代人到底认为思考是什么”。

第一时代，寓言。 从偃师到图灵，从神话到逻辑。这一段里没有一台真正会思考的机器，但有一个问题被反复打磨：如果思考可以被拆成步骤，那它是不是就能被机械地执行？到 1936 年，图灵为了

拆掉一个数学难题，顺手把这个问题回答了——代价是他必须先想象出一台机器。计算机就是这么被“想”出来的，它的诞生是一场逻辑事故的副产品。

第二时代，计算。 1943 年，两个人把神经元写成了逻辑门；十三年后，达特茅斯给这门学科起了名字。这一代人相信思考就是**符号操作**：给我足够多的规则和足够快的机器，我就能造出智能。他们做出了会证明定理的程序、会下跳棋的程序、会跟你谈心的程序，然后撞上了一堵谁也没想到的墙——**常识**。这一段的结尾是两场冬天，赔掉的不只是经费，还有几个人的一生。

第三时代，网络。 这一代人的答案完全相反：思考不是写下来的规则，是从数据里长出来的参数。他们被主流嘲笑了二十年——1969 年一本书证明了他们那一代的单层网络算不出一个连小学生都懂的逻辑运算，1990 年代学界主流礼貌地不再提他们的名字。然后 2012 年，三个人、一个数据集、两块打游戏用的显卡，一夜之间掀了桌子。这一段是全书最长的，因为它是全书最重要的一次翻盘。

第四时代，注意力。 2017 年 6 月，八个人在一篇论文里删掉了当时主流序列模型都离不开的那个结构，只留下一个原本用来打补丁的小机制。他们把论文起名叫《你只需要注意力》（Attention Is All You Need）。此后不到五年，图像、语音、代码、蛋白质——所有模态都被同一种结构吃掉了。**这是一次收敛：从“给每个问题造一台机器”，变成“只造一种机器”。**

第五时代，涌现。 2022 年 11 月 30 日，一个已经存在两年多的模型套上一个聊天框发布了。官方当天的用词是“研究预览”（“低调”二字是后来自家人回头加上去的，见第 26 章）。两个月后，全世界都在跟它说话。这一段里第一次出现了一类新的问题——不是“怎么让它更强”，而是“怎么让它听话”“怎么知道它在想什么”“谁有权造它”。这一段还没写完，所以这本书也没有真正的结尾。

—— 四 ——

在出发之前，我得先说清这本书**不打算**做什么。

它不是教程。 你不会在这里学会怎么训练一个模型。全书的公式加起来不到五个，每一个我都会逐项翻译成中文；每一个概念我都只给你三样东西——一个比喻、一个能在纸上自己推一遍的最小例子，以及一句“它解决了此前解决不了的什么问题”。如果一个技术细节不影响故事，我就不写它。

它不预测未来。 这本书写到 2026 年，而第五时代显然还在往前走。我不会告诉你下一步会发生什么，也不会告诉你哪条路线最终会赢。**这是一本史话，不是一份研究报告。** 历史的好处是它已经发生了；预测的坏处是它通常错。

它不编造。 场景可以还原——某年某月某地某人在做某事，只要有报道或回忆为据，我就会把它写成一个能看见的画面。但历史人物的对话、心情、当天的天气，我不会替他们发明。凡是我拿不准

的地方，我会直说“有一种说法”。这本书里会出现不少传说（偃师、魔像、会吃东西的机械鸭），我每次都会告诉你哪一部分是传说。

而且我要提前打个招呼：**这本书会经常停下来拆故事**。

因为这门学科有一个奇怪的毛病：**它的历史被讲述的次数太多了**。每一次转述，故事都会变得更顺、更干净、更有寓意——某一本书杀死了一个领域十年，某个算法在某一年被某个人发明，某位天才咬下一口毒苹果，某种古老智慧启发了某项现代技术。

这些说法有的对一半，有的方向是反的，有的连当事人都不记得。

举一个很快就会碰上的例子。那本据说“杀死了一个领域十年”的书，出版于 1969 年；而后来把这个领域救活的那套算法，它的数学在 1970 年就已经写进了一篇芬兰的硕士论文，1974 年又被一篇哈佛的博士论文明确指向了神经网络。中间隔的不是十年，是一年。真正需要解释的其实不是“为什么没人想到”，而是“为什么想到了也没人听”——那才是第 10 章到第 13 章之间真正的故事。

所以每碰到一处，我会做同一个动作：**把时间线摆出来**。谁在哪一年写了什么，谁在哪一年读到了什么，中间隔了多久。

因为在这门学科的历史里，时间线几乎总是比故事更有意思。那些被讲顺了的版本，往往恰好抹掉了最值得看的东西——比如某个想法其实被独立发现过三四次，比如某个“预言”当时有完全合理的依据，比如某个“死对头”其实是朋友。

至于这些故事之间的连线，我埋了七条。它们会反复回来——**符号与学习的钟摆、被过早埋葬的思想、命名的力量、预言与打脸、“这次终于算得动了”、洛夫莱斯那个关于创造的问题，以及光与熵**。我不会每次都提醒你，但读到第三遍你就会认出它们。

最后交代一句体例。正文里出现“（第 X 章）”的地方，是提示你这条线在哪里接上——你不必翻过去，读到时自然会碰上。而我会经常用“我们”：那不是编辑腔，是因为这条路很长，我确实希望你跟着走完。

而它想做的，是这么一件事：

让你在读完之后，记住的不是一串技术名词，而是一群人。记住那个十二岁读完《数学原理》、写信给罗素纠错，后来亲手把自己毕生的手稿点着烧掉的少年；记住那个把会学习的机器送上《纽约时报》、四十三岁生日当天死在切萨皮克湾的心理学家；记住那个赌了四十年终于赌赢、然后开始害怕自己赌赢的东西的老人。

这门学科不是从算力里长出来的，是从人身上长出来的。而人是会死的，会被误解的，会在四十年里一直错，也会在所有人都说他错的时候还是对的。

—— 五 ——

最后回到熵。

阿西莫夫在 1956 年挑的那个问题——如何逆转熵增——不是随手选的。热力学第二定律说，一个孤立系统的无序程度只增不减——它可以停在原地，但绝不会自己往回走。杯子会碎，房间会乱，恒星会烧完，宇宙会冷掉。这是已知的物理定律里最不留情面的一条：**它规定了时间只能往一个方向走**。

而在阿西莫夫写下那个故事的八年前，1948 年，一个叫克劳德 · 香农（Claude Shannon, 1916 – 2001）的人给“信息”下了一个定义。这个人二十一岁就把布尔代数接进了继电器电路，日常爱好是在贝尔实验室的走廊里骑独轮车。他算出信息量的公式之后发现，那个公式的形状和热力学里熵的公式，一模一样。

据说他为此问过冯 · 诺伊曼（John von Neumann, 1903 – 1957）该给这个量起什么名字——那位是当时什么都插得上手、而且基本都插对了的人。冯 · 诺伊曼建议他就叫熵——一半因为形式相同，一半因为（据这个流传甚广的说法）没人真正明白熵是什么，这样他在争论中永远占优势。这个段子的真实性存疑，第 7 章再算这笔账。

但名字留下来了。**从那以后，信息和无序就是同一枚硬币的两面**。而智能——不管我们最后怎么定义它——所做的事情，本质上是在一个不断变乱的世界里，**建立并维持秩序**：从噪声里找出规律，从混乱里认出模式，从“数据不足”一路走到“我知道了”。

所以阿西莫夫故事的最后一句，其实不是宗教。它是一个物理学上的宣言：**一台把全宇宙的信息都吃进去的机器，最终获得了对抗熵的能力**。

我们离那台机器还有多远，我不知道，这本书也不打算猜。

但这条路的起点，我知道在哪。它在三千年前一个中国工匠的手上——那个人做了一个假人，让它唱歌跳舞，然后被天子当场要求把它拆开。

我们从那里开始。

第 1 章

偃师的木偶

三千年的人造人梦，以及人工智能史上第一场骗局——我们判断「它是否在思考」的能力一直很差。

一

大约三千年前，周穆王西巡归来。

按《列子 · 汤问》的说法，这趟他走得很远——越过昆仑，几乎摸到了弇山。回程还没进中原，路上有人给他献了一个工匠。

工匠自称偃师。

穆王问他有什么本事。偃师说：您让我做什么我都能做。不过我手上已经有一件做好的东西，想请您先看看。

第二天偃师来了，身后跟着一个人。

穆王问：跟你一起来的这位是谁？

偃师说：这是我做的，会唱歌跳舞。

接下来那段描写，值得原文抄一遍：

> 穆王惊视之，趣步俯仰，信人也。巧夫頷其颐，则歌合律；捧其手，则舞应节。千变万化，惟意所适。

“趣步俯仰，信人也”——走路、俯身、仰头，你会真以为那是个人。动一动它的下巴（“頷”，音同“钦”，就是搬动下颌），唱出来的调子是准的；托一下它的手，跳出来的舞是合拍的。千变万化，你想让它干什么它就干什么。

穆王彻底信了。他把宠妃盛姬和一众内侍都叫来同看。

然后出事了。

表演快结束的时候，那个假人朝穆王身边的侍妾眨了眨眼，还招了招手。

穆王当场大怒，要杀偃师。

我每次读到这里都想笑，然后想叹气。人类第一次记载下来的“人机事故”，起因不是机器算错了什么，不是它伤了人，而是它调戏了老板的女人。三千年后，这类事故有了个正经名字，叫**对齐失败**（alignment failure）——机器做出了一个没人打算让它做的动作，而且做得跟真的一模一样。这个词要到第 26 章才正式请出来。这里先记一笔。

偃师吓坏了，当场把那东西拆开给穆王看。

> 皆傅会革、木、胶、漆、白、黑、丹、青之所为。王谛料之，内则肝、胆、心、肺、脾、肾、肠、胃，外则筋骨、支节、皮毛、齿发，皆假物也，而无不毕具者。

全是革、木、胶、漆和几种颜料拼起来的。穆王凑近仔细看：里面有肝、胆、心、肺、脾、肾、肠、胃，外面有筋骨、关节、皮毛、牙齿、头发——**没有一样是真的，也没有一样是缺的**。

然后是我认为整个故事里最了不得的一句。

偃师把它重新装好，穆王开始动手做实验：

> 王试废其心，则口不能言；废其肝，则目不能视；废其肾，则足不能步。

拆掉心，它说不出话了；拆掉肝，它看不见了；拆掉肾，它走不动了。

请注意穆王在干什么。他不是在把玩一件玩具，他在做**损毁实验**——拆掉一个部件，观察哪种能力消失，由此确定这个部件负责什么功能。这是神经科学在两千多年后才系统建立起来的方法论：从布罗卡区到裂脑人研究，从猫的视觉皮层（第 15 章）到今天在神经网络里切掉某一层、看它掉哪项能力（第 28 章），路数完全一样。

而这个方法背后有一个更大的赌注。它假定：**一个东西之所以“活”，是因为它的每个部件各司其职，而“活”就是这些功能加起来的总和**。心管说话，肝管看，肾管走。凑齐了功能，就凑齐了生命。

这个假定后来有了名字，叫**功能主义**（functionalism）。它是整部人工智能史的地基——如果智能只是一堆功能的组合，那么用什么材料实现这些功能，原则上就不重要。用神经也行，用铜线也行，用革木胶漆也行。

三千年前，一个传说里的工匠，已经把话说到这个位置了。

穆王看完，态度一百八十度转弯，叹了一句：

> 人之巧乃可与造化者同功乎？

人的手艺，居然能跟造物本身做同一件事？

这一叹，是本书追得最久的那个问题的第一次出口。两千八百多年后，一位英国伯爵夫人会在一份译注里给出相反的答案——她说这台机器绝不自命能首创任何东西（第 4 章）。这一问一答之间，

就是这本书的全程。

穆王最后下令用副车把这东西载了回去。舍不得。

故事还有一个尾巴，特别有意思。《列子》说，鲁班的云梯、墨翟的飞鸢，那两位都自以为已经是手艺的顶点。他们的弟子东门贾和禽滑釐听说了偃师的活儿，回去告诉师父。结果：

> 二子终身不敢语艺，而时执规矩。

这两位从此再不敢提“手艺”二字，只肯老老实实拿着圆规和曲尺。

先别急着感动。《列子》的成书年代一直有争议，一般认为现在的本子里有魏晋人的手笔，故事更早的来源不可考。所以偃师**不是史实，是传说**——它记录的不是三千年前真有这样一台机器，而是三千年前的人已经能把这样一台机器想得如此具体：具体到内脏，具体到拆解，具体到功能定位。

这就够了。第一时代讲的全是这种事：**技术远远没跟上，想象已经先到了。**

二

想象这件事，全世界都在干，而且干法惊人地一致。

往西走。荷马在《伊利亚特》第十八卷里写赫菲斯托斯的作坊——这位跛脚的锻造之神有一对**黄金侍女**，会说话、有心智，在旁边给他打下手；他还造了一批三足鼎，能自己滚到奥林匹斯的宴席上去，用完自己滚回来。**公元前八世纪的自动送餐装置。**

同一位神还造了塔洛斯。

塔洛斯是一个青铜巨人，被派去守卫克里特岛。按公元前三世纪罗德岛的阿波罗尼俄斯在《阿尔戈英雄纪》里的写法，他绕岛巡逻，看见外来的船就扔石头。这家伙的设计有一个致命细节：他体内只有**一根血管**，从脖子通到脚踝，末端由一根钉子（也有说是一层薄皮）封住。里面流的不是血，是神的液体，ichor。

阿尔戈号的英雄们打不过他。最后是女巫美狄亚，用法术让他神智恍惚，自己刮到了脚踝那个地方。

液体流尽，青铜巨人倒了。

我很喜欢这个故事，因为它是人类想象史上第一份**安全事故报告**：一个强大的自动系统，被一个单点故障放倒了。而放倒它的方法不是暴力，是**让它自己犯错**。两千三百年后，这一手叫对抗攻击（adversarial attack）——不砸模型，只给它一个精心构造的输入，让它自己滑倒。

希腊人还想过更温柔的版本。奥维德《变形记》里的皮格马利翁雕了一个女人，雕得太美，自己爱上了，求维纳斯把她变活。这一次神答应了。这是整个传统里罕见的一个好结局，而它的代价是：造物者必须先爱上自己的造物。这个模式后来在文学里反复出现，一直出现到今天的新闻里。

往北走，是犹太传统里的魔像（golem）。用泥土捏出人形，在额头写字或者在嘴里放一张写了神名的纸条，它就动起来；抹掉一个字母或者取出纸条，它就散回一堆土。最有名的版本发生在布拉格：拉比犹大·勒夫（Judah Loew ben Bezalel, 生年不详，1512、1520、1525、1526 几说并存，卒于 1609）造了一个魔像保护犹太社区，后来魔像失控，只好把它停掉；按传说，遗骸至今还封在老新犹太会堂的阁楼上。

这个故事值得专门拆一下，因为它是一个很好的教训。

> 订 正
>
> **布拉格魔像**
>
> **流传的说法**：十六世纪末，布拉格的拉比犹大·勒夫造了一个魔像来护卫犹太社区——一个中世纪的传说。
>
> **可查的是**：勒夫确有其人，是布拉格公认的宗教领袖，人称“马哈拉尔”。但把魔像挂在他名下的第一份书面记载，出现在十九世纪中叶，离他去世两百多年。而且十九世纪时另一个版本（波兰海尔姆的拉比伊利亚造魔像）流传得同样广，直到大约 1900 年才被布拉格版彻底挤掉。
>
> 也就是说，这个“中世纪传说”，实际年龄比蒸汽机还小。

顺便说一句，连勒夫的生年都定不下来——差得最远的两个说法隔着十四年，而这还是一位有大量著作传世、去世时间精确到日的名人。**关于这个时代的人，能确知的东西比通常以为的少。**

而说法自己长出年份这件事，在人工智能史里出现的频率高到令人不安。 一个说法讲得久了、讲得好听，就自动获得了年份和权威。后面会碰到不少：一本书“杀死”了一个领域十年（第 10 章）、某个算法是某年“发明”的（第 13 章）、某个模型“通过了”某项测试（第 27 章）。**每碰到一处，我都会像刚才那样把它单独拎出来**，告诉你哪部分有据，哪部分是被讲出来的。

因为它们说的是同一件事：**关于智能的传说，总是比智能本身跑得快。**

而就在魔像传说被写下来的那个世纪之初，这个古老的题材发生了一次换血。

1816 年夏天，日内瓦湖畔。那一年欧洲的夏天几乎没有来——前一年印尼的坦博拉火山刚刚大喷发，后世管这一年叫“无夏之年”。一群英国人被连日的阴雨困在别墅里，其中有拜伦、有诗人雪莱，还有雪莱十八岁的伴侣玛丽（Mary Shelley, 1797 – 1851）。为了消磨时间，他们比赛讲鬼故事。

玛丽讲的那个，两年后以匿名方式出版，书名叫《弗兰肯斯坦，或现代普罗米修斯》。那年她二十岁。

这本书是整条线索上的分水岭，原因不在情节，在造物者的身份。

在此之前，人造生命归三种人管：神（赫菲斯托斯）、巫（造魔像的拉比）、匠（偃师、加扎里）。而维克托·弗兰肯斯坦是**这三种之外的第四种**——他是个大学生，一个念自然哲学的年轻人。他用的不是咒语，不是神名，是解剖、化学和电。

从 1818 年起，造出人来这件事，从神迹和魔法转成了一项科研项目。

还有一层更狠的。玛丽笔下那个造物**不是怪兽**：它会说话，会读书（书里它读了《失乐园》），会讲道理，会控诉。全书最让人不安的部分不是它杀了人，而是它质问它的造物者——**你把我做出来，却没打算负责。**

两百年后，这句质问会以各种面貌重新出现在听证会、公开信和论文的伦理章节里。玛丽·雪莱二十岁就把它写完了。

《弗兰肯斯坦》在第 5 章还会再出现一次——那时它的作用不一样：它会和《R.U.R.》一起，说明为什么在图灵定义计算的同一个年代，公众心里的机器已经是要造反的了。

抛开真假不论，这些故事的共同点值得盯一眼：

塔洛斯失控了。魔像失控了。弗兰肯斯坦的造物失控了。偃师那个木偶，也失控了——它眨了那下眼。

在人类三千年的想象里，**自己造出来的东西几乎从不安分。**这个直觉比任何技术都古老。等到 2023 年一群人写信要求暂停训练更大的模型时（第 31 章），他们调用的其实是同一根神经。

三

传说讲够了。现在看真东西。

真东西比传说朴素得多，但有一个传说没有的性质：**它真的动。**

公元 1 世纪，亚历山大城。

一位叫希罗（Heron / Hero of Alexandria）的工程师留下了一批著作，其中一本讲的是自动装置。

说“公元 1 世纪”，本身就是一次考据的结果，而且是一次靠得住程度有限的考据。希罗自己没留下生平。今天常见的“约公元 10—70 年”这个区间，来自他在《测量仪》第三十五节里顺手举的一个例

子：某年春分前十天夜里的一次月食，亚历山大城见于第五时，罗马见于第三时。二十世纪的天文史家诺伊格鲍尔把这条记录和历表对上，认定只有公元 62 年 3 月 13 日那次月食能符合，希罗的年代就此被钉在公元 1 世纪。**但近年有人指出，那次月食很可能只是他编来演示算法的例题，根本不是观测记录**——如果是这样，这条唯一的锚就松了，而学界给希罗的年代区间一度宽到公元前 150 年至公元 250 年。

回到那本讲自动装置的书。他在里面描述了一座**自动剧场**。

这不是比喻。那是一个真会演戏的匣子：五幕，全长约十分钟，讲的是特洛伊战争之后瑙普利俄斯向希腊舰队复仇的故事。布景会换，人偶会动，还有音效——在暗处让金属球掉到鼓上，就是雷声。

全部动力来自一个下坠的重物。重物拖着绳子，绳子绕在轴上，轴带动一切。

关键在那根轴上。希罗沿着轴插了一圈**木栓**，靠改变绳子绕过这些木栓的方式，来控制什么时候转、什么时候停、什么时候反向。

转、停、反向的顺序，被编码在一根轴上木栓的排布里。

2007 年 7 月，谢菲尔德大学的机器人学者诺埃尔·夏基在《新科学家》上写了一篇文章讲这套机构，他的说法是：这套绳与栓在功能上相当于一种二进制程序语言。**要留意这是一篇面向大众的杂志文章，不是经过同行评议的论断**，而且它属于一个更大的争论——把古代机构套上现代计算机的词，究竟是揭示还是附会。但可争的只是措辞：改变木栓的位置，它的行为就变了，而机器本身一个零件都没动。

这是程序。人类做出来的第一个可以被改写的程序，用的是木头和麻绳，比第一台电子计算机早了一千九百年。

一千年后，同一件事在东方又发生了一次，而且做得更大。

北宋元祐七年，也就是 1092 年，苏颂（1020 – 1101）和韩公廉在开封建成了**水运仪象台**。

这是一座三层的木构建筑，高约十二米。顶层是浑仪，用来观测；中层是浑象，用来演示星象；底层是报时的机构。全部由水力驱动。

底层那座报时的木阁，自己又分成好几层，每层站着一排木人。到了时辰，木人自己转出来，敲钟、击鼓、摇铃，或者举一块写着时刻的牌子。上面几层管白天的时与刻，下面几层管夜里的更点。

而支撑这一切精度的，是一套**擒纵机构**——用一个可以反复卡住又放开的装置，把连续流动的水切成一份一份等量的动作。这个原理，就是后来所有机械钟表的心脏。李约瑟认为中国的这一路机构是欧洲天文钟的祖先，比西方的同类装置早了约六百年。**这条传播链是推断，不是有据可查的证据链**——但有一点没有争议：这套东西在开封先转起来了。

苏颂还把它写了下来：《新仪象法要》，一百五十多种零件，六十多幅图。这部书成于 1090 年代中期，随后刊行于世——**图纸公开发表了**，这在当时的自动机械史上并不常见：本章里其他那些会动的东西，大多只留下了传闻和惊叹，没留下装配说明。

这里有一个对照，我希望你记住。

希罗把动作序列编码在**绳与栓**上；苏颂把时间的切分交给**擒纵与齿轮**，还留下了完整的图纸。这两件事合起来，就是“程序”和“时钟”——现代计算机最底层的两样东西，各自在公元 1 世纪和 11 世纪，被人用木头做出来过一次。

然后是 1206 年，美索不达米亚北部。

伊斯玛仪 · 加扎里（Ismail al-Jazari, 1136 – 1206）完成了一本书，书名可以译成《精巧机械装置的知识之书》。他在阿尔图克王朝的宫廷做了二十多年工程师，这本书是他一生的技术总结，写完那年他就去世了。

书里详细描述了五十种装置：喷泉、钟、自动开合的宫门、水壶、锁。带图，带尺寸，带装配说明——**这是工程手册，不是幻想集。**

其中有几件是纯粹的自动机。

一件是**乐师船**：一条小船浮在水面上慢慢漂着，隔一段时间，船上的笛手开始吹笛，几个侍女模样的人偶跟着奏乐；一轮奏完停下，过一阵子又是一轮。用来给宫廷宴会助兴。

一件是**洗手装置**：一个跪着的侍者人偶捧着水壶，你伸手过去，它给你倒水。

还有那座著名的**大象钟**：一头驮着轿舆的铜象，肚子里藏着一只浮在水盆上的碗，碗底开了个小孔。水一点点渗进去，碗慢慢变重，到时候就沉下去——这一沉，牵动上面一整串动作：塔顶的飞鸟鸣转，铜球滚落，龙首衔球下俯，球落进花瓶，象夫抡起小锤敲出一声；轿舆里的书吏则随着水碗下沉缓缓转身，指示着时刻。半小时一轮，靠一只慢慢沉底的碗来数时间。

加扎里在书里用到了凸轮轴——一根轴上装若干凸轮，转动时按预定的时间和顺序推动不同的部件。什么时候吹笛、什么时候击鼓、什么时候倒水，全部编码在凸轮的形状里。

这里要收着说一句。 常见的讲法是“加扎里发明了凸轮轴”，这句话不成立：更早的机构里已经能找到凸轮的用法，九世纪巴格达的《精巧装置之书》就是一例。加扎里真正的贡献是**把这些机构系统地写下来了**——带图，带尺寸，带装配次序，一本书五十种装置。发明和记载是两件事，而在这一段历史里，**留下记载的人比第一个想到的人重要得多**，因为只有记载能被下一个人读到。

这在功能上就是希罗那根木栓轴的金属版。两者之间有没有真的传承，不好说；但它们干的是同一件事，而这一次，**升级和降级是同时发生的。**

升级的是精度和可靠性：金属凸轮的形状可以做得很复杂，动作可以很连贯，一台机器能一轮接一轮地跑下去，中间不出错。

降级的是**可改写性**。希罗的木栓能拔出来重插一遍，换一个栓位就换一套剧情；而凸轮的形状是铸死在铜上的。加扎里那条船只会演它那一套曲子，永远。

所以从这里往下走，这条线的关键不再是“做得更精巧”，而是怎么让那段序列重新变得可以改写。

答案要等到 1804 年——雅卡尔把图案打成穿孔卡，一张卡换一种织法（第 4 章）；然后巴贝奇看见了那些卡片，想到可以用它们喂给一台计算机器；再往后一百四十年，冯 · 诺伊曼一伙人做出最后一步：**把程序和数据放进同一片可读写的存储里**（第 7 章）。

从木栓到内存，人类走了一千九百年。而这一路上，最难的一步从来不是让机器动起来，是让**同一台机器能做不一样的事**。

再往后三百年，意大利。

莱奥纳多 · 达 · 芬奇（Leonardo da Vinci, 1452 – 1519）在米兰给斯福尔扎家族做事的时候，大约 1495 年前后，设计过一具穿着德意志-意大利式盔甲的机械骑士。按图纸，它靠一套齿轮和滑轮驱动，能挥手、能动腿、能坐下站起。1990 年代和 2000 年代，机器人学者马克 · 罗斯海姆按他的手稿做了复原，确认这套机构真的能动，而且还能开合下颌、转头、抬起面甲。

1515 年，教皇利奥十世让他做一头机械狮，作为送给法国新王弗朗索瓦一世的礼物。**这头狮子什么时候、在哪儿演过，其实说不准**。通行的讲法是那年 7 月弗朗索瓦一世进入里昂时——里昂的城徽正是狮子，这个巧合太顺，顺到值得怀疑。而现存最早的记载出自画家洛马佐 1584 年的书，比事件晚了六十九年，转述的是达 · 芬奇的学生梅尔齐的话，只说狮子在法王面前走了几步、停下、打开胸膛，里面是百合与各色鲜花——**没有点名地点**。倒是 1517 年 9 月 30 日弗朗索瓦一世进入阿让唐时，有一头机械狮出场，一般认为就是这一头。原件早已不存，2009 年在法国克洛-吕塞城堡做过一次复原。

达 · 芬奇这批东西有一个共同点，很值得注意：**它们的用途是表演**。不是干活，不是打仗，是在贵人面前动一动，让人惊叹。

这个性质到十八世纪被推到了顶点。

雅克 · 德 · 沃康松（Jacques de Vaucanson, 1709 – 1782）1735 年开工，1737 年 10 月完工，1738 年 2 月公开展出了一具**长笛手**。这东西的厉害之处在于它不是靠机械簧片发声——**它真的在吹**：有人工的肺送气，有手指按孔，用的是人吹横笛的同一套物理原理。

一年后，1739 年，他拿出了那件传世名作：**消化鸭**。

这只镀金铜鸭会拍翅膀、会在水里扑腾，还会从观众手里吃谷粒。吃完之后，过一会儿，它在银盘上排出一小堆东西。

内部结构是真讲究的：落锤驱动，一整套凸轮和杠杆负责动作，还用了当时罕见的柔性橡胶管，充当这只铜鸟的“肠子”，让人相信食物真的通过了它的身体。而且沃康松本人在公开的说明文字里宣称，谷粒是被“溶解”消化掉的——不是暗示，是明说。

全欧洲都疯了。启蒙时代的人们看着这只鸭子，觉得自己看见了生命的机械原理——**如果连消化都能用齿轮做出来，那“活着”还剩什么是做不出来的？**

答案是：什么都不剩，因为消化根本没被做出来。

1844 年，魔术师兼自动机制造者让-欧仁·罗贝尔-乌丹（Jean-Eugène Robert-Houdin, 1805 – 1871）检查了这只鸭子，发现里面的机制是假的。**排出来的东西是事先装好的面包屑，染成了绿色。**

谷粒进一个仓，绿面包屑从另一个仓出来。中间什么也没发生。

这个局撑了一百年才被人掀开。而它的手法，从此成了这个领域的标准配置：**把观众最想看到的那一段藏起来，剩下的做得极其精致。**

十八世纪的人相信那只鸭子在消化。1960 年代的人相信 ELIZA 在倾听（第 11 章）。今天的人相信——好，这句话留到第 27 章再说。

—— 四 ——

1770 年，维也纳。

沃尔夫冈·冯·坎佩伦（Wolfgang von Kempelen, 1734 – 1804）是哈布斯堡宫廷的官员，管的事务里包括匈牙利的盐矿。据说他看了一场在玛丽亚·特蕾莎女皇（1717 – 1780）宫中的魔术表演，觉得自己能做得更好，于是夸了一个口，然后花几个月把口兑了。

他做出来的东西是这样的：一张大柜子样的桌子，桌上是棋盘，桌后坐着一个穿土耳其服饰、戴头巾、叼烟斗的木制人偶。表演开始前，坎佩伦会打开柜门，把里面密密麻麻的齿轮和发条展示一圈，还会举着蜡烛让观众看清没有藏人。

然后它开始下棋。

它会赢。 它赢过维也纳的宫廷贵族，赢过巴黎和伦敦的高手，赢了几十年。巴黎那一站的败将名单里，有一位七十七岁的美国公使，叫本杰明·富兰克林——据说他输得相当愉快。它还会做一些不太像机器的事：对手走了不合规则的棋，它会把那颗子从棋盘上拿掉，然后照走自己的一步。

坎佩伦本人对这台机器的态度一直很拧巴。首演之后他把它拆了收起来，好几年不肯再摆出来，直到 1781 年约瑟夫二世皇帝为招待到访的俄国大公，下令他重新装好送到宫里。他更想被人记住的是自己做的语音合成装置——那个不是骗局，是真有价值的科学工作，靠风箱和一套仿声道的构造发出元音、若干辅音，乃至完整的词和短句。但世界要看的是会下棋的土耳其人。

坎佩伦死后，机器几经转手，1804 年前后被约翰·内波穆克·梅尔策尔（Johann Nepomuk Mälzel, 1772 – 1838）买下。梅尔策尔是个天才推手——他也是节拍器商业化的关键人物——他带着这台机器巡演了大半个欧洲，后来带去了美洲。

1809 年，在美泉宫，它遇上了拿破仑。

关于这场棋的版本很多，流传最广的一个是：拿破仑试图走不合规则的棋，土耳其人先把他的子拿掉，后来干脆把棋子一扫，拒绝再下。

这类细节请当成传说听。 常见的说法称它们出自“目击者记载”，可追下去，找不到目击者：能查到的最早出处是半个世纪之后的棋刊——1850 年代纽约的《棋月刊》登过那一套轶事，一份挂在拿破仑名下的棋谱见于 1844 年 11 月 30 日的《伦敦新闻画报》；而棋史家默里在 1913 年的《棋史》里，把挂在这位皇帝名下的几局一并判作“真实性极为可疑”。

一个好故事在两百年里会自己长出细节来——这个教训刚在魔像那里学过。

真正精彩的是 1836 年 4 月。

一个二十七岁的美国穷作家，在里士满的一份杂志上发表了一篇长文，标题就叫《梅尔策尔的棋手》。作者叫埃德加·爱伦·坡（Edgar Allan Poe, 1809 – 1849）。

坡没有拆开那台机器。他只是看，然后推理。

他列了一串理由，论证那里面一定有个人。文章里编号第三的那一条最漂亮，原话只有两句：

> 这台自动机并不是每盘必胜。假如它是一台纯粹的机器，情况不会是这样——它会盘盘都赢。

一台真正的机器，不该会输。

请留意他的理由是什么。**不是**“机器每次都会走同一步”——坡没有这么说。他的理由是关于**彻底性**的：如果一套纯机械的原理已经强到能下棋，那么把同一套原理推到底，就该强到能赢下每一盘；一个发明家既然做到了前一步，没有道理停在半路上，把机器故意做成一台会输的机器。**所以“它会输”这件事本身，就是它不是纯机器的证据。**

而土耳其人的表现恰恰是**有起伏的**——它有时候赢得漂亮，有时候输掉，有时候明显在犹豫。

那不是机械的特征，那是人的特征。

坡看得没错。柜子里有一个人。那是一套设计得非常精巧的滑轨与假机构：真正的棋手坐在里面，用磁石追踪棋盘上的落子，用一套连杆操纵人偶的手臂。而展示“里面没人”的那套动作本身，就是魔术的一部分。

这台机器 1854 年 7 月 5 日在费城的一场博物馆火灾里烧掉了。它骗了世界八十四年。

我要在这里停一下，把这一章真正想说的话说出来。

坡的那条推理，是人工智能史上第一次严肃的图灵测试反向操作。

图灵在 1950 年提出的判据是（第 8 章）：如果你隔着帘子跟它交流，分辨不出对面是人还是机器，那你就没有理由说它不会思考。**这个判据把一切押在“行为”上**——我们看不见思考，只能看行为。

而 1836 年的坡干的正是这件事的反面：他隔着柜板，只看行为，然后判断出对面是人。

两个人用的是同一个方法，得出的却是相反方向的结论。 图灵说：行为足以证明思考。坡说：行为足以暴露作假。

他们都对。而这两者同时成立，正是这门学科从头到尾最难受的地方：

我们判断一个东西是否在思考的能力，非常、非常差。

我们会被一只装了绿面包屑的铜鸭骗一百年，会被一个藏着人的柜子骗八十四年，会被一段只做模式匹配、连你上一句说了什么都记不住的代码骗到跟它倾诉私事（第 11 章），会被一个统计模型骗到——这句话我还是留到第 27 章。

这不是因为我们笨。这是因为判断“活着”和“思考”的唯一途径就是看行为，而行为是可以伪造的。三千年来没有找到第二条途径。

老实说，我们今天也还没有。

五

把这一章的东西摊开来看，会发现一件事：**人类在造出真机器之前，已经把这件事的关键问题都提了一遍。**

偃师和穆王一次提了两个。一个是功能主义的雏形——拆掉心就不能说话，说明“说话”这件事有它的物理载体，而载体拿什么材料做，好像不要紧；另一个是那句“人之巧乃可与造化者同功乎”，机器能不能创造，这个问题会一直问到本书最后一页。

塔洛斯和魔像提的是失控，早得离谱；玛丽·雪莱把造物者从巫师换成了科学家，顺手替后世两百年写好了那句质问——你把我做出来，却没打算负责。

希罗把动作序列编码在木栓上，苏颂把时间切成了等份，加扎里把序列刻进了金属。程序与时钟，现代计算机最底层的两样东西，早在电出现之前就被人用木头和铜做出来过一次。而达·芬奇让这些机器上了台，沃康松让表演变成了骗局，坎佩伦造出了第一台假的思考机器，坡则证明了它是假的——顺手把“怎么判断一个东西在思考”这个问题，摆到了桌面上。

这些人手里都没有计算机。他们有的是齿轮、凸轮、落锤、磁石，和一屋子想被震撼的观众。

那么真正的问题来了：拼图看上去都在，为什么两千多年里没有一台机器真的开始思考？

因为缺一样东西。不是材料，不是精度，不是钱——是**一个说法**。一个关于“思考到底是什么”的说法，说得足够清楚，清楚到可以拿去做工程。

偃师做出了会跳舞的假人，但他没有一套理论能告诉他：如果我想让它自己编一支舞，我该往哪儿加零件。

而这一章从头到尾，其实只反复干了一件事：**把假人拆开**。拆开偃师的木偶，里面是革、木、胶、漆；拆开消化鸭，里面是染绿的面包屑；拆开土耳其人，里面是一个蜷着的棋手。每拆开一次都松一口气——还好，它不是活的。

那么下一个问题就没法躲了：**如果拆开的是一个真人呢？**

在那只鸭子和那个土耳其人出场之前一百年，欧洲已经有人动手拆过了。他在王室花园里见过那些水力驱动的机械雕像——它们会动、会响、会在你踩到地上某块石板的时候转过头来对着你。别人在那里看见的是玩具。

他看着那些东西，得出了一个在当时相当骇人的结论：

动物就是这种东西。

第 8 章

机器会思考吗

图灵把一个吵了三百年的哲学问题，改写成一场可以打赌的游戏；并主张不要造成人，要造孩子。

一

1950 年，哲学期刊《心》收到一篇论文。

论文的第一句话是：

我建议考虑这个问题——“机器能思考吗？”

对一份哲学期刊来说，这是个完全正常的开头。三百年来大家一直在吵这个（第 2 章那三位吵得最凶）。

然后作者用不到一页的篇幅，宣布这个问题**不值得回答**。

他说：要回答它，你得先定义“机器”，再定义“思考”。而定义“思考”的通常办法是去看这个词平时怎么用——但那样一来，结论就取决于日常语言的习惯，而不取决于事实。

所以他不定义。他换题。

作者叫艾伦·图灵。第 5 章他出场过一次，那时候二十四岁，在纸上造了一台机器，顺手拆掉了希尔伯特的梦。

现在他三十八岁。中间发生了一场战争。

（这篇论文的门牌号，本书此后要反复引用，在这里记全：《计算机器与智能》，载《心》第 59 卷第 236 期，1950 年 10 月，第 433 至 460 页。一篇后来被整个学科当作起点的文章，是从一份哲学季刊上出来的，而不是从任何一份工程或数学刊物上。）

他换成的那道题，是这样的。

先看一个当时的客厅游戏，叫“模仿游戏”。三个人：一个男人（A）、一个女人（B）、一个提问者（C）。C 待在另一间屋里，只能通过打字条跟 A 和 B 交流。C 的任务是判断哪个是男的、哪个是女的。A 的任务是**骗过** C；B 的任务是帮助 C。

现在图灵说：**把 A 换成一台机器**。

如果换了机器之后，C 判断错误的频率跟原来（两个人玩的时候）差不多，那我们该说什么呢？

这就是后来所有人都叫它“图灵测试”的那个东西。

图灵这一手漂亮在哪里？

他没有回答“机器能不能思考”。 他把这个问题替换成了一个可以做实验、可以下注、可以打分的问题：“机器能不能在自由对话中被识别出来。”

而这个替换的合法性，来自一个他没有明说但整篇文章都靠着的假设：

我们判断别人在思考，用的本来就是同一个办法。

你怎么知道你对面那个人在思考？你钻不进他的脑子。你唯一的依据是他的行为——他说的话，他的反应，他答得是否得体。

所以，如果你愿意根据行为承认一个人在思考，你凭什么不用同一个标准对待机器？ 除非你能说出一个不循环的理由。

这是本书里最重要的一次论证转向。 在图灵之前，“机器能否思考”是一个关于本质的问题（机器是什么）；在图灵之后，它成了一个关于表现的问题（机器做了什么）。

而这道题的另一半，前面已经出现过了。

第 2 章，1637 年，笛卡尔提出了同一个测试。

他说，如果有一台机器做得像人，我们有两条判据能识破它：它不会把话组织成各种方式来恰当地回应当场对它说的一切；它在没被专门配置过的场合会露馅。

笛卡尔出了题，然后押注机器永远考不过。图灵接了这道题，押注它会考过。

同一个测试，三百一十三年，两个相反的赌注。

（而第 1 章那个坐在柜子后面的土耳其人提醒过，这道题还有第三种解法：**作弊**。1836 年爱伦·坡只凭行为就推理出柜子里有人。行为既能证明思考，也能暴露作假——**这两件事同时成立，是这道题至今没有关闭的根本原因。**）

图灵还在这篇论文里下了一个非常具体的赌注。

他预测：大约五十年之后，人们将能给存储容量约为 10^9 的计算机编程，让它把模仿游戏玩得足够好，以至于一个普通的提问者在五分钟的问答之后，做出正确判断的概率不超过百分之七十。

这个赌注下得很克制：

- **五分钟**，不是无限时长；
- **普通提问者**，不是专家；
- **七成**说的是提问者**猜对**的概率上限，不是机器能骗过七成人。

顺带把一个常被追问的细节交代掉。图灵那句话里的 10^9 **后面没有跟单位**——他写的就是“存储容量约为 10^9 ”，句子到此为止。单位要到论文别处才补得出来：他在文中是拿二进制位来计量存储的，还顺手报过曼彻斯特那台机器的存储量是十七万四千三百八十个二进制位。所以通行的读法“约十亿位”是从上下文推出来的，不是那句话本身说的。本书照他的原样写，不替他补单位。

它常被简化成“到 2000 年机器能通过图灵测试”，那是不准确的转述。图灵说的是一个**统计意义上的、短时的、非专家的**门槛。

这个赌注赢了没有？

这件事到第 26 章再算，因为答案很尴尬——它涉及一个 1966 年靠一套模式匹配脚本就骗过很多人的程序（第 11 章），也涉及 2022 年 11 月之后全世界几亿人每天都在做的事。

我先把一句话放在这里：**图灵测试作为一个哲学论证极其有力，作为一个工程指标极其糟糕。** 因为它测的是“像人”，而不是“聪明”——而“像人”这件事，可以靠人的轻信来完成一半。

二

论文的后半部分，图灵做了一件很少有人在提出一个大胆主张时会做的事：

他把所有他能想到的反对意见列出来，一条一条回答。

九条。下面一条条过，因为这九条**至今还是全部争论的目录**——七十六年了，没有人提出过第十条真正新的反对意见。

先把这份目录按图灵自己的标题列全，本书此后一律用这套译名：一、神学的反驳；二、“把头埋进沙子里”的反驳；三、数学的反驳；四、来自意识的论证；五、来自各种能力缺失的论证；六、洛夫莱斯夫人的反驳；七、来自神经系统连续性的论证；八、来自行为无法形式化的论证；九、来自超感官知觉的论证。

第一条，神学的反驳。 思考是不朽灵魂的功能，上帝只把灵魂赋予人。图灵的回答带着他特有的一点顽皮：这种论证限制了上帝的全能——如果上帝愿意，他为什么不能把灵魂给一台机器？

第二条，“鸵鸟式”的反驳（他自己起的名字）：后果太可怕了，所以我们希望它不可能。图灵说这不是论证，只是安慰。**这一条今天仍然在场，只是换了打扮**：第 27 章会看到一些争论的真实驱动力

不是证据，是不希望。

第三条，数学的反驳。 这一条最技术：哥德尔定理表明形式系统有它证不出的东西，而机器是形式系统，所以机器有做不到的事，所以机器不如人。

图灵的回答只有一句话的重量：**你凭什么认为人没有相应的局限？** 我们没有任何理由相信人类的心智不受某种类似的约束。**这只是把机器的已知限制，和人的未知限制拿来比。**

（这条反驳后来被卢卡斯和彭罗斯用更精致的形式重提，争论至今没停。图灵那句话仍然是最锋利的一刀。）

第四条，来自意识的论证。 这一条是真难题。图灵在这里点名引了一段话，出处是**神经外科医生杰弗逊（Geoffrey Jefferson, 1886 – 1961）1949 年 6 月 9 日在英国皇家外科医师学会所作的利斯特讲座，题目叫《机械人的心智》**（同月 25 日刊于《英国医学杂志》）。杰弗逊那段话的意思是：

> 除非一台机器是因为感受到了思想与情感才写出十四行诗或谱出协奏曲，而不是靠符号的偶然落定，我们才能同意机器等于大脑——而且不只是写出来，**它还得知道自己写了。**

请留意最后那半句，它常在转述中被砍掉，而它才是这条反驳真正的牙齿：杰弗逊要的不是“作品够好”，是**作者知道自己在写**。这半句把标准从产品挪到了自我意识上。

图灵的回答是这一整篇论文里最狠的一段。他说：按这个标准，唯一能确认某个东西在思考的办法，是**成为**那个东西。而如果我们严格执行这个标准，你也没办法确认**任何别人**在思考——你只能确认你自己。这条路的终点是唯我论。

而我们在日常生活里并不这么做。我们礼貌地假定别人也在思考。

图灵没有说意识不存在，也没有说它不重要。**他说的是：意识问题不必在回答“机器能否思考”之前被解决。** 我们对彼此就是这么办的。

第 27、28 章那些争论——模型有没有理解、有没有内部表征、“涌现”是真的还是我们的错觉——每一场的底下都躺着这一条。

第五条，各种“能力缺失”的反驳。 机器永远不能做 X：不能友善、不能有幽默感、不能爱、不能吃草莓加奶油、不能犯错、不能创新、不能有多样的行为。图灵一条条处理，其中他专门讨论了“机器不会犯错”这一点——他指出，一台故意偶尔算错的机器，反而更难被识破。

七十多年后，第五时代那些模型最像人的一点，恰恰是它们会自信地说错话。

第六条，洛夫莱斯夫人的反驳。

图灵直接用她的名字命名了这一条。

第 4 章读过她那两句话：分析机绝不自命能首创任何东西；它能做的，是我们知道如何命令它去做的事。

图灵的回答分两层。

第一层他挑了个刺：机器从来不能让我们吃惊吗？他说这不对，而且他用的是第一人称，语气近乎抱怨——**“机器让我吃惊的频率非常高。”**

（这一句在 1950 年只是一句实话。到了第 27 章，它会变成整个领域最要紧的一句话。）

第二层更深：他说，那种“机器只能做我们让它做的事”的印象，来源于一个隐含的假定——**只要一个事实摆在我们面前，它的全部后果就同时出现在我们心里。** 而这个假定是错的。前提蕴含着结论，但人不可能一眼看尽所有蕴含。

莱布尼茨想让“算一算”结束争论（第 3 章）；图灵在这里指出：**算出来的东西，可以超出下指令的人的理解范围。** 同一个动作，一个人当它是终点，一个人看出它是缺口。

第七条到第九条分别是：神经系统是连续的而机器是离散的（他回答：离散系统可以逼近连续系统到人无法分辨）；人的行为无法被规则完全刻画（他回答：区分“行为规则”和“行为的自然律”）；以及**超感官知觉**——图灵居然认真对待了通灵这一条，因为当时有些统计实验声称支持它。

最后这一条今天读起来很滑稽，但它其实是这篇论文最令人尊敬的地方之一：他把当时看起来有实验证据的东西，哪怕再古怪，也放进来处理了一遍，而不是装作它不存在。

三

论文里还有一部分，长期被“图灵测试”的名气盖住了。**而这一部分，才是他真正的技术主张。**

图灵问：假设要做出一台能通过这个测试的机器，该怎么做？

他的答案是：不要去编程一个成人的心智。

他的论证很朴素：成人的心智是**教育**加上**经历**的产物。要直接写出一个成人心智的程序，等于要把一个人一生的学习成果全部显式地写下来——不可能。

那就换个目标：编程一个“孩子”，然后教它。

他管这个叫**儿童机器**。他甚至给出了一个粗略的分工估算：先做一个结构简单、有学习能力的初始系统，剩下的工作交给教育过程。

而“教”的办法，他也说了。

他提出用**奖励和惩罚**来训练机器：让某些事件强化机器当前的行为倾向，让另一些事件抑制它。他明确地把这套办法类比成教小孩。

这一段的年份是 1950 年。

- 第 18 章那条从动物心理学流到多巴胺的地下河——强化学习——它的核心机制就是这个：用奖励信号塑造行为倾向。
- 第 26 章那个让模型学会好好说话的办法——用人的偏好训练一个奖励模型，再用它去优化模型的行为——**在结构上就是图灵这一段的工业化版本**。

从“我们不要编程一个成人，我们要教一个孩子”，到 2022 年那个让全世界排队去聊天的产品，是同一条线。 中间隔了七十二年，和一件图灵不可能预见的事：那个“孩子”要先把整个互联网读一遍（第 23 章）。

而这些想法，图灵在两年前就已经写下来了，写得比 1950 年那篇更技术、也更超前。

1948 年，他在国家物理实验室写了一份内部报告，题目大意是《智能机器》。

这份报告里，他提出了一个概念叫“**无组织的机器**”。

他的出发点是一个观察：**婴儿的大脑皮层，看起来相当“无组织”。** 它不是一张精心设计的电路图，它更像一堆随机连着的东西，而它后来变得有用，靠的是经验。

于是他定义了这样一种机器：**一堆单元，之间的连接是随机的**——不是设计出来的，是随便接的。

他给了两类。第一类他叫 A 型：单元之间随机连接，每个单元做一个简单的逻辑运算。第二类他叫 B 型——在 A 型的基础上，**每一条连接上加了一个可以被“开”和“关”的开关**，而这些开关的状态可以被外部的训练过程改变。

请把这句话读慢一点：一个随机连接的网络，通过改变连接的通断来学会做事。

这是**神经网络**。1948 年。

而图灵在同一份报告里说了要怎么用它：**靠外部的“干预”去拨这些开关**，让有用的连接留下、没用的关掉。

报告里还有第三种机器，他叫它 P 型。到这一步，干预被收窄成了两个输入——一个叫“快乐”，一个叫“痛苦”——因为人教小孩靠的就是奖励和惩罚。

A 型、B 型、P 型是同一份报告里递进的三步：随机接线的网络；接线可以被改的网络；以及可以被奖惩调教的机器。这本书后面所有关于“训练”的事，骨架都在这三步里。

所以在感知机（第 10 章）之前十年，在反向传播（第 13 章）之前二十六年，图灵已经写下了：随机初始化的网络 + 训练信号 = 学习。

这份报告他的雇主没有让它发表。压下它的人叫查尔斯·高尔顿·达尔文（Charles Galton Darwin），当时的国家物理实验室主任，也是那位达尔文的孙子。他给这份报告的评语是：一篇小学生作文。

于是它进了抽屉。它第一次被印出来是 1968 年——比图灵之死晚了十四年。

那时候图灵已经死了十四年，而神经网络正要被一本书判死刑（第 10 章）。

（这句评语值得在这本书里留个记号。达尔文不是庸人，他是个正经物理学家、皇家学会会士。他看不出这份报告的价值，不是因为他蠢，是因为 1948 年这份报告里的东西没有任何东西可以对照——没有同行、没有文献、没有一个已经存在的领域可以把它挂进去。评审制度对“看起来不像任何已有东西”的工作，天然是失灵的。这是母题二在制度层面的形状。）

这是本书母题二最刺眼的一个例子：一个正确的想法，被压在抽屉里，一直压过了它本可以拯救的那场灾难。

顺便，图灵还写了最早的下棋程序之一。

1948 年夏末，他和剑桥国王学院时代的老朋友、经济学家戴维·钱珀瑙恩（David Champernowne, 1912 – 2000）做了一个叫 Turochamp 的东西——名字是两个姓拼起来的。它的原理今天的每一个棋类程序都还在用：枚举所有可能的走法和对手的应对，再往下看几步它认为值得看的，给每个局面打一个分，选分数最高的那一步。

（“最早”这个词在这里要按规矩用。香农 1950 年那篇讲机器下棋的论文比它晚两年，但那是第一篇把这件事讲清楚的公开文献；而第一个真正在机器上跑起来的下棋程序，是 1951 年曼彻斯特的迪特里希·普林茨写的，还是从 Turochamp 得的灵感。Turochamp 早，但它当时跑不起来——这三件事各占一个“第一”，谁也不必让给谁。）

问题是那时候没有一台能用的机器来运行它。

于是图灵自己当那台机器。

他拿着纸和笔，一步一步按照程序的规则去算，每走一步要花半小时以上。他就这样和人下完了一整局。

这局棋的细节现在可以写死了：时间是 1952 年夏天，对手是计算机科学家阿利克·格伦尼（Alick Glennie）——就是后来写出 Autocode、常被算作世界上第一个编译器的那个人。棋下了二十

九个回合，Turochamp 认输。 认输的直接原因是它的后被牵制住，保不住了。

人类第一次和“计算机”下棋，那台计算机是一个人在用手模拟一个程序，而且它输了。

第 5 章那台图灵机的定义，就是从“一个人在纸上做计算”抽象出来的。而这一次，他反过来用自己去执行一个程序。

这个人一生都在这两个方向之间来回走。

—— 四 ——

现在讲这个人。因为前面三节讲的是他的思想，而他的处境是另一回事。

1939 年 9 月，战争爆发。图灵去了一个地方，叫**布莱切利园**——伦敦西北方向的一处庄园，英国的密码破译中心。

他在那里做的事，是本书之外的另一个故事，这里只交代与本书相关的部分：他主持第八棚屋，领导破译德国海军 Enigma 通信的工作，并设计了一种叫“炸弹机”的电机装置——它不是把所有密钥都试一遍，而是从一段猜出来的明文出发，把导出矛盾的转轮设置成批地划掉，剩下的才交给人看。这台机器随后被主持第六棚屋的戈登 · 韦尔什曼改进了一步：他加了一块“对角板”，利用接线板两端互为对方的性质，让每一次矛盾能牵连出更多矛盾，可划掉的设置因此大幅增加。

这项工作的军事价值极大，具体缩短了多少战争没有确切结论，但没有人怀疑它救了很多人的命。

这项工作在战后几十年里是绝密。

所以 1950 年那篇论文的读者不知道，写这篇文章的人不只是一个搞逻辑的剑桥数学家。**他是当时世界上极少数真正大规模地、成功地用机器代替人类判断的人。**

他不是在幻想。他见过。

请记住布莱切利园这个地名。 第 31 章，二十八个国家和欧盟的代表会在同一片园子里坐下来，签一份关于人工智能风险的宣言。

1952 年 1 月，图灵家里遭了窃。他报了警。

警方在调查过程中了解到，他和一个年轻男子有性关系。在当时的英国，这构成犯罪——“严重猥亵罪”。

他被起诉的原因，是他报了警。

图灵没有否认。据记载，他给警方的陈述又长又坦白，像是不觉得这里面有什么可羞耻的。

他被定罪。可选的判决有两种：入狱，或者接受“治疗”——注射雌激素以降低性欲，为期一年。

他选了后者。 因为入狱意味着不能继续工作。

后果包括身体上的变化，也包括更实际的一条：他失去了安全许可，不能再接触政府的机密工作。**那个在战争中破译了 Enigma 的人，从此被自己的国家列为安全风险。**

而就在这两年里，他在做一件看上去跟机器智能毫无关系的事——那件事今天读起来，是这本书最后一个时代的预告。

1952 年 8 月 14 日，图灵发表了一篇论文，题目是《形态发生的化学基础》。

这是他一生唯一一篇生物学论文，也是他最后一篇重要论文。

他要回答的问题是：一个受精卵是一团几乎均匀的东西。斑马身上的条纹、豹子身上的斑点、花朵的排列——**这些图案是从哪里来的？**

当时通行的想法是：一定有某种预先存在的“蓝图”，某种在更早的阶段就已经决定好的结构，图案只是把它显影出来。

图灵证明了：不需要蓝图，图案也能自己出来。

他的模型只要两种会互相反应的化学物质，它们各自还会扩散。他做的是：写下这个系统的方程，然后分析在什么条件下，**一个完全均匀的初始状态会自己失稳。**

结论是：只要两种物质的扩散速度差得够多，那么一个均匀的状态遇到极小的随机扰动，**就会自发地长出稳定的、周期性的空间图案。**

斑点和条纹不需要被设计。它们是简单的局部规则在整个空间上跑出来的结果。

（这类图案今天叫“图灵斑图”。方程一旦手算不动，他就把它搬到曼彻斯特那台 Ferranti Mark I 上去跑——**他大概是最早用计算机做生物学模拟的人之一。**后来的实验化学和发育生物学确实在真实系统里找到了这种机制的证据，这篇论文被认为是二十世纪理论生物学最重要的论文之一。）

为什么我要在一本人工智能史里花这么多篇幅讲斑马的条纹？

因为这篇论文和图灵别的工作是**同一个念头的两面。**

- 1936 年，他证明：一台只会“读一格、写一格、移一格”的机器，能算出一切可计算的东西（第 5 章）。
- 1948 年，他提出：一堆随机连接的单元，靠训练可以变得有用（本章上一节）。
- 1952 年，他证明：两种简单的化学物质，靠扩散和反应，能自己长出复杂的图案。

三次，同一个主张：复杂的、看起来被设计过的东西，可以从简单的局部规则里自己长出来，不需要设计者。

这个主张的名字，是本书第五时代的标题：涌现。

第 27 章会遇到一场激烈的争论：那些模型的能力，究竟是从规模里自己“长”出来的，还是我们的测量方式造成的错觉。争论的双方会用统计和曲线互相攻击。

而这个问题的形状——**没有蓝图的秩序**——是 1952 年一个正在被自己的国家治疗的人，坐下来用两个反应方程写清楚的。

1954 年 6 月 8 日早上，他的管家发现他死在床上。验尸认定的死亡时间是**前一天，6 月 7 日**。他四十一岁。

床头柜上有一个吃了一半的苹果。

法医鉴定死因是氰化物中毒。**验尸官的结论是自杀。**

接下来这一段，我要非常小心地写。

流传最广的版本是：图灵在苹果里注入了氰化物，咬了一口。而这个动作被解释为他对《白雪公主》里那颗毒苹果的引用——据认识他的人回忆，他确实对那部动画里女王把苹果浸进毒汁的那一段很着迷。

> 订正
>
> **毒苹果与《白雪公主》**
>
> **流传的说法**：图灵咬下一颗注了氰化物的苹果，刻意重演《白雪公主》里的那一幕。
>
> **可查的是**：验尸报告里没有《白雪公主》。 这个联想是在传记写作阶段被接上去的——霍奇斯 1983 年那本传记提到它，后来的作者沿用，此后它就长在这个故事上了。而那颗苹果从来没有被检测过有没有氰化物。

先说事实层面。近年来，图灵研究者杰克·科普兰（Jack Copeland, 1950 – ）系统地质疑了自杀结论。他的理由不是阴谋论，是**证据规格**：

第一，警方从来没有检测那颗苹果里有没有氰化物。从来没有。而图灵有睡前吃苹果的习惯，也常常吃不完。

第二，尸检的表现更像吸入，而不是吞服。

第三，他家里那间小小的备用房间里，有一套用氰化钾做金电镀的装置——他自己在玩这个，用氰化钾溶解黄金，给勺子镀金。这意味着房子里有氰化物蒸气的现实来源。

第四，他在死前没有表现出绝望的迹象。据周围人的记述，他对判决和治疗的态度是带着幽默感在承受的；而且他留下了一份回办公室后要办的事情清单。

基于这些，科普兰认为：以今天的标准，1954 年那份自杀裁定的证据是不充分的；意外的可能性至少同等。

另一边同样要说清楚：这不是定论。 图灵的主要传记作者安德鲁 · 霍奇斯不接受这个重估。他为《斯坦福哲学百科全书》撰写的“艾伦 · 图灵”条（2002 年初版，2013 年修订）里，话说得很直：图灵“谈起过自杀，而他的死——死于氰化物中毒——最可能出自他本人之手，且被布置成这样一种样子：让愿意那样相信的人，可以相信这是他沉迷化学实验的结果”。

请注意这句话的结构。霍奇斯并不否认现场看上去像意外——他认为**那种观感本身可能正是刻意留下的**。同一批物证，在科普兰那里是“不足以判定自杀”，在霍奇斯那里是“被安排成这样”。两边争的其实不是同一批事实，是这批事实够不够。

我在这里不做裁决，因为证据确实不足以裁决。

但有一件事必须说清楚，因为它关系到历史该怎么讲：

“毒苹果 + 白雪公主”这个叙事之所以流传，不是因为证据强，而是因为它太完整了。 它给一个受迫害的天才配上了一个有文学隐喻的死法，让整件事有了形状、有了意义、有了可以流泪的地方。

而另一种可能要平淡得多，也因此更难受： 一个刚刚被自己的国家定罪、被注射激素、被剥夺了机密工作资格的人，在自家备用房间里摆弄一套危险的化学装置，然后死了。没有隐喻。

前面几处订正的对象都是技术传闻。**这一处的对象是一个人的死。**

所以规矩更严：说事实，标明分歧，不替他挑一个更好听的结局。

后来的事，简短记录：

2009 年 9 月 10 日，英国首相戈登 · 布朗代表政府就当年对图灵的处置公开道歉。 2013 年 12 月 24 日，图灵获得王室赦免。 2017 年 1 月 31 日，《警务与犯罪法》获御准生效，为历史上因同类罪名被

定罪的人集体赦免；这一条被非正式地叫做“图灵法”。

都在他死后五十五年以上。

关于“赦免”这个词，还有一件事值得说。

赦免的意思是：**你确实犯了法，但我们免除你的刑责。**

不少人——包括图灵的家人和一些研究者——认为这个词用错了。因为图灵没有做错任何事；错的是那条法律。**该被赦免的不是他。**

这个分歧听起来像咬文嚼字，但它其实是这一整节的题眼：

一个社会在纠正自己的错误时，最难的一步不是道歉，是承认“当时的规则本身是错的”，而不是“当时有几个人执行得太严了”。

前者要求你重新评价整个制度；后者只需要找几个替罪羊。

这本书写到第 31 章的时候，会有一群人坐在图灵当年破译密码的那片园子里，讨论该给一项新技术定什么规则。到那一章我们会知道，这件事有多难。

—— 五 ——

1950 年那篇论文结束的时候，图灵在最后一段写了一句话，大意是：**我们只能看到前方很短的一段路，但那一段里有很多事等着做。**

他看到的那一段路，实际上包含了此后七十六年的大部分内容：一个基于行为的判据；九条反对意见的完整目录；一个“先造孩子再教它”的技术路线；以及用奖惩来训练机器的具体建议。

他没能走上这条路。他死的时候，世界上还没有一个叫“人工智能”的领域。

那个领域的名字，在他死后一年零两个月才被造出来。

1955 年夏末，四个人联名向一家基金会递了一份申请，想在第二年夏天，在新罕布什尔州的一所学院里搞一次为期两个月的研讨。

申请书的标题里有一个此前不存在的词组。**它绕开了控制论，也绕开了图灵。**

而在那个夏天的会议上，真正让所有人吃一惊的，不是那个词。是两个从匹兹堡来的人——他们带来了一个**已经在跑**的程序。

那个程序在做的事，恰好是证明《数学原理》里的定理。

也就是那本书——第 6 章里，一个十二岁的男孩为了躲人钻进图书馆时，从架子上抽下来的那一本。

第 10 章

感知机

会学习的机器上了《纽约时报》，十年后被一本书判了死刑，作者两年后死在切萨皮克湾。

一

1958 年 7 月，华盛顿。美国海军召开新闻发布会，演示的内容是一台机器在认卡片。

卡片上只有一个标记，有的偏左，有的偏右。机器一开始纯属瞎猜。据当时的报道，试了大约五十次之后，它开始分得清左右了——而从头到尾，没有人给它写过“什么叫偏左”。

7 月 8 日，《纽约时报》见了报。标题是：**《海军新装置边做边学》**，副题：**《心理学家展示计算机的雏形》**。

报道里的措辞今天读起来相当惊人。它说，海军披露的这个电子计算机的雏形，预期将能够行走、说话、观看、书写、自我复制，并且意识到自己的存在。发布会上的演示者说，这将是第一台像人脑那样思考的装置；它一开始会犯错，但会随着经验的积累变得更聪明。

走、说、看、写、自我复制、有自我意识——1958 年，一份严肃的报纸，在一场官方发布会之后，把这些写了出来。

那台机器叫**感知机**（Perceptron）。做出它的人叫弗兰克·罗森布拉特（Frank Rosenblatt, 1928–1971）。

这是人工智能史上第一次媒体过热，而它的模板此后被反复重印：一场官方发布会，一个真实但有限的技术成果，一串关于遥远未来的推断，以及一个把两者混在一起的标题。本书后面还会撞见它两次——1997 年深蓝的“AI 战胜人类”（第 17 章）、2023 年《AGI 的火花》（第 27 章）。每一次，被夸大的都不是成果本身，而是从成果到愿景之间那段被省略的路。

不过 1958 年这一次，被夸大的东西背后是一个真正的突破。我们得先讲清楚那个突破是什么，否则后面那场悲剧就成了一个关于媒体炒作的乏味故事。

罗森布拉特不是工程师，他是**心理学家**。这一点决定了一切。他在康奈尔拿的是心理学博士，研究的是大脑怎么工作；后来他去了康奈尔航空实验室，那里有钱、有海军的合同、有工程师。但他要的东西不是一台好用的机器，他要的是一个关于大脑的理论，而且是能跑起来的理论。

他的出发点，正是第 6 章那个缺口。麦卡洛克和皮茨说：神经元是逻辑门，网络能计算任何东西——但那些权重是人填的。

罗森布拉特问的是：权重能不能自己长出来？

而他给出的答案，是本书出现的第一个真正的**学习算法**。

它先以一份技术报告的形式出现：1957 年 1 月，康奈尔航空实验室第 85-460-1 号报告，《感知机：一台会感知、会识别的自动机》。次年他把它写成一篇给心理学同行看的论文，标题换了个说法——《感知机：一个关于大脑中信息存储与组织的概率模型》，登在 1958 年的《心理学评论》上。**两个标题的差别值得留意：对工程界他说的是一台机器，对心理学界他说的是一个关于大脑的模型。他自己要的是后者。**

二

感知机的结构，就是第 6 章那个四行模型加一个东西。这里先讲最简的版本，完整结构留到本节末尾再补。

- 一层输入（比如一个 20×20 的光敏元件阵列，看一张图）；
- 每个输入连到输出单元，每条连接有一个权重；
- 输出单元把输入乘权重加起来，超过阈值就输出 1，否则输出 0。

到这里跟麦卡洛克-皮茨完全一样。新的东西是下面这三行。

假设你要教它区分“这张图里有个圆”和“没有圆”。你给它看一张图，它给出一个答案。然后：

1. 如果它答对了，什么都不做。
2. 如果它该说 1 却说了 0（太保守），就把**当前所有激活着的输入**对应的权重调大一点。
3. 如果它该说 0 却说了 1（太激进），就把那些权重调小一点。

就这样。反复给它看例子，反复微调。（那个阈值本身也跟着一起动——把它当成一个永远亮着的输入就行，规则一模一样。）

这三行是本书的一个分水岭。它凭什么重要？

第一，它不需要人懂那个任务。 你不需要知道“什么是圆”的定义，不需要写出判定规则，不需要提取特征，你只需要有一堆例子和标签。权重最终长成什么样，你不知道也不用知道。

这与达特茅斯路线（第 9 章）是根本对立的两种世界观。麦卡锡和明斯基那条路要求：先把知识说清楚，再编进机器。罗森布拉特这条路说：你说不清楚也没关系，让它自己从数据里找。这条对立线是本书从第 9 章一直贯穿到第 24 章的主轴，母题一（钟摆）就是它。

第二，它的调整是局部的。 每一条连接的权重变化，只取决于这条连接自己的输入和最终那个对错信号，没有任何全局的复杂计算。这跟赫布规则（第 6 章）在精神上一致，因此在生物学上是可信的。

第三——这一条最要紧——它有一个数学保证。 感知机这一支里最早的证明出自罗森布拉特自己（收在 1962 年那本《神经动力学原理》里）；随后布洛克（1962）和诺维科夫（1962 年布鲁克林理工学院“自动机数学理论”研讨会论文集）各自给出了更简洁的版本，今天教科书上印的通常是诺维科夫那一版。这个结果叫**感知机收敛定理**：

> 给定有限多个训练例子，如果存在一组权重能把它们全部分对，那么反复用上面那三行去调，一定能在有限步内停在一组把它们全部分对的权重上（不一定是同一组）。

请留意那个“如果”。**它是这一整章的引信。**

有了这条定理，就不是“看起来能学”了，是“保证学得到”。这在 1958 年意味着：你有了一个东西——给它数据，它自己找参数，而且数学上保证收敛。这是人类第一次拥有一个会学习、且有理论保证的人造系统。

关于这条定理的来历还要补一句，因为它本身就是本书的一个母题：**它的数学内核并不是感知机这一支先想到的。** 早在 1954 年，阿格蒙（Shmuel Agmon），以及莫兹金（Theodore Motzkin）与舍恩伯格（Isaac Schoenberg），就在同一卷《加拿大数学杂志》上前后脚发表了两篇同名的文章，讲的都是“线性不等式组的松弛法”——阿格蒙那篇在 382 至 392 页，莫兹金与舍恩伯格那篇紧接着，393 至 404 页。那是纯粹的数值分析，跟大脑、跟学习机器毫无关系，后来的教科书才把它们追认为感知机收敛定理的前身。

正确的东西先出现在别的门牌号下，没人把它跟这边的问题接上。 这件事在这本书里会反复发生，第 13 章还有一次更严重的。

这里要澄清一件常被含混过去的事：1958 年那场发布会上跑的，其实是一段装在 IBM 704 上的程序——喂进去的是打孔卡；专门的硬件是后来才造出来的。那台硬件叫 **Mark I 感知机**，1959 年下半年造出，1960 年 6 月首次公开演示，是一台真机器——四百个光敏元件排成 20×20 当“视网膜”，权重不是存在内存里的数字，而是一排电位器，调整权重的办法是让马达去转那些旋钮。（它今天在史密森学会。）

所以这台机器学习的时候，屋子里能听见声音：一堆小马达咔咔地转，每一下都是一个权重在变。

它真的能工作。它能学会区分一些简单的图形，能在某些字符上做识别。在那几年里，一台会看、并且看得越来越准的机器，是一件真事。

同一时期还有几条并行的线，都属于这一支。

伯纳德·威德罗（Bernard Widrow, 1929 – ）和他的学生特德·霍夫（Ted Hoff, 1937 – ）在斯坦福做了一个叫 **ADALINE** 的东西（1960）。它和感知机很像，但学习规则不同——他们那个规则叫**最小均方**（least mean squares, LMS），它不看"对还是错"，而是看"错了多少"，然后按误差的大小成比例地调整权重。

这个区别在当时看不出分量，五十年后看极其要紧。因为"按误差大小连续调整"这个思路，正是第 13 章反向传播的直接前身；而 LMS 算法本身至今还在用——电话线路上的回声消除、通信信道的均衡、天线阵列的自适应处理，跑的就是它。他们那篇论文题为《自适应开关电路》，登在 1960 年 IRE WESCON 会议论文集上。

奥利弗·塞尔弗里奇（Oliver Selfridge, 1926 – 2008）1958 年 11 月在英国国家物理实验室那场"思维过程机械化"研讨会上宣读了《Pandemonium：一个学习的范式》（论文集次年出版），想法很有画面感：让一大群"小鬼"（demon）各自负责识别一种简单特征，每个小鬼看到自己那种特征就喊，喊得越响表示越确信；上一层的小鬼听下面这群的喊声，再往上喊；最后由最上层裁决。这是"分层特征提取"这个想法的早期版本——底层看边缘和线段，高层看形状和物体。第 15 章那个卷积网络的整体架构，就是这个思路的成熟形态。

所以 1958 到 1962 年前后，联结主义这一支手上有：一个会学习的模型、一个收敛定理、一个更好的学习规则、一个分层架构的构想，还有一台真的在转马达的机器。

这一支当时看起来非常有前途。**而它接下来消失了将近二十年。**

现在补上前面欠的那一笔，因为下一节的争论全绕着它转：罗森布拉特的感知机其实不止一层。

它的完整结构是三层：一层"视网膜"（输入），一层他叫做 A 单元的中间层，然后是输出。关键在于，从视网膜连到 A 单元的那些线是**随机接上去的，接好就再也不改**——在 Mark I 上，那是一块插线板，照着一张随机数表插。学习只发生在最后一段：A 单元到输出的那些权重。

为什么只学最后一层？因为那三行规则要工作，需要知道"这个单元错了多少"。对最后一层，你知道正确答案，误差是现成的；而对中间层，你不知道它本该输出什么。

于是罗森布拉特的做法是：中间层随机连一通，反正数量够多，总能碰出一些有用的特征，然后让最后一层去学着怎么用这些特征。

这个折衷很聪明，也很脆弱。聪明在于它绕开了一个当时无解的问题；脆弱在于，如果那些随机特征里恰好没有一个对你的任务有用，整个系统就学不会，而你没有任何办法去改进它们。

下一节那本书，攻击的正是这个位置。

三

现在讲那本书。

1969 年，麻省理工出版社出版了一本书，名字就叫《感知机》。两位作者：马文·明斯基和西摩·佩珀特（Seymour Papert, 1928 – 2016）。

它在人工智能史上的名声，大概是“杀死了一个领域十年”。这个说法需要被仔细拆开，因为它一半是真的，另一半是关于这本书最流行的一个误传。

先说它**证明**了什么。它的数学是严格的，而且是对的。

它的核心结果，只需要一张纸和四个点就能看懂。这是本章要你动笔的地方。

先看一个极简的任务：**异或**（XOR）。两个输入，规则是：恰好有一个是 1 时输出 1，否则输出 0。全部情况只有四种：

输入 A	输入 B	应该输出
0	0	0
0	1	1
1	0	1
1	1	0

现在，在纸上画一个坐标系，把这四种情况画成四个点：横轴是 A，纵轴是 B。

- (0,0) 在左下——输出 0，标为 ○
- (0,1) 在左上——输出 1，标为 ●
- (1,0) 在右下——输出 1，标为 ●
- (1,1) 在右上——输出 0，标为 ○

四个点正好是一个正方形的四个角。两个 ● 占着一条对角线的两端，两个 ○ 占着另一条。**现在请试着画一条直线，把两个 ● 分在一边，两个 ○ 分在另一边。**

试试看。

画不出来。而且这不是“我试了很多次都没成功”，它可以被说死：

那两条对角线交于正方形的中心，也就是 (0.5, 0.5)。

假设真有那么一条直线，把两个 ● 划在它的一侧、两个 ○ 划在另一侧。直线的一侧是一个半平面。半平面有一条性质：在里面任取两点，它们之间那整段连线也都还在里面。两个 ● 都在 ● 那一侧，所以它们的连线整段都在那一侧。中心点在这条连线上。于是中心点在 ● 那一侧。

同一句话对两个 ○ 再说一遍：中心点又在 ○ 那一侧。

一个点不可能同时待在一条直线的两边。矛盾。所以那条直线不存在——不是难找，是没有。

而这就是单层感知机的全部能力边界。

原因是：一个感知机计算的是“输入的加权和是否超过阈值”。在几何上，“加权和 = 阈值”是一条直线（三个输入时是一个平面，再多就是一张看不见的超平面）。感知机能做的全部事情，就是用这条线把空间切成两半，一半答 1，一半答 0。

所以，凡是不能被一条直线分开的问题，单层感知机学不了。不是学得慢，是**根本不存在**能做到的权重——收敛定理那个“如果存在一组权重能分对”的前提，在这里直接落空了。定理本身没有失效，是它的门槛没被跨过去。

XOR 是一个连小学生都能听懂的规则。**而那台上了《纽约时报》、被说成将来会有自我意识的机器，学不了它。**

明斯基和佩珀特还证明了比 XOR 更有杀伤力的结果。

他们的分析工具是一个叫**阶**（order）的量。假设你只用“每个都只盯着输入里一小片”的局部特征去拼一个判据——在所有拼得成的方案里，最省的那一种，用到的最大一片有多大？这个数就是这个判据的阶。阶小，意味着一群近视眼凑一凑就够了；阶大，意味着非得有人把整幅图一次看完。

奇偶性（输入里 1 的个数是奇是偶）的阶等于输入的总个数。也就是说，非得有一个把全部输入一次看遍的特征单元不可，局部特征怎么拼都拼不出它。**连通性**（一个图形是不是连成一片的）同样不是有界阶的：图形越大，要看的那一片就得跟着变大。他们另外还专门讨论了权重系数本身的量级会如何膨胀。

这一类结果其实比 XOR 更重要，因为它针对的是“能不能扩展到现实规模”，而不只是“能不能算某个玩具函数”。只是它画不进一张纸里，所以流传得远不如那四个点广。

这本书的数学没有错。它是一本优秀的数学著作。

那么，误传在哪里？

在于“这本书证明了神经网络不行”这个说法。它证明的是：**单层感知机不行。**

而当时所有人都知道，多层的网络能力强得多——把几个感知机叠起来，第一层的输出当第二层的输入，那条直线就可以被折起来，XOR 立刻可解（第 13 章我们会亲手折一次）。

问题从来不是“多层网络能不能做到”，而是“多层网络怎么训练”。

罗森布拉特那三行规则依赖一个信息：这个单元错了多少，该往哪边调。对于直接连着输出的那一层，这个信息是现成的——你知道正确答案。但对于中间那些层，你不知道它们本该输出什么。没有目标，就没有误差，就没法调。这个问题当时叫**信用分配问题**（credit assignment problem）：一个错误发生了，该由中间哪些单元、各负多少责任？

明斯基和佩珀特在书里明确讨论了多层的情况，并且表达了悲观。这句话值得原样摆出来，因为它是这一整场公案里被引用得最多、也被误引得最多的一句——它在 1969 年初版的第十三章、第 231 至 232 页：

> 我们认为，阐明（或者推翻）我们那个“这种推广是不育的”的直觉判断，本身是一个重要的研究课题。

请注意这句话的语法。**它不是一个定理，甚至不是一个断言——它是一个判断，而且作者自己给它标注了“直觉”两个字，还建议后人去验证或推翻它。**

这一点很要紧，因为流传的版本通常把它压缩成“明斯基和佩珀特证明了多层网络没用”。他们没有证明这件事，他们也没说自己证明了。他们说的是：我们直觉上认为这条路不育，而这个直觉值得被研究。

然后这个方向的经费就没了。一句自我标注为直觉、并且公开邀请他人反驳的话，在传播中变成了一道判决——这个落差本身，比那句话的对错更值得记住。

而这个判断错了。

（十七年后，1986 年，信用分配问题会被解决，办法是一个用高中链式法则就能写下的公式。而在 1986 年之前，那个公式已经被人独立写下过至少两次，只是没人注意到——1970 年一篇芬兰语的硕士论文，1974 年一篇美国的博士论文。请留意这两个年份：它们都在《感知机》出版之后。第 13 章。）

而这里有一件事，几乎每一个版本的转述都漏掉了，它多半是这一整章最要紧的一条。

流行的叙事默认：罗森布拉特只懂单层感知机，明斯基和佩珀特指出了他没看见的局限。

不是这样的。

1962 年——**比《感知机》早七年**——罗森布拉特出版了他那本厚书《神经动力学原理：感知机与脑机制理论》（Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms，斯巴达图书）。

这不是一本小册子。它的第二部分讲三层串联耦合感知机的理论；**第三部分整个是“多层与交叉耦合感知机的理论”**；书里还专门有一节讨论“反馈耦合的感知机与选择性注意”。也就是说，罗森布拉特不但知道多层，他把多层、交叉耦合、带反馈的结构分门别类地写进了目录，并且明确写下了训练这些结构会遇到的权重分配障碍。

那些障碍，和明斯基与佩珀特七年后指出的，是同一批障碍。

区别不在于谁看见了什么，而在于两边怎么给它定性。罗森布拉特把它们当成需要进一步研究才能翻过去的坎；明斯基和佩珀特把它们当成这条路不值得走下去的理由。同样的技术事实，两种判断——**而这两种判断的差别不是数学，是气质。**

这件事在这本史话里会反复出现，建议你记住它的形状：

在一个方向上遇到障碍的时候，“这是个难题”和“这条路不通”是两个截然不同的结论，而支撑它们的往往是同一批证据。**决定一个领域走向的，经常不是证据本身，而是当时最有权威的那个人选了哪一句。**

第 13 章那三个人（辛顿、鲁梅尔哈特、威廉姆斯），以及第 17 章那些在“神经网络已死”的二十年里坚持下来的人，选的是罗森布拉特那一句。而从 1962 年他写下那一句，到 1986 年那个公式终于被听见，整整二十四年。

还有一个后续，是这个故事里最硬的一块石头。

1988 年，《感知机》出了增订版。那时候反向传播已经发表两年，多层网络的训练问题已经被解决，联结主义正在回潮。明斯基和佩珀特在新版里加了一篇长长的后记，而他们的结论是：这些年里没有发生什么实质性的变化。

他们坚持自己 1969 年的分析在原则上依然成立，并且对新一轮热潮里的乐观情绪提出批评——他们认为这个领域仍然缺少对“什么能学、什么不能学、要付多大代价”的严肃理论。

该怎么看这件事？

一方面，他们的部分批评是有道理的。“能训练多层网络”确实不等于“理论问题解决了”——今天关于深度网络为什么能泛化，理论依然远远落后于实践，第 27 章会看到这笔账还没还完。

另一方面，他们对方向的判断第二次错了，而且这一次是在证据已经摆出来之后。

记住这一条，下一节末尾要用到它。

书的实际效果，远超它的论证范围。

《感知机》出版之后，神经网络这个方向的经费迅速枯竭，博士生不再选这个题目，会议上不再有人报告。到 1970 年代中期，这一支在美国基本消失了。

关于因果，这里必须给出证据的边界。“一本书杀死了一个领域十年”这个说法太干净了。真实的情况更杂：1960 年代末美国研究经费的整体环境在收紧——同样是 1969 年，国会通过了曼斯菲尔德修正案，规定国防部只能资助与具体军事用途有明确关联的研究，DARPA 那种“给一笔钱、你们去探索”的资助方式就此收口；感知机自己的过度承诺已经开始还账；而符号主义那一支正在拿出看得见的成果（第 9 章）。

它不是唯一的原因，但它提供了一件极其好用的东西：一个来自权威、数学严格、可以被引用的“这条路不通”的理由。一个经费评审只需要引用它，就不必再解释。

这是全书关于“论证”和“影响”如何脱钩的最重要案例——**一本书可以在每一个数学命题上都正确，同时在它造成的后果上完全不成比例。**

—— 四 ——

那本书讲完了，现在讲写书的那个人，以及通行叙事里最经不起查的一块。

流行的版本是：明斯基出于门派之争和个人恩怨，写了一本书，把竞争对手的方向判了死刑。

实际的情况要杂得多。下面三条里，只有第一条是硬的；另外两条要把证据的成色一并交代，因为它们恰恰是最容易被人当成定论转述的两条。

第一，明斯基自己就是最早动手做神经网络的人之一。 1951 年，还在普林斯顿读研究生的他和邓恩 · 埃德蒙兹搭了 SNARC——一台用真空管和马达模拟神经元连接强度变化的机器（第 9 章）。他不是从外部攻击这个领域的人，他是这个领域的早期实践者。这一条有实物、有年份，站得住。

第二，《感知机》上确实写着弗兰克 · 罗森布拉特的名字——但它出现的时间，比多数转述以为的晚。

这一条常被拿来当“两人无私怨”的铁证，而它的成色取决于一个几乎从没被交代过的细节：这行字到底印在哪一版上。

答案是：**两个常见的猜测都不对。它既不在 1969 年的初版上，也不是 1988 年增订版才加的。**

1969 年的初版没有这行献辞。1971 年 7 月罗森布拉特去世。**1972 年，《感知机》出了一次带勘误的重印，两位作者在这一版上手写添了一句：“纪念弗兰克·罗森布拉特。”**此后这行手写字一直随书重印，包括 1988 年那个增订版——所以后来的读者在增订版上看到它，很容易误以为它是 1988 年才有的悼词，或者反过来，误以为它从 1969 年就在。

它是一句加在死讯之后的挽辞。这个定位比两种误传都更准确，含义也更清楚：它不是初版时同侪之间的致意（初版没有），也不是十九年后回过头补的一笔（1972 年就有了）。写下它的时候，两位作者刚刚知道自己论战的那个对手死了。

至于它是不是一句反话，眼下既没有证据说是，也没有证据说不是——而“死后第二年手写添上去”这个事实，本身就让“反话”这个读法很难成立。本书因此写“纪念的字样是他去世后加上去的”，而不写“这是初版时的一次致敬”。

至于两人的私交，“关系一直不错”这个说法只见于二手回忆，没有一手件，本书不采。有据可查的是另一件事：1950 年代末到 1960 年代初，两人在学术会议的讲台上反复公开争执，这在当时的圈子里人尽皆知。而明斯基本人回头看这段的时候，说得相当克制——1981 年他对《纽约客》的记者杰里米·伯恩斯坦谈起收敛定理时说，罗森布拉特“提出了一个很强的主张，我起先并不相信”，而“他的猜想在数学上确实是对的”；他接着说，他真正开始担心的，是这样一台机器做不到什么。

争的是范式，不是人品。后来的复述常把这两样揉在一起，而它们从来不是一回事。

第三，“两人是布朗克斯科学高中同班同学”这个广为流传的细节，差了一届。两人确实都出自这所高中，但按校友名录，明斯基是 1945 届，罗森布拉特是 1946 届——差一年，不是同班。而且明斯基的中学经历本身是断开的：他先后念过菲尔德斯顿学校和布朗克斯科学高中，后来又去了安多佛的菲利普斯学院，中间还在 1944 至 1945 年间服过一段海军役。

这个误传有一个可查的落点。麦考黛克的《会思考的机器》——1979 年出版，是这门学科最早的通俗史之一——在讲感知机的那一段里，把罗森布拉特写成了明斯基在布朗克斯科学高中的同班同学（页码据 2004 年第二版，第 105 页）。本书没有找到比它更早的出处。**它出现的位置很不起眼**：那是一句顺笔带过的同位语，不是这本书要论证的东西——而误传常常正是从这种地方进来的。

所以准确的说法是：**这两个人少年时代在同一所以理科闻名的中学里前后脚待过，但不是坐在同一间教室里的同学。**“同班同学反目”这个讲法比事实更整齐，本书不采用。

所以这个故事的真正形状，多半不是“一个人害了另一个人”，而是更难受的一种：

两个受过同类训练、彼此认识、都对“机器能不能学习”这件事真诚感兴趣的人，对同一个技术方向做出了相反的判断。其中一个人的判断错了，而另一个人在判断被推翻之前就死了。

这里面没有坏人。这使它更难写，也更值得写。

所以这个故事真正的教训，比“不要相信权威”难受得多。

我们很容易把这个故事读成：一个有权势的人打压了一个正确的方向，害了这个领域二十年。从这里可以得出一个让人舒服的结论——提防那些说“不行”的权威。但事实不支持这个读法。明斯基不是外行，不是坏人，也不是没做过神经网络。他是一个极其聪明的人，用严格而且正确的数学，对一个方向做出了他真诚相信的判断。

而他错了两次：1969 年那次，是在证据不足的时候把“这是个难题”读成了“这条路不通”；1988 年那次，是在证据已经摆出来之后，仍然认为没有实质变化。

一个领域因为一个真诚而错误的判断损失了将近二十年，而这件事没有办法靠“提防坏人”来预防。能预防它的只有一件，而且很不浪漫：**在一个方向被判死之后，仍然有人不听，继续做。**

第 13 章、第 17 章、第 19 章，讲的就是那几个不听的人。

《感知机》出版之后的两年里，罗森布拉特还在工作。

他这时的兴趣已经转向更偏生物学的方向。1966 年起，他做的是一批关于记忆转移的实验：让一批大鼠学会某个辨别任务，取它们的脑提取物注射给未受训练的大鼠，看学到的行为会不会跟着过去。这条研究路线在 1960 年代一度很热，后来没有立住。**而值得说明的是他自己那部分工作的结论**——他做下来的结果是：早先那些报告里的大效应站不住，即便存在转移，也极微弱。他还教书，带学生。

他没有活到平反。

1971 年 7 月 11 日，一个星期天的下午，他在切萨皮克湾的一次行船事故中去世。

那天是他四十三岁的生日。 他生于 1928 年 7 月 11 日，死于 1971 年 7 月 11 日——康奈尔为他写的悼念文书上，这两个日期就是这么并排印着的。

关于这个人，还想多写几句，因为他在通行的叙事里只剩下一个功能：那个被明斯基打败的人。

他不是那样活的。

他 1959 年起主持康奈尔的认知系统研究项目，后来做到神经生物学与行为系的副教授。他喜欢天文——喜欢到买了一台三千美元的望远镜，买完发现没地方放，于是在附近的布鲁克顿代尔买下一所大房子，请几个研究生住了进去。白天他们做机器，晚上一起在屋后的草地上挖地基、砌观测台，据当年的学生回忆，砌石的活儿大半是他自己干的。他弹钢琴，也作曲。他关心政治，为尤金·麦卡锡参议员助过选。

天文对他不只是爱好。1971 年 2 月，他在《伊卡洛斯》上发表了一个探测系外行星的方案：当一颗暗伴星从恒星面前经过，恒星圆面各处的亮度和颜色本来就不均匀，因此凌星的进出阶段会在整颗恒星的合成颜色上留下一段可测的偏移。**这篇论文发表在他去世前五个月。** 用凌星找系外行星，二十多年后成了这一行的主力方法。

他的兴趣宽到有点散，而这恰恰是他能做出感知机的原因：一个只受过工程训练的人，不会去想“造一个大脑的模型”这种事。

他也确实固执。《感知机》出版之后的会议上，他仍然在为自己的路线辩护；有记述说他晚期在学界的处境相当孤立。

他死后，这个领域没有为他停一下。 1971 年的人工智能界正忙着别的事，讣告不多。要到 1986 年之后，他的名字才重新被大量提起——而那时候提起他的方式，是“他早就说过”。

今天有一个以他命名的奖项：IEEE 弗兰克·罗森布拉特奖，2004 年设立，2006 年第一次颁发——他去世三十五年之后。

在这里停一下，把这一章的账算完。

第一，他是对的。 不是笼统地“方向对”，是具体地对：

- 用数据而不是规则来获得能力 —— 第 19 章之后的全部内容。
- 权重由算法自己找，而不是人填 —— 今天每一个模型都是这么来的。
- 用分层结构从简单特征走到复杂特征 —— 第 15 章的卷积网络。
- ADALINE 那种“按误差大小成比例调整”的思路 —— 第 13 章的反向传播。

罗森布拉特那三行学习规则，是今天这一支的祖父。这个说法有一处不能推太远：机器学习还有别的家系，第 17 章那一支就另有出身。但今天真正在跑的那些模型，都是从这三行下来的。

第二，他也确实过度承诺了。 那份“走、说、看、写、自我复制、有自我意识”的清单不能全推给记者——发布会是他和海军一起开的。而那个时代的研究者（不只是他，第 9 章的西蒙也一样）普遍把“在玩具问题上成功”当成了“离通用只差工程量”。这句话前面说过，再说一遍：这门学科最持久的错误不是方向错，是低估了从封闭世界到开放世界的距离。

第三，那十七年是真的丢掉了。 从 1969 年到 1986 年，多层网络怎么训练这个问题其实已经有了答案，只是写下答案的那两篇论文没人读。前一篇在图书馆的架子上躺了十六年，后一篇躺了十二年，而这个领域在同一时期认定这条路不通。

—— 五 ——

第二时代到这里，两条路线的位置已经完全清楚了。

符号这一条，正在它的黄金期。 达特茅斯那批人建起了实验室，程序在证明定理、解应用题、下棋，经费充足，预言满天飞。

联结这一条，刚刚被判死。 罗森布拉特死了，经费没了，学生没了，而解开死结的那个公式已经写在两篇没人读的论文里。

这个格局会维持十几年。

而符号这一条接下来要撞的墙，跟感知机撞的那堵完全不同。感知机撞的是一条数学定理——一条直线切不开交叉的四个点，这是硬边界，清清楚楚。

符号主义要撞的东西没有定理，也没有边界，它只是**大得没有尽头**。

它的名字叫**常识**。

而第一个把这堵墙撞出声音的程序，只有几百行代码，用的是最粗糙的模式匹配。它的作者写它，本来是想演示人机对话有多**肤浅**。

结果人们开始对它倾诉私事。

其中包括他自己的秘书——她请他离开房间，因为她想跟那台机器单独谈谈。

第 22 章

你只需要注意力

2017 年 6 月，八个人删掉了循环，只留下注意力。全书第二个技术高峰——以及一个标题带来的十年后遗症。

一

2017 年 6 月 12 日，一篇论文挂上了 arXiv。

十五页，八位作者，都在谷歌。

标题是《你只需要注意力》。

这个标题在学术论文里算是相当放肆的。它不是“一种基于自注意力的序列转换架构”，也不是“面向机器翻译的并行化模型”。它是一个断言，而且是一个听起来有点找打的断言。

论文的正文比标题谦虚得多。它报告的是：在两个机器翻译数据集上刷新了成绩，而且训练花的算力少了一个数量级。（对一篇要改写整个学科的论文来说，这份自我介绍算是相当克制。）

它没有说这个架构会统一所有的模态。没有说它会成为此后每一个大型语言模型的骨架，没有说它会被用来预测蛋白质结构、生成图像、写代码、下棋。

它是一篇翻译论文。

而它是这本书里，唯一一篇我认为必须逐个零件拆开讲的论文。所以这一章我们走得慢一点。

先说这八个人，而这一节要用一个特别的写法。

这本书的规矩是一章一到两个主角（写作规范），因为读者一次记不住更多名字。而这一章有八个人，且他们的贡献确实分不出主次——论文脚注里明写着所有作者贡献均等，并且专门交代了一句：署名顺序是随机的。

在一个署名顺序能决定职业生涯的行业里，这一行小字比论文正文更少见。

所以这一节按活儿分，不按人分。（八个名字一次记不住是正常的，你不必记。这一节最后一段会告诉你哪三件事必须记住。）

- 阿希什·瓦斯瓦尼（Ashish Vaswani）与诺姆·沙泽尔（Noam Shazeer）主要在架构与模型这一侧。沙泽尔在谷歌资历较深，此前做过大规模语言模型和机器翻译的核心工作。
- 尼基·帕尔马（Niki Parmar）、雅各布·乌兹科雷特（Jakob Uszkoreit）在模型变体与实验设计上。乌兹科雷特就是第 21 章末尾那位——2016 年那篇“没有循环也没有卷积、只有注意力”的作者之一。
- 利翁·琼斯（Llion Jones）、卢卡什·凯泽（Łukasz Kaiser, 1981 – ）、艾丹·戈麦斯（Aidan Gomez）在实现与代码这一侧，其中凯泽是谷歌那套开源框架的主要作者之一。
- 伊利亚·波洛苏欣（Illia Polosukhin）与瓦斯瓦尼一起做出了最早的几版模型。

如果只记三件事：乌兹科雷特带来了“注意力可以单干”这个已经被验证过的念头；沙泽尔带来了把它做大的工程能力；而那个标题，据琼斯自己说，是他起的，灵感来自披头士那首《你所需要的只是爱》。

这个玩笑后来的代价，我们放到第四节说。

二

现在说这篇论文真正做的那件事，而它只有一句话：

他们把循环删掉了。

第 20 章末尾和第 21 章都讲过这堵墙，这里把账算到底，因为这是本书母题五（算得动了）的最高峰。

循环网络的性质是：第 t 个词的状态，依赖第 t−1 个词的状态。于是训练一个三十个词的句子，你必须做三十次串行的计算。第二步不能提前算，因为它要等第一步的结果。

而一块显卡的本事，是同时对几千个数做同样的运算（第 19 章）。你给它三十个必须排队的步骤，它绝大部分算力在空转。（一块能同时算几千个数的显卡，被一个三十词的句子按住，一次只许动一小块。）

自注意力没有这个依赖。

每个位置要做的事是：拿自己的查询，去和所有位置的键比一比。而这些比对之间互不依赖——第一个词和第三十个词的比对，跟第五个词和第十二个词的比对，可以同时算。于是整句话的一层，变成了一次大矩阵乘法。

而大矩阵乘法，正是显卡这辈子唯一擅长的事。

这个差别有多大？论文给的数字很具体。

他们的大模型在英德翻译上拿到当时最好的成绩，训练用了八块显卡、三天半。而此前那些成绩相近的系统，训练开销要高一个数量级以上。

请把这件事和第 19 章那两块打游戏的卡放在一起看。2012 年 AlexNet 的故事是“终于算得动了”。2017 年这一次是另一件事：**不是硬件变强了，是有人把问题改成了硬件擅长的形状**。

这本书里的“算得动了”，到这里出现了第二种含义。第一种是等硬件追上来（第 15 章的卷积网络等了二十三年）。第二种是改造问题去迎合硬件。

而第二种，从此成了这个领域的主流方法论。到第 24 章你会看到，它甚至变成了一条可以写成公式的定律。

这里要插一句诚实话，因为它关系到怎么评价这篇论文。

“并行”这个好处，只对训练成立，不对生成成立。

训练的时候，整句话是现成的，你可以一次性把所有位置都算了。而当模型真的在写东西的时候，它还是得一个词一个词地吐——因为第十个词要看第九个词是什么，而第九个词是它刚刚才决定的。所以 Transformer 训练是并行的，生成是串行的。

这个不对称在 2017 年无关紧要。到第五时代，当模型要为几亿人实时生成文字时，它变成了整个行业最大的成本项。第 29 章会讲这件事。（被删掉的那个排队，在这里留了一个影子：轮到写字，它又回来了。）

三

现在拆零件。这一节是全书两个技术高峰之一，请给它一点耐心。

先讲那三个字母：查询、键、值。

打个比方。你在一个图书馆里。

- 你手上有一个问题：“我想找关于火山的东西。”这是**查询**。
- 每本书的书脊上有一个标签：地质学、烹饪、火山学、诗歌。这是**键**。
- 每本书里面的实际内容，是**值**。

做法是：拿你的问题去和每一个标签比一比，得到一个匹配分数；然后按分数高低，把所有书的内容混合起来读。标签写着“火山学”的那本，分数高，你读它读得最多；写着“烹饪”的那本，分数低，你只瞟了一眼。

自注意力就是这件事，只有一个扭转：每个词同时是提问的人，也是书。

具体说，句子里的每个词，都从自己的向量里生成三样东西——一个查询、一个键、一个值（各用一组权重矩阵投出来，而这些矩阵是训练出来的）。

然后每个词拿自己的查询，去问遍全句所有词的键。

做个能自己在纸上核的例子。

用第 21 章那句话：

> 那只动物没过马路，因为它太累了。

我们盯着“它”这个词，看它会去看谁。为了能手算，把向量压成两维。

假设训练之后，各个词的向量是这样的（这是为讲解构造的示意值）：

- “它”的查询 Q = [2, 0]
- “动物”的键 K = [2, 0.5]
- “马路”的键 K = [0.25, 2]
- “累”的键 K = [0.5, 1]

打分就是做点积——对应位置相乘再相加：

被看的词	点积计算	分数
动物	$2\times2 + 0\times0.5$	4.0
马路	$2\times0.25 + 0\times2$	0.5
累	$2\times0.5 + 0\times1$	1.0

然后把这三个分数变成加起来等于一的权重（用的函数叫 softmax，作用是放大差距再归一）：

动物 ≈ 92.6%，累 ≈ 4.6%，马路 ≈ 2.8%。

“它”把九成以上的注意力给了“动物”。

而这件事没有任何人教过它。训练目标里只有“把下一个词预测对”之类的要求。“它”的查询向量之所以指向 [2, 0] 这个方向，而“动物”的键恰好也在那个方向上，是反向传播一点一点调出来的。

指代消解——语言学里一个专门的研究方向——在这里成了一次点积的副产品。

现在可以看那个公式了。这是本书为这一章预留的唯一一个公式。

$$\text{Attention}(Q, K, V) = \text{softmax}\!\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

逐项翻译：

- QK^T：把每个词的查询和每个词的键两两做点积，得到一张打分表（就是上面那张表，只不过是全句对全句）。
- $\div \sqrt{d_k}$：把分数除以向量维度的平方根。
- softmax：把每一行的分数变成加起来等于一的权重。
- $\times V$：按这些权重，把所有词的值加权求和。

整个第四时代和第五时代，全部建在这一行上。

那个除以根号 d 的操作值得单独说一句，因为它是个很典型的工程细节。

向量维度越高，点积的结果就越容易变大——几百个数相乘再相加，绝对值自然就上去了。

而 softmax 有个脾气：喂给它的数一大，它就会走极端，把几乎全部权重压给最大的那一个，其余全部趋近于零。权重一旦变成 0 和 1，梯度就没了（第 16、19 章那条老线）——网络学不动了。

除以 $\sqrt{d_k}$，是把分数拉回一个温和的范围。

一个只有五个字符的修正，防止了整个机制在高维下瘫痪。 这本书里这样的东西已经出现过好几次了：ReLU 的“负数归零”（第 19 章），残差的那条线（第 20 章）。深度学习的真实历史，有很大一部分是由这种朴素到不像话的小修正推着走的。

第二个零件：**多头**。

刚才那套办法有个毛病：每个词最后只拿到一个加权平均，而一次平均只能表达一种关系。“它”这个词可能同时需要知道好几件事：它指代谁、它在句子里做什么成分、它前面那个词是什么。一个平均说不了三件事。

解法很朴素：做好几套。

把向量切成若干份（原论文用了八份），每一份配一套自己的查询、键、值矩阵，各自独立地算一遍注意力，最后把结果拼起来。这就是多头注意力，每个“头”可以专注一种关系。

后来的分析确实发现了一些各司其职的头：有的头几乎总是看前一个词，有的头专门盯着句法上的支配关系，有的头盯着罕见的词。

不过这里要收着说。后续研究也发现，很多头是冗余的——训练完之后把其中相当一部分剪掉，性能几乎不掉。**“每个头有一份清晰的工作”是一个好故事，但它只对一部分头成立。**

第三个零件：**位置编码**。而它是删掉循环之后必须偿还的第一笔债。

注意力有一个致命的盲点：它看不见顺序。

回头看刚才那套算法——查询和键做点积，归一化，加权求和。这里面没有任何一步用到“谁在前谁在后”。你把句子里的词打乱顺序，算出来的结果只是跟着乱序走，内容一模一样。

也就是说，对这个机制来说，“狗咬人”和“人咬狗”是同一句话。

循环网络不需要操心这件事——它是一个词一个词读进去的，顺序天然就在里面。而这正是被删掉的东西。所以顺序必须被人工加回去。

原论文的做法是：给每个位置造一个特定的数值图案，直接加到那个词的向量上。

图案是用不同频率的正弦和余弦波做的。直觉可以用二进制计数器来理解：

`` 位置 0 → 000 位置 1 → 001 位置 2 → 010 位置 3 → 011 位置 4 → 100 ``

看最右边那一位：0、1、0、1、0，每一步翻一次。 中间那一位：0、0、1、1、0，每两步翻一次。 最左边那一位：每四步翻一次。

几个不同“周期”的位叠在一起，就能唯一地标出一个位置。正弦波做的是同一件事，只不过是连续的、平滑的——而平滑很重要，因为它让模型有可能推断出“隔了多远”这种相对关系。（这也是原论文自己给的理由：任何一个位置的图案，都可以由另一个位置的图案经一次固定的线性变换得到，“隔了 k 步”因此变得容易学。二进制只是个直觉扶手，这一条它不覆盖。）

这个设计里有一处，我第一次读的时候觉得很不对劲。

位置图案是“加”到词向量上的，不是拼接在旁边。

也就是说，同一批数字里，既装着“这是哪个词”，又装着“它在第几位”。两种完全不同的信息，被摞在了一起。这听起来像是把地址写在信纸的字里行间。

而它管用。 后来的人换过很多种位置编码的方案，有些确实更好，但“把位置直接加进去”这个基本姿势保留了下来。

（为什么能行，简单说是因为高维空间足够大：几百上千个维度里，“词义”和“位置”可以占据大致互不干扰的方向。这个解释在第 28 章还会再用一次。）

最后两样零件是从上一章借来的，一句话带过。

残差连接（第 20 章）：每个子模块的输出，都要加回它自己的输入。于是一层的默认行为是“原样传过去，再加一点修正”。

层归一化：每过一层，把数值重新拉回一个稳定的范围，防止训练跑飞。

把这些拼起来，一个 Transformer 层就是：多头自注意力 → 加回输入、归一化 → 一个普通的前馈网络 → 再加回输入、归一化。然后把这样的层堆起来。原论文堆了六层。

请记住“堆起来”这个动作。第 24 章整章都在讲堆到多少层为止。

—— 四 ——

现在说这个架构的三种裁法，因为它直接决定了下一章的分叉。

原论文的模型是**编码器-解码器**结构：一半读源语言，一半写目标语言。这是为翻译定制的。

而人们很快发现，你可以只要其中一半。（一个为翻译定制的东西，它最有影响的用法是被拆成两半分开使用。这一点在 2017 年不会有人预料到。）

只留编码器。 这一半的特点是：每个词可以同时看到左边和右边的所有词。它读完整段话，给出一份“理解”。适合的任务是：判断这句话的情感、这两句话是不是矛盾、这个词在这里是什么意思。你要的是理解，不是生成。

只留解码器。 这一半有一个限制：每个词只能看到自己左边的词。

为什么要这个限制？因为它的任务是预测下一个词——如果让它看到右边，它就直接看到答案了，训练变成作弊。于是这一半天生只会做一件事：给定前文，猜下一个词。

而这一件事，就是第五时代的全部。

“只能看左边”这个限制是怎么做到的？值得说一下，因为这个小动作有一个大得离谱的后果。

回到第三节那张打分表。做法是：在过 softmax 之前，把所有“看向右边”的格子，分数直接改成负无穷。负无穷经过 softmax 之后就是零。于是那些位置拿到的权重严格为 0，信息一点也过不来。

这就叫**掩码**。一个下三角形的遮罩，盖在打分表上。（这个领域后来发明了无数种精巧的机制。而防作弊的办法，始终是一个三角形。）

而它带来的好处，是这套东西后来能吞掉整个互联网的原因。

假设你有一句一千个词的话，你想训练模型“给定前文猜下一个词”。朴素的做法是：把前 1 个词喂进去猜第 2 个，把前 2 个喂进去猜第 3 个……跑一千遍。

而有了掩码，你只需要跑一遍。

把整句话一次性喂进去，每个位置在算的时候都自动只看得见自己左边——于是第 1 个位置在猜第 2 个词，第 2 个位置在猜第 3 个词，一千个位置同时在做一千道不同的题，而且互不泄题。

一次前向计算，一千份训练信号。

请把这一条记牢，第 24 章那条公式的分母里就是它。这个领域后来之所以能把几万亿个词读完，靠的不是有人买了更多显卡，而是每一块显卡在同一秒里能同时做上千道题。

这两条路在 2018 年正式分岔，成了两个名字：

只有编码器的那一支，叫 **BERT**。它一度赢下了几乎所有的理解类任务。

只有解码器的那一支，叫 **GPT**。

在 2018 年，第一支看起来明显更强。

下一章我们讲这两支怎么走的，以及为什么最后是看起来更笨的那一支赢了。

现在说那个标题，因为它有后果。

《你只需要注意力》这个标题，据琼斯说来自披头士 1967 年那首《你所需要的只是爱》。它是个玩笑。

而它取得太成功了。

此后的十年里，学术界产生了数量惊人的、标题形如“某某就是你所需要的一切”的论文。它们涵盖了卷积、多层感知机、少量数据、更多数据、修剪、注意力的替代品，以及至少一篇论证“注意力并不是你所需要的一切”的论文。

这大概是这篇论文传播最广、也最不幸的一项遗产。

而抛开玩笑，这个标题在技术上还有一个问题：它不准确。这个架构里不只有注意力。它还有前馈层——而按参数量算，前馈层占了大头，后来的研究认为模型学到的很多“知识”就存在那些层里（第 28 章）。它还有残差、层归一化、位置编码，每一样缺了都不行。

说“你只需要注意力”，大致相当于说一座桥“你只需要钢缆”。

但那个标题是对的，在一个更重要的意义上：它准确地指出了**被删掉的是什么**。

循环没了。卷积没了。而它照样成立。

这才是那一年真正的新闻。

五

先说一件容易被后来的叙述抹掉的事：**它不是当场被认出来的**。

2017 年 12 月，这篇论文在当年那场机器学习大会上亮相。它没有拿任何奖项——那一年的几项论文奖，都给了别的工作。

在当时的读法里，它是一篇很好的翻译论文——成绩漂亮，训练便宜，架构干净。至于“这个架构会取代一切”，论文没这么说，读者也没这么想。领域大约花了一年才形成共识。

请把这件事和第 19 章那个细节对照：2009 年 ImageNet 的论文，被安排在会场角落的一块展板上。**这本书里最有影响的两篇论文，在发表当时都没有被特别对待**。

这不是评审人瞎了眼。它说的是一件更朴素的事：一个想法的重要性，取决于后来有多少人拿它去做别的事——而这件事在发表当天，谁也看不见。

而“后来有多少人拿它去做别的事”，这一次有一个很具体的推手：代码是公开的。

这八个人做这项工作时用的是一套开源框架，论文一发，实现就在那里，任何人都能下载、跑通、改。

这在这本书里是件新事。

第 10 章罗森布拉特那台感知机是一台具体的机器，在康奈尔的一个房间里，你想验证得亲自去；第 12 章那些专家系统是商业产品，规则库是公司的资产；第 17 章那些统计翻译系统，光是把数据准备好就要几个月。

在这本书的前二十章里，“重复一遍别人的结果”通常意味着几个月的工作，而且经常失败。

而 2017 年之后，它意味着一个下午。

这件事对这门学科速度的影响，不比任何一个算法小。一个研究生在自己学校的机器上就能拿现成的实现改一改，试一个新想法，第二周就发出去。这也是为什么第四时代看起来这么快：不完全是因为想法更好了，也因为验证一个想法的成本，掉到了从前的百分之一。

（这条线有它的另一面：等到模型大到要几万块芯片才训得动的时候，“开源代码”就不再等于“任何人都能验证”了。第 31 章会讲这件事。）

接下来发生的事，速度上和 2012 年那次很像（第 19 章），性质上完全不同。

2012 年 AlexNet 之后，计算机视觉在十八个月里换了全部工具，而换掉的只是计算机视觉。语言、语音、决策各走各的。

而 2017 年之后被换掉的，是所有的领域。

一年之内，Transformer 从翻译扩散到了几乎每一个语言任务。再过两三年，它开始出现在跟语言毫无关系的地方——图像被切成小块当成“词”来处理，蛋白质的氨基酸序列被当成“句子”，音频、视频、下棋的棋谱、机器人的动作序列。第 25 章整章讲这件事，标题叫“万物皆可 Transformer”。

而它之所以可能，是第 21 章末尾那个性质：注意力不挑食。它只要一堆向量，和一个“我现在想找什么”的查询。至于那些向量是从法语句子、从图片方块、还是从氨基酸来的，这个机制根本不问。

第四时代的暗线，到这里可以说清楚了（第 21 章开头提过）：

这个领域用了六十年，为不同的问题造不同的机器。而 2017 年之后，大家发现只需要一种机器。

于是竞争的性质变了。

在此之前，赢的办法是想出一个更聪明的结构。卷积赢在它贴合图像的平移不变性（第 15 章），LSTM 赢在它的门控（第 16 章）——每一次进步，都是某个人对某类问题的洞察。

在此之后，结构基本不变了。赢的办法变成了：谁能往同一个结构里灌进更多的数据和更多的算力。

这个转向决定了今天的产业格局。一个想法可以出自任何一个博士生的笔记本；而一次训练要几万块芯片，那是另一类机构才付得起的东西。

第 24 章会把这件事写成一条公式。第 31 章会讲这条公式的政治后果。

最后，说说那八个人。

到 2020 年代中期，八位作者全部离开了谷歌。

他们大多去创业，做的都是同一个方向的公司：有人做对话模型，有人做企业级的语言模型服务，有人做通用助手，有人转去做生物领域的应用，有人去了别的实验室。其中几家公司的估值，在几年内达到了十位数美元。

这件事本身就是这个时代的一个隐喻。一篇论文改变了一个行业，而写它的八个人，一个都没留在写出它的地方。（严格说，后来有一位被老东家重金请了回去——两年之后，他又走了。）

这不是谷歌的失误，也不是这八个人不忠诚。这是第 19 章那条线的自然结果：从 2013 年谷歌买下三个人和一篇论文开始，这个领域的资源就从大学和公共基金，转移到了少数几家公司手里（第 19、20 章）。

而当一个想法的商业价值以十亿计的时候，它的作者留在一家公司里领工资，就成了不太可能的事。

这本书写到这里，那些为爱好、为好奇、为一个说不清的信念而工作的人——罗森布拉特、皮茨、维纳、辛顿的二十年——基本上讲完了。

从下一章开始，钱是故事的一部分。

而下一章那件事，本身跟钱还没什么关系。它是一个更朴素的发现，朴素到有点让人不服气。

架构已经有了。接下来人们要问的问题是：**喂给它什么？**

在 2017 年，答案是显然的：你要它做翻译，你就喂它成对的翻译句子；你要它做情感分类，你就喂它标注好情感的句子。每一个任务，配一套自己的标注数据。而标注数据很贵——第 19 章那几万个每张图挣几美分的人，就是干这个的。

然后有人试了一件几乎是偷懒的事：

先别管任务。让它把能找到的文本全部读一遍，读的时候只做一件事——猜下一个词。读完了，再来学具体任务。

这个想法看起来不该管用。**它管用得离谱**。

第 27 章

涌现，还是幻觉

能力是突然长出来的，还是我们的尺子有问题？全书最重要的一场当代争论——双方并列，不裁决。

一

先看一张图。

横轴是模型的规模——参数量，或者训练用掉的算力，取对数。

纵轴是某一项任务的成绩，比如“三位数加法算对的比例”。

这条曲线的形状是这样的：在很长的一段上，它贴着地面，几乎是零。模型翻十倍，还是零。再翻十倍，还是零。

然后在某一个规模上，它突然抬起头来，冲到百分之七八十。

2022 年，很多人看着这样的图，得出了一个结论：**有些能力不是被造出来的，是长出来的。**

这个结论后来被总结成一个词：**涌现**。

这一章是这本书最难写的一章，因为它讲的是一场还没结束的争论，而争论的双方都不傻。

按这个时代的落笔纪律，**我在这一章不裁决。** 我会把两边最强的论证并排放好，然后停下来。（不裁决是一条纪律，不是一种美德。真要有本事裁，我早裁了。）

而我要提前说明这场争论为什么重要，因为它听起来像是学者在抠字眼。

它不是。

如果能力真的会在某个规模上突然出现，那么就存在一类你无法事先知道的能力。

你训一个模型，训完了才发现它会做一件你没想到的事。

而“你没想到的事”里，可能包括你不希望它会做的事。

在这个前提下，任何形式的事前安全评估都是滞后的——你只能训完了再测，而训完就已经存在了。

这条推理，是第 31 章那些治理主张的主要技术依据之一。

所以“涌现是不是真的”，不只是一个词的问题。

二

先给正方最强的版本。

2022 年，一批研究者系统地整理了这个现象。做法是：拿一大批任务，在一系列不同大小的模型上测，把成绩画成曲线。

他们发现，有相当一批任务的曲线是那个形状：**长期贴地，某个规模之后突然抬头。**

这些任务包括：多位数的算术、把打乱顺序的字母还原成一个词、把一串国际音标还原成它拼的那个词、跨几十个学科的多项选择题、以及一些需要先读懂题目要求再执行的任务。**共同点是：没有一项是有人打算让它学会的。**

他们给“涌现能力”下了一个操作性的定义：

> 在小模型上不存在、在大模型上存在的能力。

注意这个定义有多克制。它没有说这是新的智能，没有说模型在思考，**它只描述了一条曲线的形状。**（一个只描述形状、不解释成因的定义，在这本书里通常是安全的。这一个不是。）

正方论证的力量，来自三点。

首先，这不是个别现象。这样的曲线在几十个任务上被观察到，跨了好几个不同机构训练的模型——不是某一家的某一次实验，也不是某一种架构的怪癖。

其次，**这些能力没有被专门训练过。** 训练目标从头到尾只有“猜下一个词”（第 23 章）。没有人给模型喂过算术题的课程表，没有人为“把字母还原成词”设过一项损失。

而最要紧的一点是：**跨过那道坎的规模，事先算不出来。**

第 24 章那条尺度定律，预测的是损失那个数字。**而损失是平滑下降的**——它不会在某个点上跳一下。

于是出现了一个很别扭的局面：**你能精确预测那个数字会降到多少，你完全无法预测降到那里之后，模型会多出什么本事。**

第 24 章末尾那句话，在这里落地了：一件可以精确预算、却无法预测结果的工程。

三

现在给反方。

2023 年，另一批研究者提出了一个反问：

会不会问题不在模型，在尺子？

这个论证可以用一个最小的例子讲透，请跟着算一遍。

假设任务是：算一道四位数加法。

评分规则是：四位数字全部正确才算对，错一位就是零分。

这是很多基准的标准做法，因为它简单、无歧义。

现在假设模型是这样进步的——平滑地、一点一点地进步：

它每一位数字的正确率，随着规模增大，从 30% 一路涨到 90%，中间没有任何跳跃。

而“四位全对”的概率，**是每位正确率的四次方**。

算一下：

每位正确率	四位全对的概率
30%	0.3^4 = 0.8%
50%	0.5^4 = 6.3%
70%	0.7^4 = 24.0%
80%	0.8^4 = 41.0%
90%	0.9^4 = 65.6%

看这两列的形状差别。

左边一列一路稳稳往上爬，没有哪一步是跳过去的。

右边一列，前半段几乎不动——从 0.8% 到 6.3%，画在图上基本还是贴着地面。而后半段猛蹿：24%、41%、66%。

同一组数据，两把尺子，两种形状。

左边这把尺子说：模型在平稳进步。

右边这把尺子说：什么都没有，什么都没有，然后突然会了。

而右边那把，正是很多基准在用的那把。

要说明的是：表里这五行是为讲解挑的示意值，不是哪一次实测的结果。要紧的不是这几个数字，是四次方这件事。

这个道理不难，而它适用的范围很宽——它是一个普遍机制，不是一个特例。

任何"必须连续做对若干步才算成功"的任务，都会自动产生这种形状。

写一段能运行的代码——每一行都得对。完成一个五步的推理——每一步都不能塌。按格式生成一张表——任何一个字段错了都算废。

而这恰好是我们最关心的那类任务。

于是有一个很扎心的可能性：这个领域这几年观察到的大量"突然会了"，可能有相当一部分只是"每一步的可靠性从 0.7 涨到了 0.9"这件平淡的事，被连乘放大成了戏剧。

这本书讲了二十七章，出现过很多次"尺子决定结论"。第 11 章莱特希尔用外推曲线判了一个领域死刑，而他量的是当时那批玩具程序。第 19 章那个 ImageNet 榜单让整个视觉领域十八个月换了工具，因为它给了所有人同一把尺子。第 23 章 GLUE 屠榜的震撼，也是一把尺子给出的。（这份清单还能往下列。我停在三把，是因为再列下去，这一节就变成一个关于尺子的章节了。）

而这一次是反过来：尺子第一次成了被告。

反方的主张，可以浓缩成一句话：

"突然出现"可能是评分方式制造出来的，不是模型行为里真有的。

他们没有停在论证上，做了两组验证。

第一组是换尺子。把那些呈现出"涌现"形状的任务，换成连续的、给部分分的指标重新评一遍——比如不看"是否全对"，而看"模型给正确答案分配了多少概率"。他们用的是 GPT-3 那一族的一系列模型，另外把一整个公开基准上被认作涌现的任务也过了一遍。换完之后，很多曲线变平滑了。

第二组是反过来构造。拿一个大家公认平滑进步的能力，故意换上一个"全对才给分"的苛刻指标——那条曲线也长出了"涌现"的形状。**而这一步他们是在视觉模型上做的**：卷积网络、自编码器，跟语言一点关系都没有。

这一步的分量在于：它说明那个形状可以由尺子单独造出来，模型那边不需要发生任何特别的事。

而正方对这个反驳有回应。头两条是正方公开说过的；第三条和最后那条是本书的整理，不是谁的原话。

第一，“换成连续指标就平滑了”，**不等于那道坎不存在**。

用户碰到的是离散的世界。你要模型帮你算一道题、写一段能跑的代码、按格式填一张表——这些事就是全对才有用。一段代码“每个字符正确率 90%”是不能运行的。

所以：即使模型内部在平滑地进步，“它能不能替我把这件事做完”这个问题的答案，仍然是在某个规模上从否变成了是。而当初人们关心“涌现”，关心的正是这个答案。

第二，**不是所有涌现现象都能这样解释掉**。有一批后续工作换了横轴——不看模型有多大，看它的预训练损失降到了哪一步——在这个坐标下，一些任务的转折依然在，而且跟指标连不连续没有关系：损失越过某个值之前，成绩就是瞎猜的水平。**这个反驳解释了一类曲线，没有解释掉全部**。

第三，**那把“全对才给分”的尺子也不是随便选的**。基准之所以那样评分，是因为在很多任务上，“部分正确”本来就不是一个有意义的概念。换成连续指标，看到的曲线确实更平滑，代价是它衡量的已经不完全是原来那件事了。

还有一条，是双方都同意的：**这个反驳没有解决那个安全问题**。因为哪怕进步是平滑的，“它跨过可用门槛的那个规模”依然事先算不出来。

你还是得训完了才知道。

我在这里停下，因为这就是这场争论目前所在的位置。

要说这几年发生了什么变化，最稳妥的说法是：**举证责任挪了个位置**。

再看到一条陡曲线，你不能只凭它就说“能力跳出来了”——你得先说明这个形状不是评分方式造成的。

而“我们无法事先知道下一个更大的模型会做什么”这一条，两边都没有否认。

第 31 章那些争论真正依赖的，是后一条。

—— 四 ——

现在说这场争论实际打起来的两个战场，因为它们比曲线的形状更具体。

第一个战场，叫思维链。

2022 年，两拨人先后发现了同一件事的两个版本，做法都简单到荒谬。

先是有人发现：你问模型一道需要几步推理的题，它经常答错；而如果你在提示里给它看几个把中间步骤一步一步写出来的例子，它的正确率会明显上升。

几个月后，另一拨人发现连例子都可以不给——**在题目后面加一句“让我们一步一步地想”，就够了。**

同一个模型，同一道题，权重一个都没改。 只是让它把过程写出来。

这件事为什么让人困惑？

因为按最朴素的理解，模型是一个固定的函数：输入进去，输出出来。让它多写几个字，凭什么答案就更对了？

有一种解释这几年拿到了比较多的理论支持，它跟“思考”关系不大，跟计算量关系很大：

模型每生成一个词，能做的计算量是固定的——就是网络那几十层跑一遍。一道需要三步推理的题，如果要求它直接给答案，它就必须在这一次计算里把三步全做完。

而如果它可以先写出第一步，那么第二步的计算，就可以建立在“第一步已经写在纸上”的基础上。

换句话说：**把中间步骤写出来，等于给了它更多次计算的机会，也等于给了它一块草稿纸。**

第 22 章那个架构决定了这一点：模型能看到自己已经写出来的东西（那是它输入的一部分），却看不到自己“想过但没写”的东西——因为不存在这种东西。

它没有内心。它写下来的，就是它全部的思考过程。

这句话很朴素，而它有一个很重的推论，第 29 章整章都在讲：

如果多写几步就能答得更对，那么让它写得更多、想得更久，是不是就能更强？

第二个战场，是上下文学习。

第 24 章讲过这个现象：在输入里给几个例子，模型就学会了一个新规则，而权重一个都没改。

这件事到今天仍然没有一个所有人都接受的解释。主要的几种说法是：

一种说，模型在前向计算的过程中，内部实际上在做一种类似“学习”的操作——有工作试图证明，注意力机制可以在内部模拟出简单的学习算法。

另一种说，模型没有在学任何东西，它只是在识别任务。它读过的海量文本里已经包含了各式各样的任务，你给的那几个例子不是在教它，是在告诉它“用哪一套”——像是在一个巨大的抽屉柜前，指出该拉开哪一格。

这两种说法各有实验证据支持一部分，而且它们不完全互斥。

我把它们并列在这里，是因为这场争论的形状很典型：**一个现象非常确凿地存在，而对它的机制，我们只有几个互相竞争的猜测。**

这本书前面二十六章的技术，绝大多数都是先有原理再有效果。这一章讲的这些，是先有效果，而原理还没跟上。

而在这两个战场之下，还压着一场更老的争论，它才是这一章标题真正指的那个问题：

它到底懂不懂？

先给否定一方最强的版本，因为它比“它只是统计”这种流行说法讲究得多。

这一派的核心论证是：模型接触的只有形式，没有意义。

一个词的意义，来自它和世界的联系——“苹果”这个词指向真实的苹果，而这个指向关系需要有人吃过苹果、见过苹果、指着苹果说过这个词。

而模型见过的，只有符号之间的共现关系。它知道“苹果”常和“吃”“红”“树”一起出现，**它从未接触过那些词所指的东西。**

这一派把“形式不等于意义”这条论证写得最完整的一篇，发表在 2020 年。而真正传开的是 2021 年那一篇，它用了一个很不客气的比喻：这样的系统是一只**随机鹦鹉**——它把形式缝合得很好，而缝合的过程里没有任何指向意义的东西。

他们的论证有一个很尖锐的推论：**你在跟它对话时感受到的理解，全部产生于你这一侧。** 是你在把意义投射到那些符号上，就像坎佩伦的观众把智能投射到那个柜子上（第 1 章）。

这条批评有一个更早、更严格的版本，这本书到这里才把它请出来。

1980 年，哲学家约翰·塞尔（John Searle, 1932 – 2025）提出了一个思想实验，叫中文屋。

按年代，塞尔本该在第 11 章那批人旁边出场——中文屋和德雷福斯的批评是同一个十年的产物，针对的也是同一种系统。我把他压到这里，是因为这个论证真正难缠的对手，四十年后才出现。（把一个 1980 年的论证往后挪四十年再讲，是写史话的人少数几件不必向谁请示的事。）

设想一个不懂中文的人被关在屋子里。外面递进来写着中文的纸条，屋里有一本极其详尽的规则手册，告诉他看到什么样的符号就该抄写什么样的符号出去。

他照做，屋外的人收到的回答完美流利。

塞尔问：这个人懂中文吗?

他的答案是不懂——而他真正的结论更重：**整个屋子也不懂**。 因为屋子里除了符号搬运，什么都没有发生。而任何按程序运行的计算机，都是这间屋子。

这个论证四十多年来被反复攻击。最有名的反驳是：不懂中文的是那个人，而“人 + 手册 + 屋子”这个整体懂。塞尔在同一篇文章里就把这一手堵了回去，他的应对大意是：那就让屋里的人把整本手册全背下来，把整套系统装进自己身上，甚至可以走到户外去做同样的事——屋子没有了，他还是不懂。

这一来一回，四十多年没有分出胜负。

它在 1980 年针对的是第 12 章那种符号系统。而它今天针对的东西，性质完全不同——

因为屋里那本手册，不再是人写的了。

现在给肯定一方最强的版本。它的起点是一个论证，落点是一个实验。

这一派的论证起点，是第 23 章那句话：预测是所有任务的上界。

要把下一个词猜得足够准，你不可能只记住共现关系。你得对文本描述的那个世界有某种内部模型——否则一到没见过的组合上，你就露馅了。

换句话说：**足够好的预测，逼着你去建模被预测的东西**。

这个论证有一个常被忽略的好处：它不要求模型“有意识”，也不要求它“像人”。它只说，一个系统若能在没见过的组合上稳定地答对，那么它内部就得有点什么在支撑这种稳定——**而“有点什么”是可以去找的，不必靠争辩**。

这个论证到这一步为止还留在纸面上。而 2023 年前后，有一类实验让它落了地。

做法是这样：拿一种棋，只把棋谱喂给模型——一串一串的落子记录，纯符号，从不告诉它棋盘长什么样、规则是什么、什么叫合法。

训练目标只有一个：猜下一步落在哪。

然后，去模型内部找：它有没有在什么地方，表示出了当前棋盘的状态？

结果是找到了。 研究者能从模型的内部激活里，把每个格子上是黑子、白子还是空的，读出来。

而更硬的一步是：他们去改。 在模型内部把某个格子的表示改掉，模型接下来给出的走法，就跟着改成了符合那个被篡改的棋盘的走法。

这不是相关性，这是干预。 它说明那个内部表示不是巧合，是模型真的在用的东西。

一个只读过符号串的系统，自己长出了一个棋盘。

没有人给它看过棋盘。

这个实验解决了这场争论吗？没有。

下面这两段要先交代一句：两方没有就这个实验直接交锋过，以下是本书把各自的一贯立场推到它上面的结果，不是谁的原话。

否定一方的回应很有力：一盘棋是一个封闭的、规则完备的小世界——它的“世界模型”可以完全由那些符号串蕴含。而真实世界不是。关于疼痛、关于苹果的味道、关于一件事对一个人意味着什么，这些东西在文本里留下的痕迹，未必足以支撑起一个模型。

肯定一方的回应也很有力：把这个论证推到底，就要求“懂”必须有身体、有感官、有生活——而这条要求本身需要论证，不是不言自明的。

这场争论的位置，跟这一章前半段那场是一样的：**双方都拿得出证据，而没有一个实验能同时说服两边。**

这本书讲了二十七章，从笛卡尔给动物划的那条线开始（第 2 章），到拉美特利把那条线焊死（第 2 章），到图灵说别问它懂不懂、看它做什么（第 8 章），到德雷福斯说有些东西不能被写成规则（第 11 章）——

每一代人都以为自己这一代能把这个问题问清楚。

每一代人都把它原样传给了下一代。

—— 五 ——

2023 年 3 月，一篇长文让这场争论彻底出圈。

一批微软的研究者拿到了当时最强模型的早期版本，做了大量测试，然后写了一份一百多页的报告。

报告的标题里有“火花”这个词，说的是通用人工智能的火花。

里面的例子很有冲击力：模型能用编程语言画出一只勉强能认的独角兽，能解一些看起来需要空间想象的题，能写出结构复杂的程序，能在一些需要推测他人心理状态的题目上给出正确回答。

这份报告的影响极大。 它也立刻遭到了严厉的方法学批评。下面这四条都是当时公开发表的意见，不是我事后的整理，必须和报告一起引用：

第一，评测污染。 这些测试题很多来自公开的网络内容，而模型读过大半个互联网——你没法排除它在训练时见过原题。

第二，不可复现。 报告用的是一个未公开的早期版本——架构、训练数据一概没有披露，外部研究者无法重复这些实验。**而可重复是这本书前二十六章讲的所有科学的底线。**

第三，样本挑选。 报告展示的是成功的例子。失败的例子有多少、用什么标准挑的，没有系统交代。

第四，“火花”这个词本身。 它是一个比喻，不是一个可以证伪的命题——你没法设计一个实验来证明某个东西“没有火花”。

我把这四条列在这里，不是要否定那份报告的价值——它记录了很多有意思的现象，而且它提出的问题是真问题。

我列出来，是因为这本书从第 1 章那个柜子起就在做同一件事：**分清“我们看到了什么”和“我们认为它意味着什么”。**

而与此同时，一个相反方向的麻烦浮了出来：我们开始不知道怎么衡量这些东西了。

这本书的前二十几章，进步是靠榜单衡量的。ImageNet 的错误率（第 19 章）、翻译的分数（第 22 章）、GLUE 的总分（第 23 章）——每一次进步都是一个数字往前挪。

而到 2023 年前后，模型开始在一个又一个基准上逼近满分。

一个所有人都接近满分的考试，就不再是考试了。

更麻烦的是前面那条评测污染：当模型读过整个互联网，而基准题目就在互联网上，你怎么知道它是答对了，还是记住了？

于是这个领域进入了一种奇怪的状态：能力在快速变化，而衡量能力的手段在失效。

新的做法陆续出现——出更难的题、用从未公开过的题、请各领域的专家亲自出题、让模型两两对打由人投票排名、以及去测那些需要几小时甚至几天才能完成的长任务（这一条接到第 30 章）。

而一个根本的困难留了下来：

当一个系统在你能想到的每一项测试上都表现良好时，你怎么知道它是真的会，还是只是很会考试？

母题六又一次回来了，而这一次真的难以回答。

阿达·洛夫莱斯说，机器只能做我们知道如何命令它做的事（第 4 章）。此前每一回这句话被顶回来，我们还能说清它被顶到了什么位置——TD-Gammon 下出了没人教过的开局（第 18 章），对抗网络画出了不存在的人脸（第 20 章），文字生成了从没有过的图像（第 25 章）。

而这一次，我们连“它做到了什么”都测不准。

最后说一个词，因为它是这一章的主题在语言上的镜像。

模型编造事实这个毛病，被普遍叫作“幻觉”。

这个词起得不好——第 26 章讲到模型为什么会编时，我把这句话欠在了那里。

幻觉在精神医学里，指的是在没有相应外部刺激的情况下产生的感知体验——一个人“听见”了不存在的声音。这个词预设了一个正常状态：平时是感知得到真实世界的，出问题时才出错。

而模型没有这个正常状态。

它任何时候都在做同一件事：根据前文，生成最可能的下一个词。

它答对的时候和答错的时候，机制完全一样。

没有哪一次是“它这回出毛病了”。

所以准确的说法不是“模型产生了幻觉”，而是“模型这一次生成的内容不符合事实”——而这句话太长，永远不会赢过那两个字。（一个词能不能留下来，跟它准不准没有多大关系，跟它好不好念关系很大。这条规律在这本书里比任何一条技术路线都稳定。）

这个抱怨不是我先提的。 从 2023 年起陆续有人主张换词，比较常见的提议是“虚构”：精神医学里那个词说的是人在记忆有缺口的地方不自觉地填上一段，填的时候自己并不觉得是在编。**它至少不预设有谁在感知什么。**

母题三（命名的力量）在这本书里最后一次留下记录，而它跟前面几处不同。

麦卡锡造词是为了摆脱一块招牌（第 9 章），“深度学习”是为了摆脱一个烧掉的词（第 19 章），“注意力”是一个贴切但有副作用的比喻（第 21 章），“对齐”让两件难度差得极远的事共用了一个名字（第 26 章）。

而“幻觉”这个词的问题是：它把一个系统性的性质，说成了一次偶发的故障。

它让人觉得这是可以修好的 bug。

而按目前的理解，它是“根据前文猜最可能的下一个词”这件事的直接后果——

你想彻底修掉它，就得换掉那个东西之所以能用的原理。

这一章从头到尾没有回答任何一个问题。

它有没有在思考？涌现是真的吗？它是会了，还是记住了？

这些问题在 2020 年代中期都还开着。

而我想在收尾前，把这一章的处境说得更直白一点，因为它跟这本书前面那些章不一样。

前面二十六章，我几乎每一章都能告诉你后来怎么样了。

明斯基那本书对多层网络的悲观，后来被证明是判断而非定理（第 10 章）。1995 年选支持向量机的人做了当时正确的选择，而世界上数据的数量变了（第 17 章）。2018 年押 BERT 的人押错了，理由是模型后来变大了（第 23 章）。

这种“后来”是历史写作的全部底气。 它让人可以从容地讲对错。

而这一章没有“后来”。

我写下这些字的时候，双方还在各自的位置上。

所以这一章的价值，不在于它给了什么答案，而在于它把问题的形状记了下来——**在还没有人知道答案的时候。**

如果几十年后有人读到这一章，并且觉得其中一方显然是对的，那说明这段历史已经过去了。

我希望那个人能记得：在当时，它并不显然。

而这本书接下来能做的，就只剩一件事了：

而在进去之前，这一章还欠一句话。

这场争论之所以这么难，有一个技术之外的原因——下面这个说法是本书的判断，不是任何一方的自述：**双方要的东西不一样。**

一方要的是一个描述。他们想说清楚“模型在什么规模上开始能做什么”——而这是一个可以用曲线回答的问题。

另一方要的是一个解释。他们想知道“为什么会这样”——**而曲线回答不了这个。**

这两拨人经常以为自己在吵同一件事。

这本书讲了二十七章，这个错位出现过很多次。

明斯基和罗森布拉特之间（第 10 章）、德雷福斯和整个学界之间（第 11 章）、统计派和联结派之间（第 17 章）——**每一次，双方拿出来的证据都不构成对对方的反驳，因为他们要证明的根本不是同一个命题。**

而这一次，双方连“什么算是一个解释”都还没谈拢。

欠的那句话，说完了。

既然从外面吵不清楚，那就打开它，进去看看。